

第一讲 概率测度，随机变量和期望

1. 概率测度 Probability Measure

- 样本空间 (Sample space, 记作 Ω)

定义：随机现象所有可能结果的集合。

例：

- 抛硬币 3 次： $\Omega = \{hhh, hht, hth, thh, htt, tht, tth, ttt\}$ (有限离散)。
- 打印队列中的作业数： $\Omega = \{0, 1, 2, \dots\}$ (可数无穷离散)。
- 相邻两次地震的间隔时间： $\Omega = \{t \mid t \geq 0\}$ (连续、非负实数)。

第一个是有限离散；第二个是可数离散；第三个是连续区间型。

- 事件 (Event)

定义： Ω 的子集。

例：

设 A 为抛硬币 3 次恰有 2 次正面的事件，

$$A = \{hht, hth, thh\}$$

设 A 为打印队列中少于 5 个作业的事件，

$$A = \{0, 1, 2, 3, 4\}$$

- 概率测度是定义在 Ω 的子集上的函数 P ，取实数值，并满足以下公理：

- $P(\Omega) = 1$ 。
- 若 $A \subset \Omega$ ，则 $P(A) \geq 0$ 。
- 若 A_1 和 A_2 互不相交，则

$$P(A_1 \cup A_2) = P(A_1) + P(A_2)$$

更一般地，若 $A_1, A_2, \dots$ 互不相交，则

$$P\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} P(A_i)$$

例：假设硬币是公平的。对于任一 $\omega \in \Omega$ ，

$$P(\omega) = \frac{1}{8}$$

其中

$$\Omega = \{hhh, hht, hth, thh, htt, tht, tth, ttt\}。$$

- 条件概率与乘法法则

- 条件概率：

设 A 和 B 是两个事件，且 $P(B) > 0$ ，则 A 在 B 条件下的条件概率定义为：

$$P(A|B) = \frac{P(A \cap B)}{P(B)}$$

例：假设第一次掷硬币的结果为正面 h ，问在三次试验中恰好出现两次正面的概率是多少？

样本空间为：

$$\Omega = \{hhh, hht, hth, thh, htt, tht, tth, ttt\}$$

事件 B ：第一次掷出正面：

$$B = \{hhh, hht, hth, htt\}$$

事件 A ：三次中恰好两次正面：

$$A = \{hht, hth, thh\}$$

交集（第一次为正，且恰好两次正面）为：

$$A \cap B = \{hht, hth\}$$

由于等可能模型下，每个基本事件的概率为 $\frac{1}{8}$ ，因此：

$$P(B) = \frac{4}{8} = \frac{1}{2}, \quad P(A) = \frac{3}{8}, \quad P(A \cap B) = \frac{2}{8} = \frac{1}{4}$$

由条件概率公式：

$$P(A|B) = \frac{P(A \cap B)}{P(B)} = \frac{\frac{1}{4}}{\frac{1}{2}} = \frac{1}{2}$$

◦ 乘法法则：

设 A 和 B 是两个事件，且 $P(B) > 0$ ，则有：

$$P(A \cap B) = P(A|B)P(B)$$

例：三名囚犯 A 、 B 和 C 将被处决，典狱长决定随机赦免其中一人，并告知狱卒被赦免者的身份，但要求暂时保密。

囚犯 A 试图套出消息，未果，于是问狱卒 B 和 C 中谁会被处决。狱卒回答 B 会被处决。 A 认为此时自己被赦免的概率已从 $1/3$ 升至 $1/2$ ，问 A 的判断是否正确。

设事件： A : A 被赦免, B : B 被赦免, C : C 被赦免。

• 全概率公式、贝叶斯公式和独立性

◦ 全概率公式

- 如果 $B_1, B_2, \dots, B_n$ 是两两互斥且并集为样本空间 Ω 的事件，且 $P(B_i) > 0$ ，那么对任意事件 A ：

$$P(A) = \sum_{i=1}^n P(A|B_i)P(B_i)$$

◦ 贝叶斯公式

- 在上述条件下，有：

$$P(B_i|A) = \frac{P(A|B_i)P(B_i)}{\sum_{j=1}^n P(A|B_j)P(B_j)}$$

◦ 独立性

- 两个事件 A 和 B 独立当且仅当：

$$P(A \cap B) = P(A)P(B)$$

- 一组事件 $A_1, A_2, \dots, A_n$ 相互独立，当且仅当对于任意子集 $A_{i_1}, \dots, A_{i_m}$ 有：

$$P\left(\bigcap_{j=1}^m A_{i_j}\right) = \prod_{j=1}^m P(A_{i_j})$$

例：贝叶斯公式例题

某公司生产的电脑来自三个工厂 A 、 B 、 C ，其产量比例与次品率如下表：

Factory	proportion of total production	Prob of defective products
A	$0.35=P(A)$	$1.5\%=P(D A)$
B	$0.35=P(B)$	$1\%=P(D B)$
C	$0.30=P(C)$	$2\%=P(D C)$

已知随机抽到的电脑是次品，求其来自工厂 C 的概率：

$$P(C|D) = \frac{P(D|C)P(C)}{P(D|A)P(A) + P(D|B)P(B) + P(D|C)P(C)}$$

2. 随机变量和分布 Random Variable and Distribution

- 随机变量：

随机变量是一个从样本空间 Ω 到实数集 $\mathbb{R}$ 的函数。

例：

- X_1 ：正面出现的总次数
- X_2 ：第一次抛硬币出现正面的次数
- X_3 ：正面次数减去反面次数
- 分布：随机变量的取值范围在实数轴上，可以用不同方式描述其概率测度。

	离散型	连续型
单变量	pmf, cdf, mgf	pdf, cdf, mgf
多变量	联合 pmf, 联合 cdf, 联合 mgf	联合 pdf, 联合 cdf, 联合 mgf

其中，pmf: probability mass function（概率质量函数）；pdf: probability density function（概率密度函数）；cdf: cumulative distribution function（累积分布函数）；mgf: moment generating function（矩生成函数）

- 随机变量分类：
 - 离散型随机变量：取值为有限个或可数无限多个值。
 - 连续型随机变量：取值为连续区间上的无限多个值。
- 分布函数 (distribution function)
 - 累积分布函数 (cumulative distribution function, cdf)：对于随机变量 X ,

$$F(x) = P(X \leq x), \quad x \in \mathbb{R}.$$

- 概率质量函数 (probability mass function, pmf)：若 X 为离散型随机变量，则

$$p(x) \geq 0 \quad \forall x, \quad \sum_x p(x) = 1.$$

对于 pmf $p(x)$ ：

$$P(X = x) = p(x), \quad P(X \in A) = \sum_{x \in A} p(x).$$

- 概率密度函数 (probability density function, pdf) : 若 X 为连续型随机变量, 则

$$f(x) \geq 0 \forall x, \quad \int_{-\infty}^{\infty} f(x) dx = 1.$$

对于 pdf $f(x)$:

$$P(X \in A) = \int_A f(x) dx.$$

- 关系:

$$F(x) = \int_{-\infty}^x f(t) dt, \quad f(x) = \frac{d}{dx} F(x).$$

注意: 若 $f(x) > 0$, 则 $P(X = x) = 0$.

- 累积分布函数 (cdf) 的性质

若 $F(x)$ 是某随机变量 X 的 cdf, 则:

1. $0 \leq F(x) \leq 1$
2. $F(x)$ 单调不减 (nondecreasing)
3. $F(x)$ 右连续 (right-continuous) :

$$\lim_{t \downarrow x} F(t) = F(x)$$

4. $\lim_{x \rightarrow \infty} F(x) = 1, \lim_{x \rightarrow -\infty} F(x) = 0$.
5. $P(X > x) = 1 - F(x), P(a < X \leq b) = F(b) - F(a)$.
6. 对任意 x , $F(x)$ 存在左极限 (left limit)
7. $F(x)$ 至多只有可数多个间断点 (discontinuity points) .

如果函数 $F(x)$ 满足性质 2, 3, 4, 则它是一个累积分布函数 (cdf) .

- **联合分布 (joint distribution) 和边际分布 (marginal distribution)**

为什么需要联合分布?

多元随机变量 (multivariate random variables) 之间可能存在相关性, 单独的边际分布 (marginal distribution) 无法描述它们的依赖结构. 联合分布 (joint distribution) 能够完整刻画这种关系.

例: 样本空间:

$$\Omega = \{hhh, hht, hth, thh, htt, tht, tth, ttt\}$$

设:

X_2 : 第一次投掷中正面 (head) 的个数; X_1 : 三次投掷中正面的总个数.

可以构造 X_2 与 X_1 的二维联合分布表.

$X_2 \backslash X_1$	0	1	2	3	行合计
0	1/8	2/8	1/8	0	4/8 = 1/2
1	0	1/8	2/8	1/8	4/8 = 1/2
列合计	1/8	3/8	3/8	1/8	1

- 边际分布与联合分布的关系

- 已知联合累积分布函数 (joint cdf) 可以得到每个边际累积分布函数 (marginal cdf) .
- 反之不成立, 因为边际分布不包含随机变量之间的依赖信息.

- 数学定义:

- 联合累积分布函数 (joint cdf) :

$$F(x_1, \dots, x_n) = P(X_1 \leq x_1, \dots, X_n \leq x_n), \quad x_1, \dots, x_n \in \mathbb{R}$$

- 边际累积分布函数 (marginal cdf) :

$$F_{X_1}(x_1) = P(X_1 \leq x_1) = \lim_{x_2, \dots, x_n \rightarrow \infty} F(x_1, \dots, x_n)$$

- 离散型的边际概率质量函数 (marginal pmf) :

$$p_{X_1}(x) = F_{X_1}(x) - F_{X_1}(x^-)$$

- 连续型的边际概率密度函数 (marginal pdf) :

$$f_{X_1}(x) = \frac{d}{dx} F_{X_1}(x)$$

- 多元离散型随机变量 (Discrete Multivariate Case)

联合概率质量函数 (joint probability mass function, joint pmf) :

$$p(x_1, \dots, x_n) = P(X_1 = x_1, \dots, X_n = x_n)$$

概率计算:

$$P((X_1, \dots, X_n) \in A) = \sum_{(x_1, \dots, x_n) \in A} p(x_1, \dots, x_n)$$

联合累积分布函数 (joint cumulative distribution function, joint cdf) :

$$F(x_1, \dots, x_n) = \sum_{t_1 \leq x_1, \dots, t_n \leq x_n} p(t_1, \dots, t_n)$$

边际概率质量函数 (marginal pmf) :

$$p_{X_1}(x_1) = \sum_{x_2, \dots, x_n} p(x_1, x_2, \dots, x_n)$$

- 多元连续型随机变量 (Continuous Multivariate Case)

联合概率密度函数 (joint probability density function, joint pdf) :

$$f(x_1, \dots, x_n) = \frac{\partial^n}{\partial x_1 \dots \partial x_n} F(x_1, \dots, x_n)$$

概率计算:

$$P((X_1, \dots, X_n) \in A) = \int_A f(x_1, \dots, x_n) dx_1 \dots dx_n$$

联合累积分布函数:

$$F(x_1, \dots, x_n) = \int_{-\infty}^{x_1} \dots \int_{-\infty}^{x_n} f(t_1, \dots, t_n) dt_n \dots dt_1$$

边际概率密度函数 (marginal pdf) :

$$f_{X_1}(x_1) = \int_{-\infty}^{\infty} \dots \int_{-\infty}^{\infty} f(x_1, t_2, \dots, t_n) dt_2 \dots dt_n$$

- 独立随机变量 (Independent Random Variables)

若

$$F(x_1, \dots, x_n) = F_{X_1}(x_1) \dots F_{X_n}(x_n),$$

则 $X_1, \dots, X_n$ 独立 (independent)。

离散型:

$$p(x_1, \dots, x_n) = p_{X_1}(x_1) \dots p_{X_n}(x_n)$$

连续型:

$$f(x_1, \dots, x_n) = f_{X_1}(x_1) \dots f_{X_n}(x_n)$$

事件形式:

$$P(X \in A, Y \in B) = P(X \in A)P(Y \in B)$$

• 独立性的延伸性质

1. 若 X 和 Y 独立 (independent), 则 $Z = g(X)$ 与 $W = h(Y)$ 也独立。

证明:

记 $\mathcal{B}(\mathbb{R})$ 为实数上的 Borel σ -代数 (Borel σ -algebra)。

对任意 $A, B \in \mathcal{B}(\mathbb{R})$, 有事件恒等式

$$\begin{aligned}\{Z \in A\} &= \{g(X) \in A\} = \{X \in g^{-1}(A)\}, \\ \{W \in B\} &= \{h(Y) \in B\} = \{Y \in h^{-1}(B)\},\end{aligned}$$

其中 $g^{-1}(A), h^{-1}(B) \in \mathcal{B}(\mathbb{R})$ 因 g, h 可测。

由于 X, Y 独立, 知 $\{X \in C\}$ 与 $\{Y \in D\}$ 对一切 $C, D \in \mathcal{B}(\mathbb{R})$ 独立, 故

$$\begin{aligned}P(\{Z \in A\} \cap \{W \in B\}) &= P(\{X \in g^{-1}(A)\} \cap \{Y \in h^{-1}(B)\}) \\ &= P(X \in g^{-1}(A))P(Y \in h^{-1}(B)) = P(Z \in A)P(W \in B).\end{aligned}$$

于是 Z 与 W 独立。

2. 已知 $X_1, \dots, X_n$ 的边际分布 (marginal distributions) 且它们相互独立, 可以唯一确定它们的联合分布 (joint distribution)。

($\Rightarrow$) 若 $X_1, \dots, X_n$ 独立, 则对任意 $x_1, \dots, x_n$,

$$F(x_1, \dots, x_n) = P\left(\bigcap_{i=1}^n \{X_i \leq x_i\}\right) = \prod_{i=1}^n P(X_i \leq x_i) = \prod_{i=1}^n F_{X_i}(x_i).$$

($\Leftarrow$) 设对一切 $x_1, \dots, x_n$ 有 $F(x_1, \dots, x_n) = \prod_{i=1}^n F_{X_i}(x_i)$ 。

记矩形集合 (rectangle) $R = \prod_{i=1}^n (-\infty, x_i]$, 则

$$P((X_1, \dots, X_n) \in R) = F(x_1, \dots, x_n) = \prod_{i=1}^n F_{X_i}(x_i) = \prod_{i=1}^n P(X_i \in (-\infty, x_i]).$$

设 $\mathcal{C}$ 为所有可写成 $\prod_{i=1}^n A_i$ 的集合族, 其中 $A_i \in \mathcal{B}(\mathbb{R})$, 并定义

$$\Lambda = \left\{ B \in \mathcal{B}(\mathbb{R}^n) : P((X_1, \dots, X_n) \in B) = \int \dots \int \mathbf{1}_B(x_1, \dots, x_n) dP_{X_1}(x_1) \dots dP_{X_n}(x_n) \right\}.$$

可验证 Λ 为 λ -系统 (Dynkin system), 而所有矩形

$\prod_{i=1}^n (-\infty, x_i]$ 构成的族是一个 π -系统 (π -system), 且包含于 Λ (由上式)。

由 π - λ 定理 (Dynkin's π - λ theorem),

$\sigma(\mathcal{C}) = \mathcal{B}(\mathbb{R}^n)$ 也包含于 Λ 。

于是对所有 $A_i \in \mathcal{B}(\mathbb{R})$,

$$P\left(\bigcap_{i=1}^n \{X_i \in A_i\}\right) = \prod_{i=1}^n P(X_i \in A_i),$$

即 $X_1, \dots, X_n$ 相互独立。

- 条件分布 (Conditional Distribution)

- 离散型随机变量 (Discrete Random Variables)

已知 X, Y 的联合概率质量函数 (joint probability mass function, joint pmf) $p_{XY}(x, y)$, 则条件概率质量函数 (conditional pmf) :

$$p_{Y|X}(y|x) = P(Y = y | X = x) = \frac{P(X = x, Y = y)}{P(X = x)} = \frac{p_{XY}(x, y)}{p_X(x)}$$

当 $p_X(x) > 0$ 时有效; 若 $p_X(x) = 0$, 定义 $p_{Y|X}(y|x) = 0$.

例: 由联合分布表:

$$P(X_2 = 0, X_1 = 1) = \frac{2}{8}, \quad P(X_1 = 1) = \frac{3}{8}$$

因此:

$$p_{X_2|X_1}(0|1) = \frac{\frac{2}{8}}{\frac{3}{8}} = \frac{2}{3}, \quad p_{X_2|X_1}(1|1) = 1 - \frac{2}{3} = \frac{1}{3}.$$

- 连续型随机变量 (Continuous Random Variables)

已知 X, Y 的联合概率密度函数 (joint probability density function, joint pdf) $f_{XY}(x, y)$, 则条件概率密度函数 (conditional pdf) :

$$f_{Y|X}(y|x) = \frac{f_{XY}(x, y)}{f_X(x)}, \quad y \in \mathbb{R}$$

当 $0 < f_X(x) < \infty$ 时有效, 否则定义为 0.

- 条件分布的性质 (Some remarks)

1. 对于每个固定的 x , 条件概率质量函数 (conditional pmf) $p_{Y|X}(y|x)$ 是 y 的 pmf, 条件概率密度函数 (conditional pdf) $f_{Y|X}(y|x)$ 是 y 的 pdf.

2. 乘法法则 (Multiplication Law) :

$$p_{XY}(x, y) = p_{Y|X}(y|x)p_X(x), \quad f_{XY}(x, y) = f_{Y|X}(y|x)f_X(x)$$

3. 全概率公式 (Law of total probability) :

$$p_Y(y) = \sum_x p_{Y|X}(y|x)p_X(x), \quad f_Y(y) = \int_{-\infty}^{\infty} f_{Y|X}(y|x)f_X(x) dx$$

4. 独立性判别:

$$X \text{ 与 } Y \text{ 独立} \iff p_{Y|X}(y|x) = p_Y(y) \quad \text{或} \quad f_{Y|X}(y|x) = f_Y(y)$$

- 随机变量函数的分布 (Functions of random variables)

已知随机变量 $X_1, \dots, X_n$, 如何求它们函数变换的分布?

- 事件法 (Method of events)

设 $Y = g(X)$, 对于由 Y 定义的任意事件 B , 有

$$P(Y \in B) = P(X \in A), \quad A = g^{-1}(B)$$

例: (单变量离散型随机变量)

设 X 为离散随机变量 (discrete random variable) , 取值 $x_i, i = 1, 2, \dots$, 定义 $Y = g(X)$, 则 Y 也是离散随机变量, 取值 y_j 。

当 $B = \{y_j\}$ 时, 有

$$A = \{x_i : g(x_i) = y_j\}$$

于是

$$p_Y(y_j) = P(\{y_j\}) = P(A) = \sum_{x_i \in A} p_X(x_i)$$

例: 令 $X \sim \text{Bernoulli}(0.6)$ (伯努利分布, Bernoulli) , $Y \sim \text{Bernoulli}(0.4)$, 且相互独立 (independent) 。

因此联合概率质量函数 (joint pmf) $p_{XY}(x, y) = P(X = x, Y = y)$ 为:

$x \backslash y$	0	1	行和
0	0.24	0.16	0.40
1	0.36	0.24	0.60
列和	0.60	0.40	1.00

(计算: $p_{XY}(0, 0) = 0.4 \times 0.6 = 0.24$, $p_{XY}(0, 1) = 0.4 \times 0.4 = 0.16$,
 $p_{XY}(1, 0) = 0.6 \times 0.6 = 0.36$, $p_{XY}(1, 1) = 0.6 \times 0.4 = 0.24$.)

(1) $Z = X + Y$ 的分布

由全概率公式 (law of total probability) :

$$p_Z(z) = \sum_{\substack{x, y \in \{0, 1\} \\ x+y=z}} p_{XY}(x, y), \quad z \in \{0, 1, 2\}.$$

故

$$p_Z(0) = 0.24, \quad p_Z(1) = 0.36 + 0.16 = 0.52, \quad p_Z(2) = 0.24.$$

(2) $V = Y - X$ 的分布 (练习)

同理

$$p_V(v) = \sum_{\substack{x, y \in \{0, 1\} \\ y-x=v}} p_{XY}(x, y), \quad v \in \{-1, 0, 1\},$$

从而

$$p_V(-1) = 0.36, \quad p_V(0) = 0.24 + 0.24 = 0.48, \quad p_V(1) = 0.16.$$

o CDF 方法 (Method of cdf)

这是事件法 (method of events) 的一种特殊情形, 用于求 $Y = g(X_1, \dots, X_n)$ 的分布, 步骤如下:

在 $(x_1, \dots, x_n)$ 空间中, 找到区域 $Y \leq y$ 。

离散型情况: 在 $Y \leq y$ 的区域内对联合 pmf 求和; 连续型情况: 在 $Y \leq y$ 的区域内对联合概率密度函数 (joint probability density function, joint pdf) 积分, 得到

$$F_Y(y) = P(Y \leq y).$$

若 Y 为连续型, 则对 $F_Y(y)$ 求导:

$$f_Y(y) = \frac{d}{dy} F_Y(y).$$

说明：该方法可推广至多元随机变量 (multivariate random variable) $\mathbf{Y} = (Y_1, \dots, Y_m)$ 。

例：

设 X 和 Y 相互独立 (independent)，且均服从区间 $[0, 1]$ 上的均匀分布 (uniform distribution, $U(0, 1)$)。

它们的联合概率密度函数 (joint probability density function, joint pdf) 为

$$f_{XY}(x, y) = 1, \quad 0 \leq x \leq 1, 0 \leq y \leq 1$$

否则 $f_{XY}(x, y) = 0$ 。

要求 $Z = X + Y$ 的概率密度函数 (probability density function, pdf)。

解：卷积公式 (Convolution formula)

由于 X 和 Y 独立：

$$f_Z(z) = \int_{-\infty}^{\infty} f_X(x) f_Y(z-x) dx$$

其中

$$f_X(x) = 1, \quad 0 \leq x \leq 1$$

$$f_Y(y) = 1, \quad 0 \leq y \leq 1$$

情形 1: $0 \leq z \leq 1$

此时 x 的积分范围是 $[0, z]$ ：

$$f_Z(z) = \int_0^z 1 \cdot 1 dx = z$$

情形 2: $1 < z \leq 2$

此时 x 的积分范围是 $[z-1, 1]$ ：

$$f_Z(z) = \int_{z-1}^1 1 \cdot 1 dx = 2 - z$$

情形 3: $z < 0$ 或 $z > 2$

$$f_Z(z) = 0$$

最终结果：

$$f_Z(z) = \begin{cases} z, & 0 \leq z \leq 1, \\ 2 - z, & 1 < z \leq 2, \\ 0, & \text{其它情形.} \end{cases}$$

求 $Z = Y - X$ 的分布

解：

变量变换：

$$Z = Y - X, \quad W = X$$

则

$$Y = Z + W$$

雅可比行列式 (Jacobian determinant) 为：

$$J = \left| \frac{\partial(x, y)}{\partial(z, w)} \right| = 1$$

由于 $0 \leq X \leq 1$ 且 $0 \leq Y \leq 1$, 得到:

$$0 \leq W \leq 1, \quad 0 \leq Z + W \leq 1$$

即

$$-W \leq Z \leq 1 - W$$

因此:

$$f_Z(z) = \int_{\max(0, -z)}^{\min(1, 1-z)} 1 \, dw$$

分情况计算:

- 若 $-1 \leq z \leq 0$:

$$f_Z(z) = \int_{-z}^1 1 \, dw = 1 + z$$

- 若 $0 < z \leq 1$:

$$f_Z(z) = \int_0^{1-z} 1 \, dw = 1 - z$$

- 其它情况: $f_Z(z) = 0$

最终结果:

$$f_Z(z) = \begin{cases} 1 + z, & -1 \leq z \leq 0, \\ 1 - z, & 0 < z \leq 1, \\ 0, & \text{其它情形.} \end{cases}$$

求 $Z = XY$ 的分布

解:

变量变换:

$$Z = XY, \quad W = X$$

则

$$Y = \frac{Z}{W}$$

雅可比行列式为:

$$J = \left| \frac{\partial(x, y)}{\partial(z, w)} \right| = \frac{1}{|W|}$$

约束条件 $0 \leq X \leq 1$ 且 $0 \leq Y \leq 1$ 给出:

$$0 \leq W \leq 1, \quad 0 \leq \frac{Z}{W} \leq 1 \quad \Rightarrow \quad W \geq Z$$

因此:

$$f_Z(z) = \int_{w=z}^1 \frac{1}{w} \, dw, \quad 0 \leq z \leq 1$$

计算:

$$f_Z(z) = [\ln w]_{w=z}^{w=1} = -\ln z, \quad 0 < z \leq 1$$

最终结果:

$$f_Z(z) = \begin{cases} -\ln z, & 0 < z \leq 1, \\ 0, & \text{其它情形.} \end{cases}$$

PDF 方法 (Method of pdf)

这是 CDF 方法的一个特例, 适用于连续型、可微 (differentiable)、——对应 (1-to-1 transformations) 的变量变换。

单变量情形 (Univariate case)

设 X 是连续随机变量, pdf 为 $f_X(x)$, 令 $Y = g(X)$, 其中 g 可微且严格单调 (strictly monotone)。

则:

$$f_Y(y) = f_X(g^{-1}(y)) \cdot \left| \frac{dg^{-1}(y)}{dy} \right|$$

对于那些满足 $y = g(x)$ 的 y 值, 上式成立, 否则 $f_Y(y) = 0$ 。

其中 $\left| \frac{dg^{-1}(y)}{dy} \right|$ 是雅可比因子 (Jacobian factor), 表示密度在变量变换中的尺度调整。

多元连续型随机变量 (multivariate continuous random variables)

设 $\mathbf{X} = (X_1, \dots, X_n)$ 是多元连续型随机变量 (multivariate continuous random variables),

$\mathbf{Y} = (Y_1, \dots, Y_n) = g(\mathbf{X})$ 是其——对应 (one-to-one) 变换。

若反函数 $\mathbf{x} = g^{-1}(\mathbf{y}) = \mathbf{w}(\mathbf{y}) = (w_1(\mathbf{y}), \dots, w_n(\mathbf{y}))$ 存在,

且 $\mathbf{w}$ 各分量有连续的偏导数 (continuous partial derivatives),

则定义雅可比行列式 (Jacobian determinant):

$$J = \begin{vmatrix} \frac{\partial w_1}{\partial y_1} & \cdots & \frac{\partial w_1}{\partial y_n} \\ \vdots & \ddots & \vdots \\ \frac{\partial w_n}{\partial y_1} & \cdots & \frac{\partial w_n}{\partial y_n} \end{vmatrix}$$

概率密度的变换公式为:

$$f_Y(\mathbf{y}) = f_X(g^{-1}(\mathbf{y})) \cdot |J|$$

当 $\mathbf{y} = g(\mathbf{x})$ 对某个 $\mathbf{x}$ 成立时有效, 否则为 0。

例: 已知 X_1 和 X_2 的联合概率密度函数为 $f_{X_1 X_2}(x_1, x_2)$, 求

$$Y_1 = \frac{X_2}{X_1}$$

的分布。

假设 X_1, X_2 独立且均匀分布在区间 $[0, 1]$, 即:

$$f_{X_1 X_2}(x_1, x_2) = 1, \quad 0 \leq x_1 \leq 1, \quad 0 \leq x_2 \leq 1$$

定义变换:

$$Y_1 = \frac{X_2}{X_1}, \quad Y_2 = X_1$$

反变换为:

$$X_1 = Y_2, \quad X_2 = Y_1 Y_2$$

雅可比行列式为:

$$J = \begin{vmatrix} 0 & 1 \\ Y_2 & Y_1 \end{vmatrix} = -Y_2$$

取绝对值得 $|J| = Y_2$ 。

由约束条件 $0 \leq X_1 \leq 1, 0 \leq X_2 \leq 1$ 得:

$$0 \leq Y_2 \leq 1, \quad 0 \leq Y_1 Y_2 \leq 1$$

即

$$0 \leq Y_1 \leq \frac{1}{Y_2}$$

于是:

$$f_{Y_1, Y_2}(y_1, y_2) = 1 \cdot |J| = y_2$$

边缘化得到:

$$f_{Y_1}(y_1) = \int_0^{\min(1, 1/y_1)} y_2 \, dy_2$$

分两种情况:

◦ 若 $0 \leq y_1 \leq 1$:

$$f_{Y_1}(y_1) = \int_0^1 y_2 \, dy_2 = \frac{1}{2}$$

◦ 若 $y_1 > 1$:

$$f_{Y_1}(y_1) = \int_0^{1/y_1} y_2 \, dy_2 = \frac{1}{2y_1^2}$$

最终:

$$f_{Y_1}(y_1) = \begin{cases} \frac{1}{2}, & 0 \leq y_1 \leq 1, \\ \frac{1}{2y_1^2}, & y_1 > 1, \\ 0, & \text{其它,} \end{cases}$$

例: 求 $Y_1 = X_1 X_2$ 的分布

设 X_1, X_2 独立 (independent), 且均匀分布 (uniform distribution) 在区间 $[0, 1]$ 。

联合概率密度函数 (joint probability density function, joint pdf) 为

$$f_{X_1 X_2}(x_1, x_2) = 1, \quad 0 \leq x_1 \leq 1, 0 \leq x_2 \leq 1,$$

否则为 0。

变量变换法 (Change of variables) :

令

$$Y_1 = X_1 X_2, \quad Y_2 = X_1.$$

则反变换为

$$X_1 = Y_2, \quad X_2 = \frac{Y_1}{Y_2}.$$

雅可比行列式 (Jacobian determinant)

$$J = \left| \frac{\partial(x_1, x_2)}{\partial(y_1, y_2)} \right| = \begin{vmatrix} \frac{\partial x_1}{\partial y_1} & \frac{\partial x_1}{\partial y_2} \\ \frac{\partial x_2}{\partial y_1} & \frac{\partial x_2}{\partial y_2} \end{vmatrix} = \begin{vmatrix} 0 & 1 \\ \frac{1}{y_2} & -\frac{y_1}{y_2^2} \end{vmatrix} = \frac{1}{|y_2|}.$$

由 $0 \leq X_1 \leq 1$ 与 $0 \leq X_2 \leq 1$ 得到支持域 (support) :

$$0 < Y_2 \leq 1, \quad 0 \leq Y_1 \leq Y_2.$$

于是联合密度

$$f_{Y_1, Y_2}(y_1, y_2) = f_{X_1, X_2}(y_2, \frac{y_1}{y_2}) |J| = \frac{1}{y_2}, \quad (0 < y_2 \leq 1, 0 \leq y_1 \leq y_2),$$

其他情形为 0。

对边缘化得到 Y_1 的 pdf

对 $y \in (0, 1]$,

$$f_{Y_1}(y) = \int_y^1 \frac{1}{y_2} dy_2 = -\ln y.$$

当 $y \leq 0$ 或 $y > 1$, 有 $f_{Y_1}(y) = 0$ 。

最终结果

$$f_{Y_1}(y) = \begin{cases} -\ln y, & 0 < y \leq 1, \\ 0, & \text{其它}. \end{cases}$$

对应的累积分布函数 (cumulative distribution function, cdf) 为

$$F_{Y_1}(y) = \begin{cases} 0, & y \leq 0, \\ y(1 - \ln y), & 0 < y \leq 1, \\ 1, & y > 1. \end{cases}$$

3.期望Expectation

- 期望 (Expectation)

对于随机变量 (random variables) $X_1, \dots, X_n$, 单变量随机变量

$$Y = g(X_1, \dots, X_n)$$

的期望 (expectation) 定义为:

离散情形 (Discrete case) :

$$E(Y) = \sum_y y p_Y(y) = \sum_{x_1=-\infty}^{\infty} \cdots \sum_{x_n=-\infty}^{\infty} g(x_1, \dots, x_n) p(x_1, \dots, x_n).$$

连续情形 (Continuous case) :

$$E(Y) = \int_{-\infty}^{\infty} y f_Y(y) dy = \int_{-\infty}^{\infty} \cdots \int_{-\infty}^{\infty} g(x_1, \dots, x_n) f(x_1, \dots, x_n) dx_1 \cdots dx_n.$$

应用 (Application) : 期望可以用于评估不确定结果的决策 (decision under uncertainty) 。

例: 购票 \$3, 掷两枚骰子, 如果结果为 (6, 6), 赢得 \$100, 否则赢得 \$0。

利用期望公式判断是否参与游戏:

$$P(\text{中}) = \frac{1}{36}, \quad E(\text{收益}) = 100 \cdot \frac{1}{36} + 0 \cdot \frac{35}{36} - 3 \approx -0.22.$$

由于期望收益为负, 不建议参与。

若: 票价 \$2

期望收益:

$$E(\text{收益}) = 100 \cdot \frac{1}{36} + 0 \cdot \frac{35}{36} - 2 = \frac{100}{36} - 2 = \frac{100 - 72}{36} = \frac{28}{36} \approx 0.7778.$$

此时期望为正, 建议参与。

• 随机变量的各种特征量 (Various Characteristic Measures) 及其性质 (Properties)

特征量:

1. 均值 (mean) :

若 $g(x) = x$, 则

$$E[g(X)] = E(X) = \mu_X$$

称为 X 的均值。

2. 方差 (variance) 与标准差 (standard deviation) :

若 $g(x) = (x - \mu_X)^2$, 则

$$E[g(X)] = E[(X - E(X))^2] = \text{Var}(X) = \sigma_X^2$$

其中 $\sigma_X = \sqrt{\text{Var}(X)}$ 称为标准差。

3. 协方差 (covariance) :

若 $g(x, y) = (x - \mu_X)(y - \mu_Y)$, 则

$$E[g(X, Y)] = E[(X - E(X))(Y - E(Y))] = \text{Cov}(X, Y) = \sigma_{XY}$$

4. 相关系数 (correlation coefficient) :

$$\rho_{XY} = \frac{\sigma_{XY}}{\sigma_X \sigma_Y}$$

若 $\rho_{XY} = 0$, 则称 X 与 Y 不相关 (uncorrelated)。

性质:

◦

$$\text{Var}(X) = E[(X - E(X))^2] = E(X^2) - \mu_X^2$$

◦

$$\text{Cov}(X, Y) = E(XY) - \mu_X \mu_Y$$

◦

$$\text{Var}(a + bX) = b^2 \text{Var}(X), \quad a, b \in \mathbb{R}, \quad \sigma_{a+bX} = |b| \sigma_X$$

◦

$$\text{Var}\left(a + \sum_{i=1}^n b_i X_i\right) = \sum_{i=1}^n b_i^2 \text{Var}(X_i) + 2 \sum_{1 \leq i < j \leq n} b_i b_j \text{Cov}(X_i, X_j)$$

◦

$$\text{Cov}\left(a + \sum_{i=1}^n b_i X_i, c + \sum_{j=1}^m d_j Y_j\right) = \sum_{i=1}^n \sum_{j=1}^m b_i d_j \text{Cov}(X_i, Y_j)$$

◦ 若 $X_1, \dots, X_n$ 两两不相关 (uncorrelated), 则

$$\text{Var}\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n \text{Var}(X_i)$$

◦ 均方误差 (mean square error, MSE) :

$$E[(X - \theta)^2] = \text{Var}(X) + (\mu_X - \theta)^2$$

• 矩生成函数 (moment generating function, mgf)

定义:

$$M_X(t) = E(e^{tX}), \quad t \in \mathbb{R}$$

若期望存在。

性质:

1. 对任意 t , mgf 可能存在也可能不存在。
2. 唯一性定理 (Uniqueness Theorem): 若 mgf 在包含零的某个开区间存在, 则唯一确定概率分布。
3. 若 mgf 在包含零的开区间内存在, 则

$$M_X^{(k)}(0) = E(X^k)$$

4. 对任意常数 a, b :

$$M_{a+bX}(t) = e^{at} M_X(bt)$$

5. 若 X, Y 独立:

$$M_{X+Y}(t) = M_X(t) M_Y(t)$$

- 联合矩生成函数 (Joint Moment Generating Function)

定义:

$$M_{X_1, \dots, X_n}(t_1, \dots, t_n) = E(e^{t_1 X_1 + \dots + t_n X_n})$$

性质:

1. 边际 mgf:

$$M_{X_1}(t_1) = M_{X_1, \dots, X_n}(t_1, 0, \dots, 0)$$

2. 唯一性定理同样适用。
3. 独立性判别:

$$M_{X_1, \dots, X_n}(t_1, \dots, t_n) = \prod_{i=1}^n M_{X_i}(t_i)$$

4. 高阶混合矩:

$$\frac{\partial^{r_1 + \dots + r_n}}{\partial t_1^{r_1} \dots \partial t_n^{r_n}} M_{X_1, \dots, X_n}(0, \dots, 0) = E(X_1^{r_1} \dots X_n^{r_n})$$

例:

投资组合 (Portfolio) 期望、方差与标准差

设两资产收益率 (returns) R_A, R_B 满足:

$$E(R_A) = \mu_A, \quad Var(R_A) = \sigma_A^2, \quad E(R_B) = \mu_B, \quad Var(R_B) = \sigma_B^2,$$

$$Cov(R_A, R_B) = \sigma_{AB} \text{ (协方差, covariance).}$$

令权重 (weights) x_A, x_B 且 $x_A + x_B = 1$, 组合收益

$$R_P = x_A R_A + x_B R_B.$$

期望 (Expectation)

$$E(R_P) = x_A \mu_A + x_B \mu_B.$$

方差 (Variance)

$$\text{Var}(R_P) = x_A^2 \sigma_A^2 + x_B^2 \sigma_B^2 + 2x_A x_B \sigma_{AB}.$$

标准差 (Standard deviation)

$$\sigma_P = \sqrt{\text{Var}(R_P)}$$

若用相关系数 (correlation coefficient) $\rho_{AB} = \sigma_{AB}/(\sigma_A \sigma_B)$ 表示,

$$\text{Var}(R_P) = x_A^2 \sigma_A^2 + x_B^2 \sigma_B^2 + 2x_A x_B \rho_{AB} \sigma_A \sigma_B.$$

4. 条件期望 Conditional Expectation

- 离散型 (Discrete case)

$$E(h(Y) | X = x) = \sum_y h(y) p_{Y|X}(y | x)$$

特别地:

$$E(Y | X = x) = \sum_y y p_{Y|X}(y | x)$$

- 连续型 (Continuous case)

$$E(h(Y) | X = x) = \int h(y) f_{Y|X}(y | x) dy$$

特别地:

$$E(Y | X = x) = \int y f_{Y|X}(y | x) dy$$

- 备注:

- 对于联合概率密度 $f(x, y)$, 如果固定 $x = x^*$, $f(x^*, y)$ 是否是 y 的概率密度函数?
不是 (一般情况下)。

$$\int_{-\infty}^{\infty} f(x^*, y) dy = f_X(x^*) \neq 1,$$

除非出现退化/特殊情形使得 $f_X(x^*) = 1$; 因此它未归一化 (not normalized)。

- 条件概率密度

$$f_{Y|X}(y | x^*) = \frac{f(x^*, y)}{f_X(x^*)}$$

是否是 y 的概率密度函数? 为什么?

是。因为

$$\int_{-\infty}^{\infty} f_{Y|X}(y | x^*) dy = \frac{1}{f_X(x^*)} \int_{-\infty}^{\infty} f(x^*, y) dy = \frac{f_X(x^*)}{f_X(x^*)} = 1,$$

且 $f_{Y|X}(y | x^*) \geq 0$, 故满足 pdf 的两条公理 (axioms)。

例: 设 X 表示年龄 (age, in years), Y 表示身高 (height, in cm)。

- $Y|X = x$ 是一个随机变量 (random variable)。
- $E(Y|X = x)$ 不是随机变量。
- 条件方差 (conditional variance) $\text{Var}(Y|X = x)$ 和 $\text{Var}(Y|X)$ 可以类似定义。
- $E(Y)$ 是常数, 不是随机变量。

- $Var(Y)$ 也是常数, 不是随机变量。
- 条件期望性质 (Properties of conditional expectation)

1. $E_{Y|X}(h(Y)|x)$ 是 x 的函数, 与 Y 无关。
2. 若 X 与 Y 独立 (independent), 则

$$E_{Y|X}(h(Y)|x) = E_Y(h(Y)).$$

3. 对任意函数 h ,

$$E(h(X)|X=x) = h(x)$$

4. 若 $g(x) = E_{Y|X}(h(Y)|x)$, 则 $g(X)$ 是一个随机变量, 并记作

$$E_{Y|X}(h(Y)|X)$$

5. 全期望公式 (Law of total expectation) :

$$E_X[E_{Y|X}(h(Y)|X)] = E_Y[h(Y)]$$

特别地:

$$E_X[E_{Y|X}(Y|X)] = E_Y(Y).$$

6. 方差分解公式 (Variance decomposition)

$$Var_Y(Y) = Var_X(E_{Y|X}(Y|X)) + E_X(Var_{Y|X}(Y|X))$$

- 应用:

- 线性回归 (Linear Regression)

目标: 利用随机变量 X 对随机变量 Y 进行最佳预测。

最小化平方误差:

$$\min_{a,b} E(Y - a - bX)^2$$

最优预测公式:

$$E_{Y|X}(Y|X) = \mu_Y + \rho \frac{\sigma_Y}{\sigma_X} (X - \mu_X)$$

当 (X, Y) 服从二维正态分布时, 上式成立。

只需知道均值、方差和协方差即可进行计算。

预测误差为:

$$\sigma_Y^2(1 - \rho^2)$$

当 ρ 接近 ± 1 时, 该误差很小。

- δ 方法 (Delta Method) :

已知 X 的均值 μ_X 和方差 σ_X^2 , 但未知其完整分布。

问题:

1. 能否推出 $Y = g(X)$ 的分布?
2. 能否粗略描述 Y 的均值和方差?

一阶近似 (泰勒展开) :

$$Y = g(X) \approx g(\mu_X) + (X - \mu_X)g'(\mu_X)$$

$$E[g(X)] \approx g(\mu_X)$$

$$\text{Var}[g(X)] \approx \text{Var}(X)[g'(\mu_X)]^2$$

二阶近似：

$$Y \approx g(\mu_X) + (X - \mu_X)g'(\mu_X) + \frac{1}{2}(X - \mu_X)^2 g''(\mu_X)$$

近似精度取决于 g 是否能在 μ_X 附近用低阶多项式很好地近似。