

第一讲 线性方程组与向量空间

第一讲 线性方程组与向量空间

1.线性方程组

2.矩阵

(1) 矩阵的运算

3.线性方程组解的情况

4.线性方程组的解法 (Gauss-Jordan elimination)

5.矩阵求逆和行列式求解

(1) 矩阵求逆

(2) 行列式求解

(3) 分块矩阵

6.向量空间

1.线性方程组

- 假设我们有以下的一个方程组:

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1m}x_m = b_1 \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2m}x_m = b_2 \\ \vdots \\ a_{n1}x_1 + a_{n2}x_2 + \cdots + a_{nm}x_m = b_n \end{cases}$$

那么我们可以将其写为矩阵形式: $\mathbf{Ax} = \mathbf{b}$, 其中 $\mathbf{A}$, $\mathbf{x}$, $\mathbf{b}$ 分别代表着:

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1m} \\ a_{21} & a_{22} & \cdots & a_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nm} \end{bmatrix}, \quad \mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_m \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{bmatrix}$$

2.矩阵

- 单位矩阵: 我们将对角线元素全部为1, 其余元素为0的矩阵成为对角线矩阵 (identity matrix)。
- 行向量与列向量: $[a_{11}, a_{12}, \dots, a_{1m}]$ 被称为行向量, $[a_{11}, a_{12}, \dots, a_{1m}]^T$ 被称为列向量。我们默认称向量为列向量。

(1) 矩阵的运算

- 转置Transpose: 若矩阵 $\mathbf{A} = [a_{ij}]_{N \times M}$, 那么其转置后的矩阵为:

$$\mathbf{A}^T = [a_{ji}]_{M \times N} = \begin{bmatrix} a_{11} & a_{21} & \cdots & a_{n1} \\ a_{12} & a_{22} & \cdots & a_{n2} \\ \vdots & \vdots & \ddots & \vdots \\ a_{1m} & a_{2m} & \cdots & a_{nm} \end{bmatrix}$$

即交换原有矩阵的行列。

矩阵 $\mathbf{A}$ 是一个 $n \times n$ 维的方阵, 如果 $\mathbf{A} = \mathbf{A}^T$, 那么 $\mathbf{A}$ 被称为对称矩阵。

- 迹Trace: 如果矩阵 $\mathbf{A} = [a_{ij}]_{n \times n}$ 是一个方阵, 那么矩阵 $\mathbf{A}$ 的迹就是

$$tr(A) = \sum_{i=1}^N a_{ii}$$

主对角线元素的和。

- 矩阵加减Matrix Addition and Subtraction:

设矩阵 $A = [a_{ij}]_{N \times M}$, $B = [b_{ij}]_{N \times M}$, 即 A 与 B 维度相同, 则:

$$A + B = [a_{ij} + b_{ij}]_{N \times M}, \quad A - B = [a_{ij} - b_{ij}]_{N \times M}$$

- 矩阵的乘法Matrix Multiplication:

设 $A = [a_{ij}]_{N \times M}$, $B = [b_{ij}]_{M \times K}$, 且 p, q 为正整数:

- 数乘: 若 α 为一个标量, 则

$$\alpha A = [\alpha a_{ij}]_{N \times M}$$

- 矩阵的乘法: 仅当 A 的列数等于 B 的行数, 即 M 相等时定义。乘积 $C = AB$ 是一个 $N \times K$ 矩阵, 其中第 i 行第 j 列元素为:

$$(AB)_{ij} = \sum_{m=1}^M a_{im} b_{mj}$$

因此:

$$AB = \left[\sum_{m=1}^M a_{im} b_{mj} \right]_{N \times K}$$

- 矩阵的幂 (Powers of a matrix): 若 A 是一个 $n \times n$ 的方阵, 则

$$A^p = \underbrace{A \cdot A \cdots A}_{p \text{ times}}, \quad A^p A^q = A^{p+q}, \quad (A^p)^q = A^{pq}$$

注意: 矩阵乘法和实数乘法两个不同的地方

1. 交换律并不适用于矩阵相乘 $\mathbf{AB} \neq \mathbf{BA}$
2. 如果 $\mathbf{AB} = 0$, 并不能推出 $\mathbf{A} = 0$ 或者 $\mathbf{B} = 0$, 反之亦然。

- 矩阵运算的性质:

1. $(A + B)^T = A^T + B^T$
2. $(AB)^T = B^T A^T$
3. $tr(A + B) = tr(A) + tr(B)$
4. $tr(AB) = tr(BA)$
5. 加法交换律: $A + B = B + A$
6. 加法分配律: $A + (B + C) = (A + B) + C$
7. 乘法分配律: $(AB)C = A(BC)$
8. 左乘分配律: $A(B + C) = AB + AC$
9. 右乘分配律: $(A + B)C = AC + BC$
10. 如果 $A, B \in R^{n \times n}$, 如果 $AB = I$, 那么 $BA = I$

3.线性方程组解的情况

- 线性方程组的一些定义：
 - 如果线性方程组至少有一个解，那么称之为一致的 (consistent)
 - 如果线性方程组无解，那么称之为不一致的 (inconsistent)
 - 如果方程数多于未知数，那么称之为超定方程组 (overdetermined)
 - 如果方程数少于未知数，那么称之为欠定方程组 (underdetermined)
 - 方程数与未知数数量相等，那么称之为正定方程组 (exactly determined)。
- 以下为超定线性方程组求解：课程中没有特别提到，但是有提到，故需注意。
 - 定义：所谓超定线性方程组表示：方程个数大于未知数个数的方程组。
 - 问题背景：给定一个点集合，要求对该集合进行曲线拟合，但一般情况下，很难保证拟合到的结果曲线可以同时经过集合的所有点。也就是说，给定的条件（即该点集合）过于严格，导致解析解（即保证所有点都经过的曲线）不存在。对于这种无法完全满足给定条件的情况下，通常使用最小二乘法求解一个最接近的解。

线性回归的因变量是自变量的线性组合，其定义式可以表示为：

$$h(x_1, x_2, \dots, x_n) = \theta_0 + \theta_1 x_1 + \dots + \theta_{n-1} x_{n-1}$$

其中， θ 为参数， $x_i (i = 0, 1, \dots, n-1)$ 为自变量， h 为因变量。

假设有 m 个观测样本（即方程个数），每个样本有 n 维特征（即未知量个数），将所有观测样本带入线性回归方程则有：

$$\begin{cases} y_1 = \theta_0 + \theta_1 x_{1,1} + \theta_2 x_{1,2} + \dots + \theta_{n-1} x_{1,n-1} \\ y_2 = \theta_0 + \theta_1 x_{2,1} + \theta_2 x_{2,2} + \dots + \theta_{n-1} x_{2,n-1} \\ \dots \\ y_m = \theta_0 + \theta_1 x_{m,1} + \theta_2 x_{m,2} + \dots + \theta_{n-1} x_{m,n-1} \end{cases}$$

若 $m > n$ ，则上述线性回归方程就是超定线性方程组，该方程组没有精确解，只能求解其最小二乘解。对该线性回归问题进行建模，可用矩阵表示为：

$$\mathbf{H} = \mathbf{X}\boldsymbol{\theta}$$

其中， $\mathbf{X}$ 为自变量构成的矩阵，它是 $m \times n$ 的矩阵； $\boldsymbol{\theta}$ 为要求解的模型参数，它是 $n \times 1$ 的列向量； $\mathbf{H}$ 为给定自变量矩阵后的理论估计向量，它是 $m \times 1$ 的列向量。假设 $\mathbf{Y}$ 为观测向量，它也是 $m \times 1$ 的列向量，由于 $\mathbf{X}$ 和 $\mathbf{Y}$ 都是已知的，未知的模型参数是 $\boldsymbol{\theta}$ ，则目标函数的矩阵形式可以表示为：

$$J(\boldsymbol{\theta}) = \|\mathbf{H} - \mathbf{Y}\|^2 = \|\mathbf{X}\boldsymbol{\theta} - \mathbf{Y}\|^2 = (\mathbf{X}\boldsymbol{\theta} - \mathbf{Y})^T (\mathbf{X}\boldsymbol{\theta} - \mathbf{Y})$$

该目标函数取得最小值就是导数为 0 的地方，即：

$$\boldsymbol{\theta} = \arg \min_{\boldsymbol{\theta}} \frac{\partial J(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}}$$

可以得到：

$$\frac{\partial J(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}} = 2\mathbf{X}^T \mathbf{X}\boldsymbol{\theta} - 2\mathbf{X}^T \mathbf{Y} = 0$$

即：

$$\mathbf{X}^T \mathbf{X}\boldsymbol{\theta} = \mathbf{X}^T \mathbf{Y}$$

若 $X^T X$ 可逆, 则 θ 的最小二乘解为:

$$\theta = (X^T X)^{-1} X^T Y$$

- 课件内容: 假设 $AX = b$ 是一个超定线性方程组, 那么在原方程两边同时左乘 A^T , 得到正规方程:

$$A^T AX = A^T b$$

求解这个新的方程组 (这是 $n \times n$ 的方阵), 最后得到的 X 是使得 $\|Ax - b\|_2$ 的最小二乘解。

例: 解方程组

$$\begin{cases} x + y = 2 \\ x + 2y = 3 \\ x + 3y = 6 \end{cases}$$

写成矩阵形式:

$$A = \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{bmatrix}, \quad X = \begin{bmatrix} x \\ y \end{bmatrix}, \quad b = \begin{bmatrix} 2 \\ 3 \\ 6 \end{bmatrix}$$

构造正规方程:

$$A^T A = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 2 & 3 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & 2 \\ 1 & 3 \end{bmatrix} = \begin{bmatrix} 3 & 6 \\ 6 & 14 \end{bmatrix}$$

$$A^T b = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 2 & 3 \end{bmatrix} \begin{bmatrix} 2 \\ 3 \\ 6 \end{bmatrix} = \begin{bmatrix} 11 \\ 25 \end{bmatrix}$$

所以正规方程为:

$$\begin{bmatrix} 3 & 6 \\ 6 & 14 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 11 \\ 25 \end{bmatrix}$$

解正规方程:

$$\begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 3 & 6 \\ 6 & 14 \end{bmatrix}^{-1} \begin{bmatrix} 11 \\ 25 \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

故最小二乘解为: $x = 1, y = 1$

- 先修课课件内容: 有些时候我们使用上述方法会发现 $A^T A$ 是不是满秩的, 导致求解不稳定或解不唯一。此时, 图中建议**加上正则项** λI , 引入正则化后的正规方程为:

$$(A^T A + \lambda I) X = A^T b \quad (\lambda > 0)$$

例: 解方程组:

$$\begin{cases} x + y = 9 \\ x + y = 10 \\ x + y = 11 \end{cases}$$

写成矩阵形式:

$$A = \begin{bmatrix} 1 & 1 \\ 1 & 1 \\ 1 & 1 \end{bmatrix}, \quad X = \begin{bmatrix} x \\ y \end{bmatrix}, \quad b = \begin{bmatrix} 9 \\ 10 \\ 11 \end{bmatrix}$$

用正则化正规方程求解最小二乘解：

$$A^T A = \begin{bmatrix} 3 & 3 \\ 3 & 3 \end{bmatrix}, \quad \lambda I = \begin{bmatrix} \lambda & 0 \\ 0 & \lambda \end{bmatrix} \Rightarrow A^T A + \lambda I = \begin{bmatrix} 3 + \lambda & 3 \\ 3 & 3 + \lambda \end{bmatrix}$$

$$A^T b = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix} \begin{bmatrix} 9 \\ 10 \\ 11 \end{bmatrix} = \begin{bmatrix} 30 \\ 30 \end{bmatrix}$$

所以正则化正规方程为：

$$\begin{bmatrix} 3 + \lambda & 3 \\ 3 & 3 + \lambda \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 30 \\ 30 \end{bmatrix}$$

$$\text{求解有: } X = (A^T A + \lambda I)^{-1} A^T b$$

$$\begin{bmatrix} x \\ y \end{bmatrix} = \frac{1}{\lambda + 6} \begin{bmatrix} 30 \\ 30 \end{bmatrix}$$

• 一个有 n 个等式, m 个未知数的线性方程组, $Ax = b$ 可能有 3 种解的情况:

1. 若 $R(A) = r < R(A, b) = r + 1$, 这说明 $d_{r+1} \neq 0$, 最后一个方程无解 $0 = d_{r+1}$.

2. 若 $R(A) = R(A, b) = n$

我们可以继续化简矩阵:

$$R(A, b) = \left[\begin{array}{cccc|c} a_{11} & a_{12} & \dots & a_{1n} & b_1 \\ a_{21} & a_{22} & \dots & a_{2n} & b_2 \\ \dots & \dots & \dots & \dots & \dots \\ a_{m1} & a_{m2} & \dots & a_{mn} & b_n \end{array} \right] = \left[\begin{array}{cccc|c} 1 & 0 & \dots & 0 & d_1 \\ 0 & 1 & \dots & 0 & d_2 \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & \dots & 1 & d_n \\ 0 & 0 & \dots & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & \dots & 0 & 0 \end{array} \right]$$

此时 $r = n, d_{r+1} = 0$, 方程组变为:

$$\begin{cases} x_1 = d_1 \\ x_2 = d_2 \\ \dots \\ x_n = d_n \end{cases}$$

有唯一解

3. 若 $R(A) = R(A, b) < n$, 则 $d_{r+1} = 0$, 有

$$\begin{cases} x_1 + b_{11}x_{r+1} + \dots + b_{1,r-n}x_n = d_1 \\ x_2 + b_{21}x_{r+1} + \dots + b_{2,r-n}x_n = d_2 \\ \dots \\ x_r + b_{r1}x_{r+1} + \dots + b_{r,r-n}x_n = d_r \end{cases}$$

因为方程的数量比未知数多所以方程组有无穷多个解。此时我们需要选择自由变量来表示方程的解。自由变量的数量等于未知数的数量减去增广矩阵的秩, 即 $n - R(A, b)$ 。

4.线性方程组的解法 (Gauss-Jordan elimination)

- 此消元法主要包含矩阵的初等行变换:
 - 以一个非零的数乘矩阵的某一行
 - 把矩阵的某一行的 c 倍加到另一行
 - 互换矩阵中两行的位置
- 高斯消元法Gaussian elimination和高斯-若尔当消元法Gauss-Jordan elimination的比较:
 - 高斯消元法Gaussian elimination:
 - 初等行变换
 - 化简为阶梯形矩阵row echelon method
 - 回代求解
 - 高斯-若尔当消元法Gauss-Jordan elimination:
 - 初等行变换
 - 化为最简型阶梯矩阵reduced row echelon form

- 一个矩阵称为**阶梯形 (或行阶梯形) 矩阵**row echelon method, 若它有以下三个性质:

1. 每一非零行都在每一零行之上。
2. 某一行的先导元素所在的列位于前一先导元素的右边。
3. 某一先导元素所在列下方元素都是零。

若一个阶梯形矩阵还满足一下性质, 则称它为**简化阶梯形 (或简化行阶梯形) 矩阵**reduced row echelon form.

1. 每一非零行的先导元素是1.
2. 每一先导元素1是该元素所在列的唯一非零元素。

- 矩阵秩Rank的定义:

设 A 是以一个 n 维向量组 (可以包含无限多个向量), 如果从 A 中取出 r 个向量满足条件:

1. $\alpha_1, \alpha_2, \dots, \alpha_r$ 线性无关
2. 对于 A 中的任意向量 β , 向量组 $\alpha_1, \alpha_2, \dots, \alpha_r, \beta$ 线性相关

那么我们称向量组 $\alpha_1, \alpha_2, \dots, \alpha_r$ 是 A 的一个极大线性无关组。

那么矩阵的秩我们可以定义为: 将矩阵按列分解为 n 个向量, 组成一个向量组。则该向量组的一个**极大线性无关组**中包含向量的个数 r 称为矩阵的行秩。同理可定义列秩, 可证列秩=行秩。

秩的另一个定义方法: 对于 $m \times n$ 的矩阵, 任取 k 行和 k 列 ($k \leq \min(m, n)$), 不改变它们在矩阵中的位置次序, 构成的 k 阶行列式, 称为矩阵的 k 阶子式。在矩阵中有一个非零的 r 阶子式, 且所有 $r+1$ 阶子式的值均为零。则的值称为**矩阵的秩**。

由定义可知秩的重要性质: 矩阵 A 的秩 $0 \leq R(A) \leq \min(m, n), R(A^T) = R(A)$

同时因为初等行变换不会改变行空间所以也不会改变矩阵的行秩, 并且每个矩阵都有一个唯一的对应的最简阶梯形矩阵, 所以 $R(A)$ = 该矩阵对应的最简阶梯形矩阵种非零行的数量。

- 用消元法解线性方程组的步骤:

高斯消元法Gaussian elimination:

1. 我们将等号右边的一系列元素写在系数矩阵的右侧, 该矩阵被称为增广矩阵, 增广矩阵如下:

$$R(A, b) = \left[\begin{array}{cccc|c} a_{11} & a_{12} & \dots & a_{1n} & b_1 \\ a_{21} & a_{22} & \dots & a_{2n} & b_2 \\ \dots & \dots & \dots & \dots & \dots \\ a_{m1} & a_{m2} & \dots & a_{mn} & b_n \end{array} \right]$$

2. 化简为阶梯型矩阵

$$\left[\begin{array}{cccc|c} 1 & 0 & \dots & 0 & b_{11} & \dots & b_{1,n-r} & d_1 \\ 0 & 1 & \dots & 0 & b_{21} & \dots & b_{2,n-r} & d_2 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & \dots & 1 & b_{r1} & \dots & b_{r,n-r} & d_r \\ 0 & 0 & \dots & 0 & 0 & \dots & 0 & d_{r+1} \\ 0 & 0 & \dots & 0 & 0 & \dots & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & \dots & 0 & 0 & \dots & 0 & 0 \end{array} \right] = B'$$

3. 回代求解

高斯-若尔当消元法 Gauss-Jordan elimination:

1. 我们将等号右边的一列元素写在系数矩阵的右侧，该矩阵被称为增广矩阵，增广矩阵如下：

$$R(A, b) = \left[\begin{array}{cccc|c} a_{11} & a_{12} & \dots & a_{1n} & b_1 \\ a_{21} & a_{22} & \dots & a_{2n} & b_2 \\ \dots & \dots & \dots & \dots & \dots \\ a_{m1} & a_{m2} & \dots & a_{mn} & b_n \end{array} \right]$$

2. 化简为最简阶梯型矩阵

$$\left[\begin{array}{cccc|c} 1 & 0 & \dots & 0 & 0 & \dots & 0 & d_1 \\ 0 & 1 & \dots & 0 & 0 & \dots & 0 & d_2 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & \dots & 1 & 0 & \dots & 0 & d_r \\ 0 & 0 & \dots & 0 & 0 & \dots & 0 & d_{r+1} \\ 0 & 0 & \dots & 0 & 0 & \dots & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 0 & 0 & \dots & 0 & 0 & \dots & 0 & 0 \end{array} \right] = B'$$

3. 直接得到解：对于每个非零行，求解与该行中首元相关联的未知数对应的方程。

5. 矩阵求逆和行列式求解

(1) 矩阵求逆

- 逆矩阵的定义：如果矩阵 A 是一个 $n \times n$ 维矩阵，并且矩阵 A^{-1} 满足以下条件

$$AA^{-1} = A^{-1}A = I$$

那么我们称矩阵 A^{-1} 为矩阵 A 的逆矩阵。

- 判断逆矩阵存在的条件：若矩阵是一个非奇异矩阵，即该矩阵的行列式不为 0，即 $\det(A) \neq 0$ 。等价于矩阵 A 的秩为 N 即该方阵的维度。
- 矩阵求逆的两种方法：

1. 在原有矩阵的基础上写出增广矩阵，及在原有矩阵的右边加上一个单位矩阵，然后对增广矩阵进行初等行变换，使得左侧的原有矩阵变为单位矩阵，此时右侧矩阵为原有矩阵的逆矩阵。

$$A^{-1}[A|E] = [A^{-1}A|A^{-1}E] = [E|A^{-1}]$$

2. 用伴随矩阵求逆矩阵。

假设有一个矩阵 A

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{bmatrix}$$

那么 n 阶方阵 A 的伴随矩阵 A^* 为：

$$A^* = \begin{bmatrix} A_{11} & A_{21} & \cdots & A_{n1} \\ A_{12} & A_{22} & \cdots & A_{n2} \\ \vdots & \vdots & \ddots & \vdots \\ A_{1n} & A_{2n} & \cdots & A_{nn} \end{bmatrix}$$

其中 $A_{11}, A_{12}, \dots$ 被称为代数余子式， $A_{ij} = (-1)^{i+j} M_{ij}$ 。其中， M_{ij} 为 a_{ij} 的余子式， a_{ij} 表示矩阵 A 中第 i 行第 j 列的元素， M_{ij} 的值等于将 A 的第 i 行和第 j 列去掉后，剩余项组成的行列式的值。如：

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 2 & 4 & 1 \\ 0 & -1 & 2 \end{bmatrix}$$

a_{12} 的余子式 M_{12} 为：

$$\begin{vmatrix} 2 & 1 \\ 0 & 2 \end{vmatrix} = 4$$

a_{12} 的代数余子式 A_{12} 为：

$$(-1)^{1+2} M_{12} = -4$$

那么我们可以得到： $A^{-1} = \frac{1}{|A|} A^*$

举例如下：

$$A = \begin{bmatrix} 1 & 0 & 0 \\ 2 & -1 & 0 \\ 2 & 1 & 1 \end{bmatrix}$$

$$|A| = \begin{vmatrix} 1 & 0 & 0 \\ 2 & -1 & 0 \\ 2 & 1 & 1 \end{vmatrix} = \begin{vmatrix} -1 & 0 \\ 1 & 1 \end{vmatrix} = -1$$

$$A_{11} = -1 \quad A_{21} = 0 \quad A_{31} = 0$$

$$A_{12} = -2 \quad A_{22} = 1 \quad A_{32} = 0$$

$$A_{13} = 4 \quad A_{23} = -1 \quad A_{33} = -1$$

$$A^* = \begin{bmatrix} -1 & 0 & 0 \\ -2 & 1 & 0 \\ 4 & -1 & -1 \end{bmatrix}$$

$$\therefore A^{-1} = \frac{1}{|A|} A^* = \begin{bmatrix} 1 & 0 & 0 \\ 2 & -1 & 0 \\ -4 & 1 & 1 \end{bmatrix}$$

定理：若有一个二阶非奇异矩阵

$$A = \begin{bmatrix} a & b \\ c & d \end{bmatrix}$$

那么

$$A^{-1} = \frac{1}{ad-bc} \begin{bmatrix} d & -b \\ -c & a \end{bmatrix} = \frac{1}{\det(A)} \begin{bmatrix} d & -b \\ -c & a \end{bmatrix}$$

• 逆矩阵的性质：

$$\circ (A^{-1})^T = (A^T)^{-1}$$

$$\circ (AB)^{-1} = B^{-1}A^{-1}$$

• Woodbury 恒等式：设 $A \in \mathbb{R}^{n \times n}$ 为可逆矩阵， $U \in \mathbb{R}^{n \times k}$ ， $V \in \mathbb{R}^{k \times n}$ ， $C \in \mathbb{R}^{k \times k}$ 也是可逆的，则有：

$$(A + UCV)^{-1} = A^{-1} - A^{-1}U(C^{-1} + VA^{-1}U)^{-1}VA^{-1}$$

证明（不要求掌握）：

$$\text{记：} M = A + UCV, \quad X = A^{-1} - A^{-1}U(C^{-1} + VA^{-1}U)^{-1}VA^{-1}$$

我们将证明 $MX = I$ 。展开乘积：

$$\begin{aligned} MX &= (A + UCV)(A^{-1} - A^{-1}U(C^{-1} + VA^{-1}U)^{-1}VA^{-1}) \\ &= AA^{-1} - AA^{-1}U(C^{-1} + VA^{-1}U)^{-1}VA^{-1} \\ &\quad + UCVA^{-1} - UCVA^{-1}U(C^{-1} + VA^{-1}U)^{-1}VA^{-1} \end{aligned}$$

简化各项：得到

$$= I - U(C^{-1} + VA^{-1}U)^{-1}VA^{-1} + UC(VA^{-1}) - UCVA^{-1}U(C^{-1} + VA^{-1}U)^{-1}VA^{-1}$$

提取公共因子：

$$MX = I + U[CVA^{-1} - (C^{-1} + VA^{-1}U)^{-1}VA^{-1} - CVA^{-1}U(C^{-1} + VA^{-1}U)^{-1}]VA^{-1}$$

我们可以验证括号中的部分等于零，从而有：

$$MX = I \Rightarrow X = M^{-1}$$

得证。

Sherman-Morrison 公式: 当 $C = 1$, $U = u \in \mathbb{R}^{n \times 1}$, $V = v^T \in \mathbb{R}^{1 \times n}$ 时, Woodbury 恒等式退化为:

$$(A + uv^T)^{-1} = A^{-1} - \frac{A^{-1}uv^TA^{-1}}{1 + v^TA^{-1}u}$$

(2) 行列式求解

- 克莱姆法则 (Cramer's Rule): 没有一个 $n \times n$ 的线性方程组:

$$AX = b$$

其中:

- A 是一个 $n \times n$ 的可逆矩阵 (即 $\det(A) \neq 0$);
- $X = [x_1, x_2, \dots, x_n]^T$ 是未知量向量;
- $b = [b_1, b_2, \dots, b_n]^T$ 是常数向量。

则该方程组有唯一解, 且第 (i) 个未知数的解为:

$$x_i = \frac{\det(A_i)}{\det(A)}$$

其中 (A_i) 表示用向量 (b) 替换矩阵 (A) 的第 (i) 列所得到的新矩阵。

- 行列式计算:
 - 二阶或者三阶行列式可以直接求解:

$$A = \begin{vmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{vmatrix}, \det(A) = a_{11}a_{22} - a_{21}a_{12}$$

$$B = \begin{vmatrix} b_{11} & b_{12} & b_{13} \\ b_{21} & b_{22} & b_{23} \\ b_{31} & b_{32} & b_{33} \end{vmatrix},$$

$$\det(B) = b_{11}b_{22}b_{33} + b_{21}b_{32}b_{13} + b_{12}b_{23}b_{31} - b_{31}b_{22}b_{13} - b_{12}b_{21}b_{33} - b_{11}b_{23}b_{32}$$

- 求解行列式的方法:
 - 拉普拉斯展开 (Laplace Expansion): 对于任何大小的方阵都可以使用此方法。
 - 三角化: 如果能够通过初等变换把一个矩阵转换为上三角形或下三角形形式, 则其行列式等于主对角线上元素的乘积。
 - 高斯消元法: 类似地, 可以通过一系列的操作使矩阵变为阶梯型矩阵, 在这个过程中保持行列式的不变性质 (例如交换两行改变符号), 最终得到简化后的行列式值。
 - 特征多项式: 特征多项式的根即为矩阵的特征值, 而对于非奇异矩阵而言, 行列式就是所有特征值之积。
- 拉普拉斯展开 (Laplace Expansion):

假设 D 是一个 n 阶行列式

$$D = \begin{vmatrix} a_{11} & a_{12} & \cdots & a_{1j} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2j} & \cdots & a_{2n} \\ \cdots & \cdots & \cdots & \cdots & \cdots & \cdots \\ a_{i1} & a_{i2} & \cdots & a_{ij} & \cdots & a_{in} \\ \cdots & \cdots & \cdots & \cdots & \cdots & \cdots \\ a_{n1} & a_{n2} & \cdots & a_{nj} & \cdots & a_{nn} \end{vmatrix}$$

此时我们定义： M_{ij} 是 D 去掉第 i 行 j 列后剩余的项组成的 $n - 1$ 阶行列式，称为 a_{ij} 的余子式。
 $A_{ij} = (-1)^{i+j} M_{ij}$ 称为 a_{ij} 的代数余子式。

定理：

通过拉普拉斯展开计算行列式的公式如下：

$$D = a_{i1}A_{i1} + a_{i2}A_{i2} \cdots + a_{ij}A_{ij} \cdots + a_{in}A_{in}$$

$$D = a_{1j}A_{1j} + a_{2j}A_{2j} \cdots + a_{ij}A_{ij} \cdots + a_{nj}A_{nj}$$

◦ 范德蒙德行列式（不要求掌握）：

定义：形式如下的行列式

$$D = \begin{vmatrix} 1 & 1 & 1 & \cdots & 1 \\ x_1 & x_2 & x_3 & \cdots & x_n \\ x_1^2 & x_2^2 & x_3^2 & \cdots & x_n^2 \\ \cdots & \cdots & \cdots & \cdots & \cdots \\ x_1^{n-2} & x_2^{n-2} & \cdots & \cdots & x_n^{n-2} \\ x_1^{n-1} & x_2^{n-1} & \cdots & \cdots & x_n^{n-1} \end{vmatrix}$$

可以直接计算行列式的值：

$$\prod_{n \geq i > j \geq 1} (x_i - x_j)$$

对应性质：某两行（列）成比例，行列式值为零。

• 行列式的性质

1. 如果 A 是一个上三角或下三角矩阵，则有：

$$\det(A) = a_{11}a_{22} \cdots a_{nn}$$

2. 行列式为零的条件，当满足以下任意一个条件时， $\det(A) = 0$ ：

- 某一行或某一列全为 0；
- 有两行或两列完全相同；
- 有两行或两列成比例。

3. 如果将矩阵 A 的两行或两列交换得到矩阵 A' ，则：

$$\det(A') = -\det(A)$$

4. 如果将矩阵 A 的某一行（或某一列）所有元素乘以常数 k 得到矩阵 A' ，则：

$$\det(A') = k \cdot \det(A)$$

5. 如果将矩阵 A 的第 j 行乘以常数 k 后加到第 i 行，得到矩阵 A' ，则：

$$\det(A') = \det(A)$$

6. 转置不改变行列式：

$$\det(A^\top) = \det(A)$$

7. 如果矩阵 A 可逆 (即 $\det(A) \neq 0$) , 则:

$$\det(A^{-1}) = \frac{1}{\det(A)}$$

8. 乘积的行列式:

$$\det(AB) = \det(A) \cdot \det(B)$$

一般情况下,

$$\det(A + B) \neq \det(A) + \det(B)$$

9. 多个矩阵乘积的行列式, 对于 $A_1, A_2, \dots, A_n$:

$$\det(A_1 A_2 \cdots A_n) = \det(A_1) \cdot \det(A_2) \cdots \det(A_n)$$

(3) 分块矩阵

• 设 A, B, C, D 是维度匹配的矩阵, 分块矩阵的常见运算包括:

◦ 转置:

$$\begin{bmatrix} A & B \\ C & D \end{bmatrix}^\top = \begin{bmatrix} A^\top & C^\top \\ B^\top & D^\top \end{bmatrix}$$

◦ 迹:

$$\text{tr} \left(\begin{bmatrix} A & B \\ C & D \end{bmatrix} \right) = \text{tr}(A) + \text{tr}(D)$$

◦ 加法与减法:

$$\begin{bmatrix} A_1 & B_1 \\ C_1 & D_1 \end{bmatrix} \pm \begin{bmatrix} A_2 & B_2 \\ C_2 & D_2 \end{bmatrix} = \begin{bmatrix} A_1 \pm A_2 & B_1 \pm B_2 \\ C_1 \pm C_2 & D_1 \pm D_2 \end{bmatrix}$$

◦ 标量乘法:

$$\alpha \begin{bmatrix} A & B \\ C & D \end{bmatrix} = \begin{bmatrix} \alpha A & \alpha B \\ \alpha C & \alpha D \end{bmatrix}$$

◦ 矩阵乘法:

$$\begin{bmatrix} A_1 & B_1 \\ C_1 & D_1 \end{bmatrix} \begin{bmatrix} A_2 & B_2 \\ C_2 & D_2 \end{bmatrix} = \begin{bmatrix} A_1 A_2 + B_1 C_2 & A_1 B_2 + B_1 D_2 \\ C_1 A_2 + D_1 C_2 & C_1 B_2 + D_1 D_2 \end{bmatrix}$$

◦ 逆矩阵 (若 A 和 D 可逆):

$$\begin{bmatrix} A & B \\ C & D \end{bmatrix}^{-1} = \begin{bmatrix} A^{-1} + A^{-1}B(D - CA^{-1}B)^{-1}CA^{-1} & -A^{-1}B(D - CA^{-1}B)^{-1} \\ -(D - CA^{-1}B)^{-1}CA^{-1} & (D - CA^{-1}B)^{-1} \end{bmatrix}$$

◦ 求解行列式:

$$\det \left(\begin{bmatrix} A & 0 \\ C & D \end{bmatrix} \right) = \det(A) \cdot \det(D)$$

若 A 可逆:

$$\det \left(\begin{bmatrix} A & B \\ C & D \end{bmatrix} \right) = \det(A) \cdot \det(D - CA^{-1}B)$$

若 A, B, C, D 为同阶方阵, 且满足 $CD = DC$, 则:

$$\det \begin{pmatrix} A & B \\ C & D \end{pmatrix} = \det(AD - BC)$$

6. 向量空间

- 向量空间的相关定义:

设 V 是定义在数域 $\mathbb{R}$ 上的一个向量空间, 对任意 $u, v, w \in V$, 以及任意标量 $\lambda, \mu \in \mathbb{R}$, 满足以下性质:

- 加法封闭性: 若 $u, v \in V$, 则 $u + v \in V$ 。
- 数乘封闭性: 若 $\lambda \in \mathbb{R}$ 且 $u \in V$, 则 $\lambda u \in V$ 。
- 向量加法结合律: $u + (v + w) = (u + v) + w$ 。
- 向量加法交换律: $u + v = v + u$ 。
- 数量乘法对向量加法的分配律: $\lambda(u + v) = \lambda u + \lambda v$ 。
- 数量乘法对标量加法的分配律: $(\lambda + \mu)u = \lambda u + \mu u$ 。
- 数量乘法的结合律: $\lambda(\mu u) = (\lambda\mu)u$ 。
- 加法单位元存在性: 存在一个零向量 $0 \in V$, 使得 $u + 0 = u$ 。
- 加法逆元存在性: 对任意 $u \in V$, 存在一个向量 $-u \in V$, 使得 $u + (-u) = 0$ 。
- 数乘单位元存在性: 存在一个单位标量 $1 \in \mathbb{R}$, 使得 $1 \cdot u = u$ 。

(与课程无关) 如何证明一个向量集合在同一个向量空间:

要验证定义完这两个运算之后,

向量加法: $V + V \rightarrow V$, 记作 $v + w$; $\forall v, w \in V$

标量乘法: $\mathbb{R} \times V \rightarrow V$, 记作 kv , $\forall k \in \mathbb{R}, \forall v \in V$

符合以下公理, $\forall k, l \in \mathbb{R}$ 和 $\forall u, v, w \in V$

向量加法结合律: $u + (v + w) = (u + v) + w$;

向量加法交换律: $v + w = w + v$

向量加法的单位元: V 里面有一个叫做零向量的元素 O , $\forall v \in V, v + O = v$;

向量加法的逆元存在: $\forall v \in V$ 都有 $\exists w \in V$, 使得 $v + w = O$;

标量加法分配与向量加法上: $k(v + w) = kv + kw$;

标量乘法分配于域加法上: $(k + l)v = kv + lv$;

标量乘法一致于标量的域乘法: $k(lv) = (kl)v$;

标量乘法有单位元: $1 \cdot v = v$, 在这里我们称 1 为指域 $\mathbb{R}$ 的乘法单位元。

- 向量空间与金融的关系:

一个投资组合 $x = (x_1, x_2, \dots, x_N)$ 描述了交易者在 N 个金融资产中的投资情况。通常来说, 权重 x_i ($i = 1, 2, \dots, N$) 是正实数, 表示投资金额。

然而, 如果允许**卖空 (short selling)**, 那么 x_i 也可以为负数。此时, 所有可能的投资组合构成一个定义在实数域 $\mathbb{R}$ 上的向量空间。

设 $W \subset V$, 若 W 本身也是一个向量空间, 则称 W 为 V 的一个**子空间 (subspace)**。

在投资组合空间中, 确定一个**正确的子空间**, 用于执行**现金流优化 (cashflow optimization)**, 对于理解**不完备市场中的无套利定价理论 (no-arbitrage pricing in incomplete markets)** 具有重要意义。

- 线性无关性:

设有 n 个向量组成的集合 $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_n$, 若满足以下条件:

$$\lambda_1 \mathbf{u}_1 + \lambda_2 \mathbf{u}_2 + \dots + \lambda_n \mathbf{u}_n = \mathbf{0} \Rightarrow \lambda_1 = \lambda_2 = \dots = \lambda_n = 0$$

则称这些向量是**线性无关的 (linearly independent)**。

若存在不全为零的系数使得上述等式成立, 则这些向量是**线性相关的 (linearly dependent)**。

设 $U = [\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_n] \in \mathbb{R}^{m \times n}$, 令 $\boldsymbol{\lambda} = [\lambda_1, \dots, \lambda_n]^T \in \mathbb{R}^n$, 则:

$$\{\mathbf{u}_1, \dots, \mathbf{u}_n\} \text{ 线性无关} \Leftrightarrow U\boldsymbol{\lambda} = \mathbf{0} \text{ 只有零解} \Leftrightarrow \text{若 } U \in \mathbb{R}^{m \times n}, \text{ 则 } U \text{ 可逆}$$

若向量组线性相关, 则可以通过构造增广矩阵 $[U \mid \mathbf{0}]$ 并使用高斯消元法 (或其他方法) 来寻找 $\boldsymbol{\lambda}$ 的**非零解 (non-trivial solution)**。

- 向量空间的维度和基:

向量空间的维度定义: 一个向量空间 V 的维度 n , 是从 V 中能选出的最多线性无关向量的个数。

向量空间基的定义: 若一个向量空间 V 中的任意向量都可以表示为 n 个线性无关向量的线性组合: $U = \{\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_n\}$, 满足:

- 向量组 U 是线性无关的;
- 向量空间 V 中任意向量 $\mathbf{v} \in V$ 都可以表示为 U 中向量的线性组合:

$$\mathbf{v} = v_1 \mathbf{u}_1 + v_2 \mathbf{u}_2 + \dots + v_n \mathbf{u}_n$$

则称 U 是 V 的一个基。

向量 $\mathbf{v}$ 在基 U 下的坐标为 $(v_1, v_2, \dots, v_n)$, 这些系数是唯一确定的。

(课外) 怎样证明: 一个向量组是某个空间的一组基?

第一种情况

已知 $\text{Span}\{v_1, v_2, \dots, v_n\} = V$, 证明 $\{v_1, v_2, \dots, v_n\}$ 是向量空间 V 的一组基

- 若 $\dim(V)$ 已知, 当 $\dim(V) = n$ 时, $\{v_1, v_2, \dots, v_n\}$ 是向量空间 V 的一组基
- 若 $\dim(V)$ 未知时, 只需要证明向量组 $\{v_1, v_2, \dots, v_n\}$ 线性无关, 令 $A = [v_1, v_2, \dots, v_n]$, 若 A 为方阵, 当 $\det(A) \neq 0$ 时, 向量组 $\{v_1, v_2, \dots, v_n\}$ 线性无关; 若 A 为非方阵, 当 $Ax = \mathbf{0}$ 只有平凡解, 即 $x = [0, \dots, 0]^T$ 时, 向量组 $\{v_1, v_2, \dots, v_n\}$ 线性无关。

第二种情况

已知向量组 $\{v_1, v_2, \dots, v_n\}$ 和向量空间 V , 先证明 $\text{Span}\{v_1, v_2, \dots, v_n\} = V$, 即对于 V 中的任意向量 v , 都可以表示为 $\{v_1, v_2, \dots, v_n\}$ 的线性组合, 即 $v = \alpha_1 v_1 + \dots + \alpha_n v_n$, 然后回到第一种情况。

- 向量空间的基变换 Change of Basis

定义: 一个向量空间 V 的基不是唯一的。设 $\mathbf{u}_1, \mathbf{u}_2, \dots, \mathbf{u}_n$ 与 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ 是 V 的两组不同的基。对于任意向量 $\mathbf{x} \in V$, 记它在两组基下的坐标分别为:

在 $\mathbf{u}_i$ 下为 $(x_1^u, x_2^u, \dots, x_n^u)$; 在 $\mathbf{v}_j$ 下为 $(x_1^v, x_2^v, \dots, x_n^v)$ 。

有以下引理 (Lemma):

若第二组基向量可表示为第一组基向量的线性组合:

$$\mathbf{v}_j = \sum_{i=1}^n a_{i,j} \mathbf{u}_i \quad (j = 1, \dots, n)$$

或记为矩阵形式:

$$V = UA_{V \rightarrow U}$$

则向量的基变换公式为：

$$\mathbf{x}^u = A_{V \rightarrow U} \mathbf{x}^v$$

即：

$$x_i^u = \sum_{j=1}^n a_{i,j} x_j^v \quad (i = 1, \dots, n)$$

推导如下：

$$\mathbf{x} = \sum_{i=1}^n x_i^u \mathbf{u}_i = \sum_{j=1}^n x_j^v \mathbf{v}_j = \sum_{j=1}^n x_j^v \left(\sum_{i=1}^n a_{i,j} \mathbf{u}_i \right) = \sum_{i=1}^n \left(\sum_{j=1}^n a_{i,j} x_j^v \right) \mathbf{u}_i$$

从而推出：

$$x_i^u = \sum_{j=1}^n a_{i,j} x_j^v$$

例：基底 $\mathcal{B} = \mathbf{b}_1, \mathbf{b}_2, \mathbf{b}_3$ ，其中：

$$\mathbf{b}_1 = \begin{bmatrix} -7 \\ 4 \\ 4 \end{bmatrix}, \quad \mathbf{b}_2 = \begin{bmatrix} 4 \\ 2 \\ -1 \end{bmatrix}, \quad \mathbf{b}_3 = \begin{bmatrix} -7 \\ 5 \\ 0 \end{bmatrix}$$

基底 $\mathcal{C} = \mathbf{c}_1, \mathbf{c}_2, \mathbf{c}_3$ ，其中：

$$\mathbf{c}_1 = \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}, \quad \mathbf{c}_2 = \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix}, \quad \mathbf{c}_3 = \begin{bmatrix} 3 \\ -1 \\ -1 \end{bmatrix}$$

问题 1：求从 $\mathcal{B}$ 到 $\mathcal{C}$ 的基变换矩阵

设 $B = [\mathbf{b}_1 \ \mathbf{b}_2 \ \mathbf{b}_3], C = [\mathbf{c}_1 \ \mathbf{c}_2 \ \mathbf{c}_3]$ ，则基变换矩阵为：

$$B = [\mathbf{b}_1 \ \mathbf{b}_2 \ \mathbf{b}_3] = \begin{bmatrix} -4 & 4 & -5 \\ 7 & 2 & 7 \\ 4 & -1 & 0 \end{bmatrix}, \quad C = [\mathbf{c}_1 \ \mathbf{c}_2 \ \mathbf{c}_3] = \begin{bmatrix} 1 & 0 & -3 \\ 1 & 1 & 1 \\ 0 & 1 & -1 \end{bmatrix}$$

基变换矩阵为：

设 $B = [\mathbf{b}_1 \ \mathbf{b}_2 \ \mathbf{b}_3], C = [\mathbf{c}_1 \ \mathbf{c}_2 \ \mathbf{c}_3]$ ，则基变换矩阵为：

$$P_{B \rightarrow C} = C^{-1}B = \begin{bmatrix} 0 & 3 & 5 \\ \frac{5}{3} & -\frac{2}{3} & -4 \\ -\frac{7}{3} & \frac{1}{3} & 4 \end{bmatrix}$$

问题2：坐标变换

若 $\mathbf{x}$ 在基底 $\mathcal{B}$ 下的坐标为 $[1, 2, 3]^T$ ，则其在 $\mathcal{C}$ 下的坐标为：

$$[\mathbf{x}]_C = P_{B \rightarrow C} \cdot \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} = \begin{bmatrix} 21 \\ -\frac{35}{3} \\ -\frac{41}{3} \end{bmatrix}$$

