

第三讲 参数估计

1. 统计推断导论 Introduction to Statistical Inference

给定一组 i.i.d. 样本 $X_1, X_2, \dots, X_n \sim F(x)$ 总体分布 $F(x)$ 往往未知。

Question

What can we infer about $F(x)$?

我们能从样本对 $F(x)$ 做如下推断:

- **非参数推断 (Non-parametric)** : 在不设定具体分布形式的前提下, 直接用数据估计 $F(x)$ 本身或其函数 (如分位数、均值)。

1. Non-parametric model: $F(x)$ 完全未知

经验分布函数 (ECDF) :

$$\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbf{1}\{X_i \leq x\}$$

它是一致的 $F(x)$ 估计 (大数定律与 Glivenko-Cantelli 定理表明 $\sup_x |\hat{F}_n(x) - F(x)| \rightarrow 0$ a.s.)。

- **区间与检验 (举例)** : 可基于 $\hat{F}_n$ 构造分位数估计与区间, 或做分布拟合/一致性检验 (如 Kolmogorov-Smirnov 检验)。
- **结论** : 在不设定模型的情况下, $\hat{F}_n$ 给出对 F 的直接、数据驱动的近似。
- **参数推断 (Parametric)** : 假设 $F(x)$ 属于某一已知分布族 $F(x; \theta)$, 但参数 θ 未知; 据此估计 θ 并进行假设检验, 从而间接了解 $F(x)$ 。

估计 (Estimation) : 用点估计或区间估计求 θ 。常见方法:

- **极大似然估计 $\hat{\theta}_{MLE}$** ;
- **矩估计** 等。
例如, 正态模型 $N(\mu, \sigma^2)$ 中, 用样本均值与样本方差估计 μ, σ^2 。
- **假设检验 (Hypothesis testing)** : 围绕参数或分布形式提出原假设 H_0 与备择 H_1 , 利用似然比、 $z/t/\chi^2/F$ 等检验统计量做决策。
- **不确定性量化**: 借助中心极限定理与 Delta 方法, 给估计量构造近似正态的标准化形式, 从而得到置信区间与 p 值。

- 基本概念

Parameter (参数)

- 在样本联合分布中**固定但未知**的常数 (如 θ) 称为“参数”。
- 有时 θ 的函数也称为参数 (例如方差 σ^2)。

Estimator / Estimate (估计量 / 估计值)

- **估计量**: 记为 $\hat{\theta}$, 是一个**统计量** (仅由 $X_1, \dots, X_n$ 组成、不含未知参数的函数), 用于估计 θ 。
- **估计值**: 把观测到的数据 $x_1, \dots, x_n$ 代入 $\hat{\theta}$ 得到的**具体数值**, 记为 $\hat{\theta}(x_1, \dots, x_n)$ 。

Note: **估计量是随机变量; 估计值是一个数。**

Example: 我们记录 5 名学生的身高 (单位 cm) : 178, 182, 170, 161, 164。

Q1. $X_1, \dots, X_5$ 表示什么?

- 它们是**随机变量**, 表示从总体中独立抽取的第 i 个学生的身高 (观测前是随机的)。
- 观测后的具体数值 $x_1 = 178, \dots, x_5 = 164$ 是这些随机变量的一次**实现**。

Q2. 若假设 $X_i \sim N(\mu, 1)$, 用样本均值

$$\bar{X} = \frac{X_1 + X_2 + X_3 + X_4}{4}$$

来估计 μ , 那么 $\bar{X}$ 与 $\bar{x} = 171$ 是否相同?

答: **不相同。原因有二:**

1. 概念不同

- $\bar{X}$ 是估计量 (**随机变量**), 在给定假设下 $\bar{X} \sim N(\mu, \frac{1}{4})$ 。
- $\bar{x} = 171$ 是用**5 个观测值**计算得到的样本均值 (**一个具体数**)。

2. 数值也不同 (若按上式只用前 4 个样本)

- 用前 4 个观测值的估计值为

$$\hat{\mu}_{(4\text{个样本})} = \frac{178 + 182 + 170 + 161}{4} = 172.75.$$

- 用全部 5 个观测值的样本均值为

$$\bar{x}_{(5\text{个样本})} = \frac{178 + 182 + 170 + 161 + 164}{5} = 171.$$

- Distinction between $X_1, \dots, X_n$ 和 $x_1, \dots, x_n$
 - 本质:** $X_1, \dots, X_n$ 是**随机变量**; $x_1, \dots, x_n$ 是它们在一次试验中的**具体取值** (实数)。
 - 时间视角:** 采集数据之前用 $X_1, \dots, X_n$ 表示; 数据观测后得到实现 $x_1, \dots, x_n$ 。
 - 推断对象:** 统计推断以 $X_1, \dots, X_n$ 为出发点 (考虑未来所有可能的数据及其不确定性), 而不仅是当前这组已观测到的 $x_1, \dots, x_n$ 。
- Distinction between θ 和 $\hat{\theta}$
 - θ : 总体 (分布) 中的**固定但未知**参数, 例如均值、方差、分位数等。它不是由样本决定的, 也不是随机的。
 - $\hat{\theta}$: 用于估计 θ 的**统计量**, 是 $X_1, \dots, X_n$ 的函数, 因此是**随机变量**; 其具体数值

$$\hat{\theta}(x_1, \dots, x_n)$$

才是本次样本下的**估计值**。

2. 点估计 Point Estimation

- Point Estimation (点估计)

Estimation: 基于样本为未知参数 θ 给出尽量接近其真实值的**估计过程**。

Point estimate: 对 $\hat{\theta}$ 给出**单个数值** (而非区间) 的估计。

- Bias (偏差)
偏差定义为

$$\text{bias}(\hat{\theta}) = \mathbb{E}(\hat{\theta}) - \theta.$$

- 若 $\mathbb{E}(\hat{\theta}) = \theta$, 则称 $\hat{\theta}$ **无偏**; 否则为**有偏**。
- 直观: 偏差度量估计量在重复抽样下的**系统性误差**。

- Standard error (标准误, SE)

定义: 估计量抽样分布的标准差

$$SE(\hat{\theta}) = \sqrt{\text{Var}(\hat{\theta})}.$$

◦ 直观: SE 描述**重复抽样的波动性** (不确定度)。

◦ SE 越小, 点估计越稳定。

Note: SE 依赖于总体分布 $F(x)$ (未知), 因此本身也是未知量, 但可通过:

◦ **解析/插件法:** 用样本估计未知量代入方差公式;

◦ **渐近近似:** 基于大样本正态性;

◦ **重抽样:** 如 bootstrap, 来估计 SE。

- Mean squared error (MSE)

对任一点估计量 $\hat{\theta}$, 同时需要考虑偏差与标准误来评估其质量。**均方误差** (MSE) 定义为

$$MSE(\hat{\theta}) = \mathbb{E}[(\hat{\theta} - \theta)^2].$$

◦ 结论

$$MSE(\hat{\theta}) = [\text{bias}(\hat{\theta})]^2 + \text{Var}(\hat{\theta}).$$

◦ 推导:

记 $\mu_{\hat{\theta}} = \mathbb{E}[\hat{\theta}]$, $\text{bias}(\hat{\theta}) = \mu_{\hat{\theta}} - \theta$. 则

$$\hat{\theta} - \theta = (\hat{\theta} - \mu_{\hat{\theta}}) + (\mu_{\hat{\theta}} - \theta)$$

平方并取期望:

$$\begin{aligned} \mathbb{E}[(\hat{\theta} - \theta)^2] &= \mathbb{E}[(\hat{\theta} - \mu_{\hat{\theta}})^2] + 2(\mu_{\hat{\theta}} - \theta) \mathbb{E}[\hat{\theta} - \mu_{\hat{\theta}}] + (\mu_{\hat{\theta}} - \theta)^2 \\ &= \underbrace{\text{Var}(\hat{\theta})}_{\mathbb{E}[(\hat{\theta} - \mu_{\hat{\theta}})^2]} + \underbrace{0}_{\mathbb{E}[\hat{\theta} - \mu_{\hat{\theta}}] = 0} + (\mu_{\hat{\theta}} - \theta)^2 \\ &= \text{Var}(\hat{\theta}) + [\text{bias}(\hat{\theta})]^2. \end{aligned}$$

注: 若 $\hat{\theta}$ 无偏, 则 $MSE(\hat{\theta}) = \text{Var}(\hat{\theta})$; 一般情形则体现**偏差-方差权衡**。

- 例: 伯努利总体比例的点估计, 设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Bernoulli}(p)$, 令

$$\hat{p} = \frac{1}{n} \sum_{i=1}^n X_i.$$

无偏性

$$\mathbb{E}(\hat{p}) = \frac{1}{n} \sum_{i=1}^n \mathbb{E}(X_i) = \frac{1}{n} \cdot np = p,$$

故 $\hat{p}$ 是 p 的无偏估计量。

标准误 (SE)

$$\text{Var}(\hat{p}) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i) = \frac{1}{n^2} \cdot np(1-p) = \frac{p(1-p)}{n}, \quad SE(\hat{p}) = \sqrt{\frac{p(1-p)}{n}}.$$

插件估计的 SE

$$\widehat{\text{SE}}(\hat{p}) = \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}.$$

数值题：有 $n = 10$ 个观测，其中“1”有 6 个、“0”有 4 个

$$\Rightarrow \hat{p} = \frac{6}{10} = 0.6,$$

$$\widehat{\text{SE}}(\hat{p}) = \sqrt{\frac{0.6 \times 0.4}{10}} = \sqrt{0.024} \approx 0.155.$$

例：正态均值的点估计

已知 $X_i \sim N(\mu, 1)$ ，使用估计量

$$\hat{\mu} = \bar{X} = \frac{X_1 + X_2 + X_3 + X_4}{4}.$$

无偏性

$$\mathbb{E}(\hat{\mu}) = \frac{1}{4} \sum_{i=1}^4 \mathbb{E}(X_i) = \frac{1}{4} \cdot 4\mu = \mu,$$

故 $\hat{\mu}$ 无偏。

给定 5 个观测 (178, 182, 170, 161, 164) 时的点估计

按题目给定的估计量（只用前 4 个）：

$$\hat{\mu} = \frac{178 + 182 + 170 + 161}{4} = 172.75.$$

估计量的 SE（已知方差为 1）

$$\text{Var}(\hat{\mu}) = \frac{1}{4^2} \sum_{i=1}^4 \text{Var}(X_i) = \frac{1}{16} \cdot 4 = \frac{1}{4}, \quad \text{SE}(\hat{\mu}) = \sqrt{\frac{1}{4}} = 0.5.$$

- 样本方差的无偏性

设 $X_1, \dots, X_n$ 是来自总体 (μ, σ^2) 的随机样本 (i.i.d., 不要求正态, 仅需方差有限)。记

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i, \quad S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2, \quad S^{*2} = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2.$$

关键恒等式

对任意常数 a ，都有

$$\sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n (X_i - a)^2 - n(\bar{X} - a)^2.$$

取 $a = \mu$ 得

$$\sum_{i=1}^n (X_i - \bar{X})^2 = \sum_{i=1}^n (X_i - \mu)^2 - n(\bar{X} - \mu)^2. \quad (\star)$$

取期望

由于 $\mathbb{E}(X_i) = \mu$, $\text{Var}(X_i) = \sigma^2$ 且独立,

$$\mathbb{E} \left[\sum_{i=1}^n (X_i - \mu)^2 \right] = n\sigma^2, \quad \text{Var}(\bar{X}) = \frac{\sigma^2}{n} \Rightarrow \mathbb{E} \left[n(\bar{X} - \mu)^2 \right] = n \cdot \frac{\sigma^2}{n} = \sigma^2.$$

把这些代入 $(\star)$:

$$\mathbb{E}\left[\sum_{i=1}^n (X_i - \bar{X})^2\right] = n\sigma^2 - \sigma^2 = (n-1)\sigma^2. \quad (\dagger)$$

结论

1. 无偏样本方差

$$\mathbb{E}(S^2) = \mathbb{E}\left[\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2\right] = \frac{1}{n-1} \cdot (n-1)\sigma^2 = \sigma^2.$$

2. 有偏版本

$$\mathbb{E}(S^{*2}) = \mathbb{E}\left[\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2\right] = \frac{1}{n} \cdot (n-1)\sigma^2 = \left(1 - \frac{1}{n}\right)\sigma^2.$$

因此

$$\text{bias}(S^{*2}) = \mathbb{E}(S^{*2}) - \sigma^2 = -\frac{\sigma^2}{n} (< 0),$$

说明 S^{*2} 低估 σ^2 , 而 S^2 是 σ^2 的无偏估计量。

- 评价准则与“如何找到好的点估计量？”

给定样本 $X_1, \dots, X_n \sim F$, 我们用某个统计量 $\hat{\theta} = \hat{\theta}(X_1, \dots, X_n)$ 来估计参数 θ 。

- 评价 $\hat{\theta}$ 的合理准则:

- **Small SE**: 标准误小, 抽样波动弱。 $\text{SE}(\hat{\theta}) = \sqrt{\text{Var}(\hat{\theta})}$.
- **Small bias**: 偏差小。 $\text{bias}(\hat{\theta}) = \mathbb{E}(\hat{\theta}) - \theta$.
- **Small MSE**: 均方误差小。 $\text{MSE}(\hat{\theta}) = \mathbb{E}[(\hat{\theta} - \theta)^2] = \text{Var}(\hat{\theta}) + \text{bias}(\hat{\theta})^2$.
- **Consistent**: 一致性。 $\hat{\theta}(X_1, \dots, X_n) \xrightarrow{P} \theta \quad (n \rightarrow \infty)$.
- **Robust**: 稳健性好 (样本出现少量异常点时仍给出合理估计)。

例:

- **样本均值 $\bar{X}$** : $\mathbb{E}(\bar{X}) = \mu$, $\text{Var}(\bar{X}) = \sigma^2/n \Rightarrow \bar{X}$ 无偏且由 LLN 得一致。
- **样本方差 S^2** : $\mathbb{E}(S^2) = \sigma^2$ (无偏), 且 $S^2 \xrightarrow{P} \sigma^2$ (一致)。

(1) 矩估计法 The Method of Moments

- 定义: 用“样本矩”去近似“总体矩”。也就是说, 样本给出的矩应当是相应总体矩的**好估计**。
- Population moment (总体矩)
对随机变量 X , 若 k 阶原点矩存在, 则

$$\mu_k = \mathbb{E}(X^k).$$

- Sample moment (样本矩)
若 $X_1, \dots, X_n$ 是来自某分布的随机样本, 则 k 阶样本矩定义为

$$m_k = \frac{1}{n} \sum_{i=1}^n X_i^k.$$

- 具体做法 (矩估计)
设参数为 p 维的 $\theta = (\theta_1, \dots, \theta_p)$, 取前 p 阶原点矩, 建立方程

$$m_k = \mu_k(\theta), \quad k = 1, \dots, p,$$

解得

$$\hat{\theta}_{\text{MoM}} = g(m_1, \dots, m_p).$$

由大数定律 $m_k \xrightarrow{P} \mu_k$, 在 g 连续且可解的条件下, $\hat{\theta}_{\text{MoM}}$ 往往是一致的。

• 例:

◦ **Bernoulli**(p): $\mu_1 = \mathbb{E}X = p \Rightarrow \hat{p}_{\text{MoM}} = m_1 = \bar{X}$.

◦ **Normal**(μ, σ^2): $\mu_1 = \mu, \mu_2 = \mathbb{E}X^2 = \mu^2 + \sigma^2$

$$\hat{\mu}_{\text{MoM}} = m_1 = \bar{X}, \quad \hat{\sigma}_{\text{MoM}}^2 = m_2 - \bar{X}^2, \quad m_2 = \frac{1}{n} \sum_{i=1}^n X_i^2.$$

• 若模型含有 K 个参数, 记总体第 k 阶矩为 $\mu_k = \mathbb{E}(X^k)$, 样本第 k 阶矩为

$$m_k = \frac{1}{n} \sum_{i=1}^n X_i^k,$$

则 **MME** 通过方程组

$$\mu_k = m_k, \quad k = 1, \dots, K$$

解出 $\hat{\theta}_{\text{MME}}$ (K 为待估参数个数)。

例: Poisson(λ) 的矩估计

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Pois}(\lambda)$ 。

Poisson 的一阶总体矩为

$$\mu_1 = \mathbb{E}(X) = \lambda,$$

而一阶样本矩为

$$m_1 = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i.$$

令 $\mu_1 = m_1$, 得

$$\hat{\lambda}_{\text{MME}} = \bar{X}.$$

记录 23 天 (10am-12pm) 的到店顾客数, 样本均值为 $\bar{X} = 24.9$ 。

因而 MME 为

$$\hat{\lambda} = 24.9.$$

• 标准误 (SE)

因为 $\text{Var}(X_i) = \lambda$, 所以样本均值的方差

$$\text{Var}(\bar{X}) = \frac{\lambda}{n}, \quad \text{SE}(\hat{\lambda}) = \sqrt{\text{Var}(\bar{X})} = \sqrt{\frac{\lambda}{n}}.$$

用插件法以 $\hat{\lambda}$ 代替未知的 λ :

$$\widehat{\text{SE}}(\hat{\lambda}) = \sqrt{\frac{\hat{\lambda}}{n}} = \sqrt{\frac{24.9}{23}} \approx 1.0405 \quad (\approx 1.04).$$

例：已知 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Uniform}(0, \theta)$ ，用矩估计法求 θ 。

- 总体一阶矩（均值）为

$$\mu_1 = \mathbb{E}[X] = \frac{\theta}{2}.$$

- 一阶样本矩为 $m_1 = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$ 。

令 $\mu_1 = m_1$ ，得

$$\hat{\theta}_{\text{MM}} = 2\bar{X}.$$

例：已知 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Gamma}(\alpha, \lambda)$ （采用 **rate** 参数化：pdf 为

$$f(x) = \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x}, x \geq 0).$$

用矩估计法求 α, λ 。

- 总体矩（或均值与方差）：

$$\mathbb{E}[X] = \frac{\alpha}{\lambda}, \quad \text{Var}(X) = \frac{\alpha}{\lambda^2}.$$

等价地，原点矩 $\mu_1 = \frac{\alpha}{\lambda}$ 、 $\mu_2 = \mathbb{E}[X^2] = \frac{\alpha(\alpha+1)}{\lambda^2}$ 。

- 样本矩：

$$m_1 = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i, \quad m_2 = \frac{1}{n} \sum_{i=1}^n X_i^2, \quad s^2 = m_2 - m_1^2.$$

解法 1 (用 m_1, m_2)

令 $\mu_1 = m_1, \mu_2 = m_2$ ，解得

$$\hat{\alpha}_{\text{MM}} = \frac{m_1^2}{m_2 - m_1^2} = \frac{m_1^2}{s^2}, \quad \hat{\lambda}_{\text{MM}} = \frac{\hat{\alpha}_{\text{MM}}}{m_1} = \frac{m_1}{m_2 - m_1^2} = \frac{m_1}{s^2}.$$

解法 2 (用均值与方差)

令 $\frac{\alpha}{\lambda} = m_1, \frac{\alpha}{\lambda^2} = s^2$ ，同样得到

$$\hat{\alpha}_{\text{MM}} = \frac{m_1^2}{s^2}, \quad \hat{\lambda}_{\text{MM}} = \frac{m_1}{s^2}.$$

(2) 极大似然估计 Maximum Likelihood Estimation

- Key idea.** 先选定一个“合理的”概率模型 $F(\cdot | \theta)$ 来描述数据。已观测数据固定为 $\mathbf{x} = (x_1, \dots, x_n)$ ，把参数 θ 当作未知变量，选择能让这组数据“最可能出现”的参数值：

$$\hat{\theta}_{\text{MLE}} = \arg \max_{\theta} L(\theta | \mathbf{x}).$$

- Likelihood function (似然函数)

给定随机样本 $X_1, \dots, X_n$ 与其观测值 $\mathbf{x} = (x_1, \dots, x_n)$ ，**似然函数**定义为在参数为 θ 时得到这组观测的联合密度/概率，把它视为 θ 的函数。

- 离散型** (pmf 为 $p(x | \theta)$ ，且常假设 X_i 独立同分布)：

$$L(\theta | \mathbf{x}) = \mathbb{P}_{\theta}(X_1 = x_1, \dots, X_n = x_n) = \prod_{i=1}^n p(x_i | \theta).$$

- 连续型** (pdf 为 $f(x | \theta)$ ，i.i.d. 情形)：

$$L(\theta | \mathbf{x}) = \prod_{i=1}^n f(x_i | \theta).$$

注：连续情形里 L 由密度构成，并非“概率值”；观测 $\mathbf{x}$ 视为已定， θ 是变量。

- Maximum Likelihood Estimation — 计算公式与做法

- 定义

给定样本 $\mathbf{X} = (X_1, \dots, X_n)$ 的观测值 $\mathbf{x} = (x_1, \dots, x_n)$ ，似然函数定义为

$$L(\theta | \mathbf{x}) = \prod_{i=1}^n f(x_i | \theta),$$

其对数似然为

$$\ell(\theta | \mathbf{x}) = \log L(\theta | \mathbf{x}) = \sum_{i=1}^n \log f(x_i | \theta).$$

极大似然估计量 (MLE) 是使似然（或等价的对数似然）最大的参数：

$$\hat{\theta} = \arg \max_{\theta} L(\theta | \mathbf{x}) = \arg \max_{\theta} \ell(\theta | \mathbf{x}).$$

- 典型求解步骤（函数极大化）

1. 求导并令零（得分方程）

若 θ 为标量：

$$\frac{\partial}{\partial \theta} \ell(\theta | \mathbf{x}) = 0.$$

若为向量参数： $\nabla_{\theta} \ell(\theta | \mathbf{x}) = \mathbf{0}$ 。

2. 验证是极大点

- 标量：检查二阶导 $\ell''(\hat{\theta}) < 0$ ；
- 向量：Hessian 为负定；
- **边界/约束** 情形需比较端点与内部临界点，取使 ℓ 最大者。

3. 报告估计与不确定性（可在后续用信息矩阵近似标准误等）。

例：正态模型下的极大似然估计 (MLE)

已做初步探索，胆固醇数据可用正态模型刻画： $X \sim N(\mu, \sigma^2)$ 。现有 $n = 25$ 个观测（单位 mmol/L）：

4.57 5.20 6.16 6.20 5.33 5.57 4.43 5.31 5.72 6.36 4.28 4.71 4.23 5.48 6.09 6.11 5.80 5.50 3.99
5.41 5.90 5.81 6.17 5.59 5.65

1. 似然与对数似然

对独立同分布的正态样本，联合密度为

$$L(\mu, \sigma^2 | \mathbf{x}) = (2\pi\sigma^2)^{-n/2} \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \right\}.$$

取对数（忽略与参数无关常数）：

$$\ell(\mu, \sigma^2) = -\frac{n}{2} \log \sigma^2 - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2.$$

2. 一阶条件求解 MLE

对 μ 求导并令零:

$$\frac{\partial \ell}{\partial \mu} = \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = 0 \Rightarrow \hat{\mu} = \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$$

将 $\mu = \bar{x}$ 代回, 对 σ^2 求导并令零:

$$\frac{\partial \ell}{\partial \sigma^2} = -\frac{n}{2\sigma^2} + \frac{1}{2(\sigma^2)^2} \sum_{i=1}^n (x_i - \bar{x})^2 = 0 \Rightarrow \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2.$$

注意: 正态模型下的 **MLE 方差** 的分母是 n (非 $n-1$)。

3. 代入数据计算

样本总和与均值:

$$\sum x_i = 135.57, \quad \bar{x} = \hat{\mu} = \frac{135.57}{25} = 5.4228.$$

离差平方和与方差:

$$\sum_{i=1}^n (x_i - \bar{x})^2 = 11.294104, \quad \hat{\sigma}^2 = \frac{11.294104}{25} = 0.45176416.$$

标准差:

$$\hat{\sigma} = \sqrt{\hat{\sigma}^2} = 0.67213.$$

4. 结果:

- MLE of mean: $\hat{\mu} = \mathbf{5.4228}$
- MLE of variance: $\hat{\sigma}^2 = \mathbf{0.451764}$
- (sd) $\hat{\sigma} = \mathbf{0.67213}$

例: Gamma(α, λ) 的极大似然估计 (rate 参量化)

已知样本 $x_1, \dots, x_n$ 来自

$$f(x | \alpha, \lambda) = \frac{1}{\Gamma(\alpha)} \lambda^\alpha x^{\alpha-1} e^{-\lambda x}, \quad x \geq 0, \alpha > 0, \lambda > 0.$$

1. 对数似然

$$\ell(\alpha, \lambda | \mathbf{x}) = \sum_{i=1}^n \log f(x_i | \alpha, \lambda) = n\alpha \log \lambda + (\alpha - 1) \sum_{i=1}^n \log x_i - \lambda \sum_{i=1}^n x_i - n \log \Gamma(\alpha).$$

2. 一阶条件

对 α, λ 求偏导, 并令为 0. 记 $\psi(\alpha) = \frac{\Gamma'(\alpha)}{\Gamma(\alpha)}$ 为 **digamma 函数**.

- 关于 α :

$$\frac{\partial \ell}{\partial \alpha} = n \log \lambda + \sum_{i=1}^n \log x_i - n \psi(\alpha) = 0.$$

- 关于 λ :

$$\frac{\partial \ell}{\partial \lambda} = \frac{n\alpha}{\lambda} - \sum_{i=1}^n x_i = 0.$$

由第二式得

$$\hat{\lambda} = \frac{n\hat{\alpha}}{\sum_{i=1}^n x_i} = \frac{\hat{\alpha}}{\bar{x}}, \quad \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$$

代回第一式，得到关于 $\hat{\alpha}$ 的方程

$$n \log \hat{\alpha} - n \log \bar{x} + \sum_{i=1}^n \log x_i - n \psi(\hat{\alpha}) = 0,$$

3. 数值求解

令 $g(\alpha)$ 如上，更新

$$\alpha^{(t+1)} = \alpha^{(t)} - \frac{g(\alpha^{(t)})}{g'(\alpha^{(t)})}, \quad g'(\alpha) = \frac{1}{\alpha} - \psi'(\alpha),$$

其中 $\psi'(\alpha)$ 为 **trigamma 函数**。

常用初值

- **矩估计初值**: $\alpha^{(0)} = \bar{x}^2/s^2$, $\lambda^{(0)} = \bar{x}/s^2$, s^2 为样本方差。
- 或采用 **log-moment** 初值: $\alpha^{(0)} \approx \frac{1}{2} \left/ \left(\log \bar{x} - \frac{1}{n} \sum \log x_i \right) \right.$ (粗略)。

迭代至收敛后，取

$$\hat{\alpha} = \alpha^{(\text{conv})}, \quad \hat{\lambda} = \frac{\hat{\alpha}}{\bar{x}}.$$

例: Bernoulli(θ) 的 MLE

模型与样本

$X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Bernoulli}(\theta)$, pmf 为

$$p(x | \theta) = \theta^x (1 - \theta)^{1-x}, \quad x \in \{0, 1\}, 0 \leq \theta \leq 1.$$

记成功次数 $S = \sum_{i=1}^n X_i$, 样本均值 $\bar{X} = S/n$ 。

似然与对数似然

$$L(\theta | \mathbf{x}) = \prod_{i=1}^n \theta^{x_i} (1 - \theta)^{1-x_i} = \theta^S (1 - \theta)^{n-S},$$

$$\ell(\theta) = \log L = S \log \theta + (n - S) \log(1 - \theta).$$

一阶条件

$$\frac{d\ell}{d\theta} = \frac{S}{\theta} - \frac{n-S}{1-\theta} = 0 \Rightarrow S(1-\theta) = \theta(n-S) \Rightarrow \hat{\theta} = \frac{S}{n} = \bar{X}.$$

二阶导检验 (极大点)

$$\frac{d^2\ell}{d\theta^2} = -\frac{S}{\theta^2} - \frac{n-S}{(1-\theta)^2} < 0,$$

当 $0 < \hat{\theta} < 1$ 时为极大值; 若 $S=0$ 或 $S=n$ 则最大值落在边界, 分别为 $\hat{\theta}=0$, $\hat{\theta}=1$ 。

结论

$$\boxed{\hat{\theta}_{\text{MLE}} = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X}} \quad (\text{极端样本 } S=0 \Rightarrow \hat{\theta}=0, S=n \Rightarrow \hat{\theta}=1).$$

例: Laplace($\theta, 1$) 的 MLE

模型与样本

$X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Laplace}(\theta, 1)$, pdf 为

$$f(x|\theta) = \frac{1}{2}e^{-|x-\theta|}, \quad -\infty < x, \theta < \infty.$$

似然与对数似然

$$L(\theta | \mathbf{x}) = \prod_{i=1}^n \frac{1}{2}e^{-|x_i-\theta|} = \left(\frac{1}{2}\right)^n \exp\left(-\sum_{i=1}^n |x_i - \theta|\right).$$

最大化 L 等价于最小化

$$Q(\theta) = \sum_{i=1}^n |x_i - \theta|.$$

最小化 $Q(\theta)$ 的解

设次序统计量 $x_{(1)} \leq \dots \leq x_{(n)}$ 。在开区间 $x_{(k)} < \theta < x_{(k+1)}$ 上,

$$Q'(\theta) = \#\{i: \theta > x_i\} - \#\{i: \theta < x_i\} = k - (n - k) = 2k - n,$$

故 $Q'(\theta) = 0$ 的解要求 $2k - n = 0 \Rightarrow k = n/2$ 。这意味着使 Q 取得最小的 θ 必须使左、右两侧样本个数相等——也就是**样本中位数**。

- 若 n 为奇数, 唯一解为

$$\hat{\theta}_{\text{MLE}} = x_{(\frac{n+1}{2})}.$$

- 若 n 为偶数, 任何

$$\hat{\theta}_{\text{MLE}} \in [x_{(\frac{n}{2})}, x_{(\frac{n}{2}+1)}]$$

都使 $Q(\theta)$ 最小 (常取样本中位数, 如两者平均)。

例: $\text{Uniform}(0, \theta)$ 的极大似然估计

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Uniform}(0, \theta)$, 其 pdf 为

$$f(x|\theta) = \begin{cases} \frac{1}{\theta}, & 0 < x \leq \theta, \\ 0, & \text{otherwise.} \end{cases}$$

记样本最大值为 $X_{(n)} = \max\{X_1, \dots, X_n\}$, 观测为 $\mathbf{x} = (x_1, \dots, x_n)$ 。

1. 似然与对数似然

联合密度 (似然):

$$L(\theta | \mathbf{x}) = \prod_{i=1}^n \frac{1}{\theta} \mathbf{1}\{0 < x_i \leq \theta\} = \theta^{-n} \mathbf{1}\{\theta \geq x_{(n)}\}.$$

对数似然 (忽略指示函数的约束部分):

$$\ell(\theta | \mathbf{x}) = \log L = -n \log \theta, \quad \text{定义域 } \theta \geq x_{(n)}.$$

2. 极大化

- 在可行域内, $-n \log \theta$ 单调递减于 θ ;
- 因此最大值出现在可行域的最小点, 即边界 $\theta = x_{(n)}$ 。

3. MLE 结论

$$\hat{\theta}_{\text{MLE}} = X_{(n)} = \max\{X_1, \dots, X_n\}.$$

说明：由于 $L(\theta | \mathbf{x}) = 0$ 当 $\theta < x_{(n)}$ ，而在 $\theta \geq x_{(n)}$ 时 $L(\theta)$ 随 θ 递减，故最优解为边界点 $x_{(n)}$ ；不存在内部驻点。

• 极大似然估计的性质：

1. Invariance (不变性)

若模型参数为 θ ，并关心其函数 $g(\theta)$ 。设 $\hat{\theta}$ 是 θ 的 MLE，则

$$\widehat{g(\theta)} = g(\hat{\theta}).$$

直观理由：在一一可逆时，令 $\tau = g(\theta)$ ，则

$$\arg \max_{\tau} L(\tau | \mathbf{x}) = \arg \max_{\theta} L(g(\theta) | \mathbf{x}) = g\left(\arg \max_{\theta} L(\theta | \mathbf{x})\right) = g(\hat{\theta}).$$

更一般地，即使 g 不是一一的， $g(\hat{\theta})$ 仍给出 $g(\theta)$ 的 MLE（可用 sup 在原像集上来论证）。

例子

■ Bernoulli 中若 $\hat{p} = \bar{X}$ ，则 odds $g(p) = \frac{p}{1-p}$ 的 MLE 为 $g(\hat{p}) = \frac{\bar{X}}{1-\bar{X}}$ 。

■ Uniform $(0, \theta)$ 中 $\hat{\theta} = X_{(n)}$ ，则 θ^2 的 MLE 为 $X_{(n)}^2$ 。

2. Consistency (一致性)

在适当的正则条件（独立同分布、模型正确设定、光滑性等）下，MLE 是一致的：

$$\hat{\theta} \xrightarrow{P} \theta \quad \text{as } n \rightarrow \infty.$$

直观理由 (LLN/M-估计思想)：对真参数 θ_0 ，

$$\frac{1}{n} \ell(\theta) = \frac{1}{n} \sum_{i=1}^n \log f(X_i | \theta) \xrightarrow{a.s.} \mathbb{E}_{\theta_0}[\log f(X | \theta)],$$

右侧（期望对数似然）在 $\theta = \theta_0$ 处唯一最大（与最小 Kullback-Leibler 距离等价）。因此使样本对数似然最大的 $\hat{\theta}$ 以概率收敛到 θ_0 。

3. Asymptotic Normality of MLE (极大似然估计的渐近正态性)

在适当的正则/光滑条件下（模型正确、可交换求导与期望、信息有限等），MLE 满足**渐近正态**。设真值为 θ_0 ，则有

$$\sqrt{n I(\theta_0)} (\hat{\theta} - \theta_0) \xrightarrow{d} N(0, 1),$$

或等价地

$$\hat{\theta} \sim N\left(\theta_0, \frac{1}{n I(\theta_0)}\right) \quad (n \text{ 大}).$$

其中 $I(\theta)$ 为 **Fisher 信息**，可由两种等价形式定义（记得分函数 $U(\theta) = \frac{\partial}{\partial \theta} \log f(X | \theta)$ ）：

$$I(\theta) = E[U(\theta)^2] = -E\left[\frac{\partial^2}{\partial \theta^2} \log f(X | \theta)\right].$$

注意：

■ **近似无偏：**由正态近似， $E(\hat{\theta}) \approx \theta_0$ （一阶近似）。

■ **近似方差 / MSE：**

$$\text{Var}(\hat{\theta}) \approx \frac{1}{n I(\theta_0)}, \quad \text{MSE}(\hat{\theta}) \approx \frac{1}{n I(\theta_0)}.$$

- **标准误 (SE) :**

$$\text{SE}(\hat{\theta}) \approx \frac{1}{\sqrt{n I(\theta_0)}}.$$

4. 效率 (Efficiency)

当比较**相同偏差** (通常都无偏) 的两个估计量时, 用**相对效率**衡量优劣。设 $\hat{\theta}$ 与 $\tilde{\theta}$ 的偏差相同, 则

$$\text{eff}(\hat{\theta}, \tilde{\theta}) = \frac{\text{Var}(\tilde{\theta})}{\text{Var}(\hat{\theta})}.$$

- 若两者都**无偏**, 且 $\text{Var}(\tilde{\theta}) \geq \text{Var}(\hat{\theta})$, 则称 $\hat{\theta}$ **更有效率** (more efficient)。
- 直观: 在无偏前提下, 方差越小, 估计越集中, 效率越高。

5. Cramér-Rao 下界 (CRLB)

设 $X_1, \dots, X_n$ 是来自密度 $f(x | \theta)$ 的 i.i.d. 样本, $T = T(X_1, \dots, X_n)$ 是 θ 的一个**无偏**估计量。在适当正则条件下, 有

$$\text{Var}(T) \geq \frac{1}{n I(\theta)},$$

其中 $I(\theta)$ 为**Fisher 信息** (单样本), 可写为

$$I(\theta) = E \left[\left(\frac{\partial}{\partial \theta} \log f(X | \theta) \right)^2 \right] = -E \left[\frac{\partial^2}{\partial \theta^2} \log f(X | \theta) \right].$$

意义: CRLB 给出了所有无偏估计量方差**的理论下界**; 任何无偏估计量的方差不可能比该下界更小。

6. 与 MLE 的关系

- 若 MLE $\hat{\theta}$ **无偏**, 并且其方差达到 CRLB, 则 $\hat{\theta}$ 是**最优 (最小方差) 无偏估计量** (UMVUE)。
- 在大样本下, MLE 具有

$$\text{Var}(\hat{\theta}) \approx \frac{1}{n I(\theta)},$$

因而**渐近地达到** CRLB, 称为**渐近有效** (asymptotically efficient)。

例: 设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{Pois}(\lambda)$ 。其似然为

$$L(\lambda | \mathbf{x}) = \prod_{i=1}^n \frac{e^{-\lambda} \lambda^{x_i}}{x_i!}, \quad \ell(\lambda) = \sum_{i=1}^n (-\lambda + x_i \log \lambda - \log x_i!).$$

求导并令零点:

$$\frac{\partial \ell}{\partial \lambda} = \sum_{i=1}^n \left(-1 + \frac{x_i}{\lambda} \right) = 0 \implies \hat{\lambda} = \bar{X}.$$

无偏性与最优性

$E(\bar{X}) = \lambda$, 故 $\bar{X}$ 无偏; 单样本 Fisher 信息 $I_1(\lambda) = 1/\lambda$, 故

$$\text{CRLB: } \text{Var}(T) \geq \frac{1}{n I_1(\lambda)} = \frac{\lambda}{n}.$$

而 $\text{Var}(\bar{X}) = \lambda/n$ 达到下界, 因此

$\hat{\lambda} = \bar{X}$ 是 **Poisson 中的最佳 (最小方差) 无偏估计量 (UMVUE)**。

例: 设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} \text{EXP}(\lambda)$, 密度 $f(x | \lambda) = \lambda e^{-\lambda x}, x \geq 0$ 。

题设: $E(X) = 1/\lambda$, $\text{Var}(X) = 1/\lambda^2$; 令总体均值 $\mu = 1/\lambda$ 。

(a) 求 μ 的 MLE

先对 λ 做 MLE:

$$L(\lambda | \mathbf{x}) = \lambda^n \exp\left(-\lambda \sum_{i=1}^n x_i\right), \quad \ell(\lambda) = n \log \lambda - \lambda \sum_{i=1}^n x_i.$$

一阶条件给出

$$\hat{\lambda} = \frac{n}{\sum_{i=1}^n x_i} = \frac{1}{\bar{X}}.$$

由 **MLE 不变性**, $\mu = 1/\lambda$ 的 MLE 为

$$\hat{\mu} = \frac{1}{\hat{\lambda}} = \bar{X}.$$

(b) 是否为最佳无偏估计量?

◦ 无偏性: $E(\bar{X}) = E(X) = 1/\lambda = \mu$, 故 $\bar{X}$ 无偏。

◦ CRLB: 单样本对 λ 的信息 $I_1(\lambda) = 1/\lambda^2$, 对 $\mu = 1/\lambda$ 的信息

$$I_n(\mu) = n I_1(\lambda) \left(\frac{d\lambda}{d\mu} \right)^2 = n \cdot \frac{1}{\lambda^2} \cdot \lambda^4 = n\lambda^2 = \frac{n}{\mu^2}.$$

因而

$$\text{CRLB: } \text{Var}(T) \geq \frac{1}{I_n(\mu)} = \frac{\mu^2}{n}.$$

而

$$\text{Var}(\bar{X}) = \frac{\text{Var}(X)}{n} = \frac{1/\lambda^2}{n} = \frac{\mu^2}{n},$$

恰好达到下界。

结论: $\hat{\mu} = \bar{X}$ 是 μ 的最佳 (最小方差) 无偏估计量 (UMVUE)。

(3) 区间估计 Interval Estimator (Confidence Interval)

- 定义 (基于样本的随机区间)

设随机样本为 $\mathbf{X} = (X_1, \dots, X_n)$, 其分布密度 (或 pmf) 为 $f(x | \theta)$ 。若存在两个由样本计算得到的统计量 (端点)

$$\hat{\theta}_L(\mathbf{X}), \hat{\theta}_U(\mathbf{X}),$$

满足

- $\hat{\theta}_L(\mathbf{X})$ 与 $\hat{\theta}_U(\mathbf{X})$ 都是 $\mathbf{X}$ 的函数 (因此是随机变量);
- $\hat{\theta}_L(\mathbf{X}) < \hat{\theta}_U(\mathbf{X})$;
- **覆盖概率 (coverage probability)** 为

$$P\{\theta \in (\hat{\theta}_L(\mathbf{X}), \hat{\theta}_U(\mathbf{X}))\} = 1 - \alpha,$$

则称区间 $(\hat{\theta}_L(\mathbf{X}), \hat{\theta}_U(\mathbf{X}))$ 为 θ 的一个 $100(1 - \alpha)\%$ **置信区间** (confidence interval)。

- 构建置信区间的方法：

Exact confidence intervals (又称 pivotal method)

思想：若能找到一个**枢轴量** (pivot) $Q(\mathbf{X}, \theta)$ ，其分布**不含未知参数** θ ，则可用其分位数**精确**构造置信区间 (有限样本下覆盖概率即为 $1 - \alpha$)。

枢轴量 (Pivot) 的定义：设样本 $\mathbf{X} = (X_1, \dots, X_n)$ ，参数为 θ 。若统计量 $Q(\mathbf{X}, \theta)$ 的分布不依赖于 θ ，则称 $Q(\mathbf{X}, \theta)$ 为**枢轴量**。

通用构造步骤

1. 选取枢轴量 $Q(\mathbf{X}, \theta)$;

寻找统计量 $Q(\mathbf{X}, \theta)$ ，其**分布不依赖于**未知参数 θ 。

例如：正态模型下

- 已知方差： $Q = \frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \sim N(0, 1)$;
- 未知方差： $Q = \frac{\sqrt{n}(\bar{X} - \mu)}{S} \sim t_{n-1}$;
- 方差本身： $Q = \frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2$ 。

2. 用其分位数 $q_{\alpha/2}, q_{1-\alpha/2}$ 写出

$$P(q_{\alpha/2} \leq Q(\mathbf{X}, \theta) \leq q_{1-\alpha/2}) = 1 - \alpha;$$

取常数 a, b ，使得

$$P(a \leq Q(\mathbf{X}, \theta) \leq b) = 1 - \alpha.$$

这里 a, b 是 Q 分布的分位数 (例如 z 、 t 或 χ^2 分位数)。

3. 对上式关于 θ “反解/翻转不等式”，得到 θ 的 $100(1 - \alpha)\%$ 置信区间。

将第 2 步的不等式关于 θ 变形，得到

$$\theta_L(\mathbf{X}) \leq \theta \leq \theta_U(\mathbf{X}),$$

这就是 θ 的 $100(1 - \alpha)\%$ 置信区间。

例：正态总体 $X_1, \dots, X_n \stackrel{i.i.d.}{\sim} N(\mu, \sigma^2)$

1. σ^2 已知 (估计 μ)

枢轴量

$$Z = \frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \sim N(0, 1)$$

由 z 分位数 $z_{1-\alpha/2}$ 得

$$P\left(-z_{1-\alpha/2} \leq \frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \leq z_{1-\alpha/2}\right) = 1 - \alpha,$$

化为 μ 的区间

$$\boxed{\bar{X} \pm z_{1-\alpha/2} \frac{\sigma}{\sqrt{n}}}$$

2. μ, σ^2 均未知 (估计 μ)

样本方差 $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$, 枢轴量

$$T = \frac{\sqrt{n}(\bar{X} - \mu)}{S} \sim t_{n-1}$$

由 t 分位数 $t_{1-\alpha/2, n-1}$ 得

$$\bar{X} \pm t_{1-\alpha/2, n-1} \frac{S}{\sqrt{n}}.$$

3. 估计 σ^2

$(n-1)S^2/\sigma^2$ 是否也是枢轴量?

答案: 是。因

$$\frac{(n-1)S^2}{\sigma^2} = \sum_{i=1}^n \frac{(X_i - \bar{X})^2}{\sigma^2} \sim \chi_{n-1}^2,$$

其分布不含未知参数 (与 μ 无关)。因此得到 σ^2 的精确区间

$$P\left(\chi_{\alpha/2, n-1}^2 \leq \frac{(n-1)S^2}{\sigma^2} \leq \chi_{1-\alpha/2, n-1}^2\right) = 1 - \alpha,$$

从而

$$\frac{(n-1)S^2}{\chi_{1-\alpha/2, n-1}^2} \leq \sigma^2 \leq \frac{(n-1)S^2}{\chi_{\alpha/2, n-1}^2}.$$

例: 正态总体均值 μ 的置信区间

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$, $\bar{X}$ 为样本均值, $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$ 为无偏样本方差。

情形 A: σ 已知 (Z 区间)

枢轴量:

$$Z = \frac{\sqrt{n}(\bar{X} - \mu)}{\sigma} \sim N(0, 1).$$

用标准正态分位点给出概率不等式:

$$1 - \alpha = \mathbb{P}(-z_{\alpha/2} < Z < z_{\alpha/2}),$$

其中 $z_{\alpha/2}$ 为 $N(0, 1)$ 的上 $\alpha/2$ 分位点 (亦写作 $z_{1-\alpha/2}$)。

解出 μ 并给区间:

$$\mu \in \left[\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}}, \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}} \right]$$

情形 B: σ 未知 (t 区间)

枢轴量:

$$T = \frac{\sqrt{n}(\bar{X} - \mu)}{S} \sim t_{n-1}.$$

用 t 分布分位点给出概率不等式:

$$1 - \alpha = \mathbb{P}(-t_{n-1, \alpha/2} < T < t_{n-1, \alpha/2}),$$

其中 $t_{n-1, \alpha/2}$ 为自由度 $n-1$ 的 t 分布上 $\alpha/2$ 分位点 (亦写 $t_{n-1, 1-\alpha/2}$)。

解出 μ 并给区间:

$$\mu \in \left[\bar{X} - t_{n-1, \alpha/2} \frac{S}{\sqrt{n}}, \bar{X} + t_{n-1, \alpha/2} \frac{S}{\sqrt{n}} \right]$$

例: 指数分布 $EXP(\lambda)$ 的 $100(1-\alpha)\%$ 置信区间

模型: $X_1, \dots, X_n \stackrel{i.i.d.}{\sim} EXP(\lambda)$, 密度为

$$f(x | \lambda) = \lambda e^{-\lambda x}, \quad x \geq 0, \lambda > 0.$$

枢轴量 (pivot)

记样本和 $S = \sum_{i=1}^n X_i$, 指数分布的可加性给出

$$S \sim \text{Gamma}(n, \text{rate} = \lambda) \implies \lambda S \sim \text{Gamma}(n, \text{rate} = 1),$$

因此 $Q(X, \lambda) = \lambda S$ 的分布与 λ 无关, 是一个**枢轴量**。

用分位点给出概率不等式

设 $\gamma_{n,1}(\cdot)$ 为 $\text{Gamma}(n, \text{rate} = 1)$ 的分位点函数, 则

$$\mathbb{P}\{\gamma_{n,1}(\alpha/2) \leq \lambda S \leq \gamma_{n,1}(1-\alpha/2)\} = 1 - \alpha.$$

化回参数, 得到置信区间

$S > 0$ (几乎必然), 两端同除以 S :

$$\lambda \in \left[\frac{\gamma_{n,1}(\alpha/2)}{S}, \frac{\gamma_{n,1}(1-\alpha/2)}{S} \right] \quad (\text{两侧 } 100(1-\alpha)\% \text{ 区间})$$

若用样本均值 $\bar{X} = S/n$ 表示:

$$\lambda \in \left[\frac{\gamma_{n,1}(\alpha/2)}{n\bar{X}}, \frac{\gamma_{n,1}(1-\alpha/2)}{n\bar{X}} \right].$$

与 χ^2 等价的写法 (常用)

因为 $2\lambda S \sim \chi_{2n}^2$, 记 $\chi_{2n,p}^2$ 为自由度 $2n$ 的 χ^2 分布的 p 分位点, 则

$$\lambda \in \left[\frac{\chi_{2n, \alpha/2}^2}{2S}, \frac{\chi_{2n, 1-\alpha/2}^2}{2S} \right] \quad \text{或} \quad \lambda \in \left[\frac{\chi_{2n, \alpha/2}^2}{2n\bar{X}}, \frac{\chi_{2n, 1-\alpha/2}^2}{2n\bar{X}} \right].$$

例: $X_1, \dots, X_n \stackrel{i.i.d.}{\sim} N(0, \sigma^2)$ 的 $100(1-\alpha)\%$ 置信区间

思路与关键枢轴量

已知均值为 0, 则

$$\frac{\sum_{i=1}^n X_i^2}{\sigma^2} \sim \chi_n^2$$

因此 $Q(X, \sigma^2) = \frac{\sum X_i^2}{\sigma^2}$ 的分布与 σ^2 无关, 是**枢轴量**。

记 $\chi_{\nu,p}^2$ 为自由度为 ν 的 χ^2 分布的 p 分位点 (即满足 $P(\chi_\nu^2 \leq \chi_{\nu,p}^2) = p$)。

构造两侧置信区间

由分位点不等式得

$$P\left(\chi_{n,\alpha/2}^2 \leq \frac{\sum_{i=1}^n X_i^2}{\sigma^2} \leq \chi_{n,1-\alpha/2}^2\right) = 1 - \alpha.$$

对不等式两侧同乘以 σ^2 并对 σ^2 求解, 得到

$$P\left(\frac{\sum_{i=1}^n X_i^2}{\chi_{n,1-\alpha/2}^2} \leq \sigma^2 \leq \frac{\sum_{i=1}^n X_i^2}{\chi_{n,\alpha/2}^2}\right) = 1 - \alpha$$

这就是 σ^2 的 $100(1 - \alpha)\%$ 两侧置信区间。

备注:

- 若要一侧区间, 把 α 全放在一边, 例如上侧区间

$$P\left(\sigma^2 \leq \frac{\sum X_i^2}{\chi_{n,\alpha}^2}\right) = 1 - \alpha, \quad P\left(\sigma^2 \geq \frac{\sum X_i^2}{\chi_{n,1-\alpha}^2}\right) = 1 - \alpha.$$

- 若均值未知 (一般情形), 需使用

$$\frac{\sum_{i=1}^n (X_i - \bar{X})^2}{\sigma^2} \sim \chi_{n-1}^2,$$

从而把上述公式中的 n 换为 $n - 1$, 并将 $\sum X_i^2$ 换为 $\sum (X_i - \bar{X})^2$ 。

- Asymptotic confidence intervals (基于极大似然估计的近似区间)

动机: 当难以找到精确的枢轴量且样本量 n 足够大时, 可利用 MLE 的渐近正态性构造近似置信区间。

回顾: MLE 的渐近正态性

若满足适当的正则条件, 则

$$\sqrt{n I(\theta_0)}(\hat{\theta} - \theta_0) \xrightarrow{d} N(0, 1), \quad n \rightarrow \infty,$$

其中 $I(\theta)$ 为 (单位样本) Fisher 信息, θ_0 为真值。

推导近似区间

由上式, 有

$$1 - \alpha \approx P\left(-z(\alpha/2) < \sqrt{n I(\theta_0)}(\hat{\theta} - \theta_0) < z(\alpha/2)\right),$$

其中 $z(\alpha/2)$ 是标准正态 $N(0, 1)$ 的上 $\alpha/2$ 分位数。

实际中 θ_0 未知, 用 $I(\hat{\theta})$ 代替 $I(\theta_0)$, 得到

$$1 - \alpha \approx P\left(-z(\alpha/2) < \sqrt{n I(\hat{\theta})}(\hat{\theta} - \theta_0) < z(\alpha/2)\right).$$

代数变形即可得到 θ_0 的近似 $100(1 - \alpha)\%$ 置信区间:

$$\hat{\theta} \pm \frac{z(\alpha/2)}{\sqrt{n I(\hat{\theta})}}$$

记号说明: $I(\hat{\theta})$ 表示在 $\hat{\theta}$ 处计算的 (单位样本) Fisher 信息; 其倒数的平方根即为 MLE 的近似标准误

$$\text{SE}(\hat{\theta}) \approx \frac{1}{\sqrt{n I(\hat{\theta})}}.$$