

第三讲 求导、微分与优化

1.多元函数

(1) 标量函数和向量函数

- 我们称输入是多个变量，输出是一个数值的函数

$$f(x, y, z, \dots) \quad \text{或} \quad f(x_1, x_2, \dots, x_n) \quad \text{或} \quad f(\mathbf{x})$$

为 (多元) 标量函数 scalar function。

- 称输入是多个变量，输出是一个向量，其每个分量都是一个标量函数的函数

$$\mathbf{F}(x, y, z, \dots) \quad \text{或} \quad \mathbf{F}(x_1, x_2, \dots, x_n) = \begin{bmatrix} F_1(x_1, x_2, \dots, x_n) \\ F_2(x_1, x_2, \dots, x_n) \\ \vdots \\ F_m(x_1, x_2, \dots, x_n) \end{bmatrix} \quad \text{或} \quad \mathbf{F}(\mathbf{x})$$

为 (多元) 向量函数 vector function。

(2) Copula 函数

- 定义：**Copula 函数是一类多元概率分布，用来刻画多个随机变量之间的依赖结构。

- 例：

1. Gumbel Copula:

$$C_G(u, v) = \exp \left\{ - \left[(-\ln u)^\delta + (-\ln v)^\delta \right]^{1/\delta} \right\},$$

其中 δ 表示 u 和 v 之间的非线性相关程度。

2. Frank Copula

$$C_F(u, v) = -\frac{1}{\vartheta} \ln \left[1 + \frac{(e^{-\vartheta u} - 1)(e^{-\vartheta v} - 1)}{e^{-\vartheta} - 1} \right],$$

其中 ϑ 表示 u 和 v 之间的非线性相关程度。

(课外)

以二元为例，若 $H(x, y)$ 是一个具有连续边缘分布的 $F(x)$ 与 $G(y)$ 的二元联合分布函数，那么存在唯一的 Copula 函数 C ，使得

$$H(x, y) = C(F(x), G(y)).$$

反之，如果 C 是一个 copula 函数，而 F 和 G 是两个任意的概率分布函数，那么由上述定义的 H 函数一定是一个联合分布函数，且对应的边缘分布恰好就是 F 和 G 。

Sklar 认为，对于 N 个随机变量的联合分布，可以将其分解为这 N 个变量各自的边缘分布和一个 Copula 函数，从而将变量的随机性和相关性分离开来。其中，随机变量各自的随机性由边缘分布进行描述，随机变量之间的相关性由 Copula 函数进行描述。换句话说，一个联合分布关于相关性的性质，完全由其 Copula 函数决定

如果已知 H 、 F 和 G ，则 Copula 函数可以表达为：

$$C(u, v) = H(F^{-1}(u), G^{-1}(v)),$$

Copula 理论的数学表达

假设 $X_1, X_2, \dots, X_N$ 是 N 个随机变量，它们各自的边缘分布分别为 $F_1(x_1), F_2(x_2), \dots, F_N(x_N)$ ，它们的联合分布为 $H(x_1, x_2, \dots, x_N)$ ，则存在一个将边缘分布和联合分布“连接”起来的函数 $C(\cdot)$ ，使得：

$$H(x_1, x_2, \dots, x_N) = C(F_1(x_1), F_2(x_2), \dots, F_N(x_N))$$

根据边缘分布的 CDF 的逆变换，即 $x_i = F_i^{-1}(u_i)$ ($i = 1, 2, \dots, N$)，可以得到 Copula 函数的表达形式：

$$C(u_1, u_2, \dots, u_N) = H(F_1^{-1}(u_1), F_2^{-1}(u_2), \dots, F_N^{-1}(u_N))$$

补充知识：概率积分变换 (Probability Integral Transform)

在概率论中，概率积分变换（也称为均匀的普适性）是指将任意给定连续分布的随机变量的数值借由转换成为具有均匀分布的随机变量的结果。

简单解释概率积分变换：如果 X_1 和 X_2 都是随机变量 (Random Variables, RV)，而 U_1, U_2 分别是它们的累积分布函数，即 $U_1 = F(X_1)$ ， $U_2 = F(X_2)$ ，那么 U_1 和 U_2 都服从均匀分布，即：

$$U_1 \sim \text{Uniform}(0, 1), \quad U_2 \sim \text{Uniform}(0, 1)$$

简单的数学证明如下：

$$F_U(u) = P(U \leq u) = P(F(X) \leq u) = P(F^{-1}(F(X)) \leq F^{-1}(u)) = P(X \leq F^{-1}(u)) = F(F^{-1}(u)) = u$$

换句话说，任何位于原分布的 CDF 值域的均匀分布在区间 $[0, 1]$ 上。

如果从任意分布中随机抽取，那么抽取的分布的最大值 ($U = 1$) 的概率等于可能的最小值 ($U = 0$) 或中值 ($U = 0.5$) 的概率相同。

而 copula 变量是它所连接的随机变量的 CDFs 的联合分布。

详解概率积分变换

概念与直观：给定一个随机变量 X 及其累积分布函数 (CDF) $F(x) = P(X \leq x)$ ，概率积分变换(PIT) 指将 X 映射为

$$U = F(X)$$

若 F 连续且严格单调，则

$$U \sim \text{Uniform}(0, 1)$$

直观理解： $F(X)$ 表示观测 X 在总体中的分位数（秩百分比）。

严格表述（连续情形）

设 F 为连续 CDF，定义广义反函数

$$F^{-1}(u) = \inf\{x : F(x) \geq u\}$$

对任意 $u \in [0, 1]$ ，有

$$P(U \leq u) = P(F(X) \leq u) = P(X \leq F^{-1}(u)) = F(F^{-1}(u)) = u,$$

因此 $U \sim \text{Uniform}(0, 1)$ 。

不连续（离散/混合）情形与随机化 PIT

若 F 有跳跃，直接取 $U = F(X)$ 不再严格均匀，而是在若干点有质量。

可用随机化 PIT 恢复均匀：设 $V \sim \text{Uniform}(0, 1)$ 与 X 独立，令

$$U = F(X^-) + V \cdot P(X = X), \quad F(x^-) = \lim_{t \uparrow x} F(t),$$

则 $U \sim \text{Uniform}(0, 1)$ 。

反向变换（抽样）

反之，若 $U \sim \text{Uniform}(0, 1)$ ，取

$$X = F^{-1}(U)$$

则 X 服从 CDF 为 F 的分布。这就是逆变换抽样法，常用于模拟复杂分布。

例：指数分布

若 $X \sim \text{Exp}(\lambda)$ ，则

$$F(x) = 1 - e^{-\lambda x}, \quad U = F(X) = 1 - e^{-\lambda X} \sim \text{Uniform}(0, 1)$$

反向为

$$X = F^{-1}(U) = -\frac{1}{\lambda} \ln(1 - U)$$

标准正态分布：

若 $X \sim \mathcal{N}(0, 1)$ ，令 $U = \Phi(X)$ （ Φ 为正态 CDF），则 $U \sim \text{Uniform}(0, 1)$ 。

反向为 $X = \Phi^{-1}(U)$ 。

离散例子（随机化 PIT）

若 $P(X = 0) = 0.3, P(X = 1) = 0.7$ ，则

$$F(0) = 0.3, \quad F(1) = 1$$

取

$$U = \begin{cases} V \cdot 0.3, & X = 0, \\ 0.3 + V \cdot 0.7, & X = 1, \end{cases} \quad V \sim \text{Uniform}(0, 1)$$

则 $U \sim \text{Uniform}(0, 1)$ 。

用途：

1. 模型检验/校准

若给出预测分布 $F_t(\cdot | \mathcal{I}_{t-1})$ ，则

$$U_t = F_t(X_t | \mathcal{I}_{t-1})$$

- 1

理应是 i.i.d. 的 $\text{Uniform}(0, 1)$ 。
- 2
- 3

用 PIT 直方图、QQ 图或独立性/均匀性检验可评估预测是否可靠。

2. Copula 与多元分布

对向量 $X = (X_1, \dots, X_d)$ ，对每个分量做 PIT 得

$$U_i = F_i(X_i) \in [0, 1],$$

- 1

则 $(U_1, \dots, U_d)$ 的联合分布就是 Copula，刻画变量间依赖结构。

3. 仿真

用均匀数通过 F^{-1} 生成任意目标分布样本，是蒙特卡罗方法的基础操作。

总结：PIT 把“任何分布”变为“均匀分布”——用 $U = F(X)$ 把观测投影到分位数空间；再用 $X = F^{-1}(U)$ 从均匀数还原目标分布。

• Copula 函数的形式

Copula 函数种类非常多，以二元为例，只需要满足下面三个条件的函数即为 Copula 函数：

1. 定义域为 $[0, 1] \times [0, 1]$, 值域为 $[0, 1]$, 即 $C: [0, 1] \times [0, 1] \rightarrow [0, 1]$.

2. $C(u, 0) = C(0, v) = 0$, $C(u, 1) = C(1, u) = u$, $C(v, 1) = C(1, v) = v$.

3. $0 \leq \frac{\partial C(u, v)}{\partial u} \leq 1$, $0 \leq \frac{\partial C(u, v)}{\partial v} \leq 1$, 或

$$C(u_2, v_2) - C(u_2, v_1) - C(u_1, v_2) + C(u_1, v_1) \geq 0,$$

对于任意的 $0 \leq u_1 \leq u_2 \leq 1$ 和 $0 \leq v_1 \leq v_2 \leq 1$ 成立

椭圆 Copula 函数簇: 椭圆 Copula 函数簇有 Copula 函数、Gaussian Copula 函数等, 两者均有对称的尾部相关性, 在中心区域差别不大, 差别主要体现在尾部的厚度。

这类 copula 函数, 同时通过已知的多元分布来计算出来的。最为人所知的就是多元正态分布的 copula, 即高斯 copula。

Gaussian copula: 高斯 copula 是 a distribution over the unit cube $[0, 1]^d$ 。它是从多元正态分布 R^d 通过概率积分变换得到的。

对于一个给定的协方差矩阵 (correlation matrix) $R \in [-1, 1]^{d \times d}$, 基于参数矩阵 R 的高斯 Copula 可以表达成:

$$C_R^{\text{Gauss}}(u) = \Phi_R(\Phi^{-1}(u_1), \dots, \Phi^{-1}(u_d))$$

其中, Φ^{-1} 是标准正态分布的逆累积分布函数, Φ_R 为多元正态分布的联合累积分布函数, 它的均值向量为 0, 协方差矩阵为 R 。

阿基米德 Copula 函数簇:

阿基米德 Copula 函数簇的分布函数定义首先由 Genest 和 Mackay 在 1986 年给出, 这一类函数有着统一的函数表达形式:

$$C(u_1, u_2, \dots, u_N) = \varphi^{-1}(\varphi(u_1) + \varphi(u_2) + \dots + \varphi(u_N))$$

如果用 wiki 加上参数的表示法, 则为:

$$C(u_1, u_2, \dots, u_N; \theta) = \varphi^{-1}(\varphi(u_1; \theta) + \varphi(u_2; \theta) + \dots + \varphi(u_N; \theta))$$

其中, 函数 $\varphi(\cdot)$ 称为阿基米德 Copula 函数的生成元 (或者叫生成函数, generator function), 生成元需要满足:

1. $\varphi: [0, 1] \times \Theta \rightarrow [0, \infty)$ 是一个连续、严格减函数和凸函数, 且 $\varphi(1) = 0$ ($\varphi(1; \theta) = 0$)。

2.
$$\varphi^{-1}(t; \theta) = \begin{cases} \varphi^{-1}(t; \theta), & \text{if } 0 \leq t \leq \varphi(0; \theta) \\ 0, & \text{if } \varphi(0; \theta) \leq t \leq \infty \end{cases}$$

并且要求 φ^{-1} 在 $(0, \infty)$ 是 N 维单调的, 即:

$$(-1)^k \varphi_t^{(k-1)}(t; \theta) \geq 0, \quad \text{对任意的 } 0 \leq t \leq 1, \quad k = 0, 1, \dots, d-2 \text{ 成立}$$

$$(-1)^d \varphi_{t,t}^{(d-2)}(t; \theta) \text{ 是一个非增凸函数}$$

3. 对于二维来说, 即需要满足对任意的 $0 \leq t \leq 1$, 有

$$\varphi^{-1'}(t) < 0, \quad \varphi^{-1''}(t) > 0$$

根据不同的生成元函数能够得到不同的阿基米德 Copula 函数, 常见有: Frank Copula、Clayton Copula 及 Gumbel Copula。Gumbel Copula 对于上尾部的厚尾特性比较敏感, 对于下尾部的厚尾特性不敏感, 因此适合于对上尾部厚尾特性明显而下尾部厚尾特性不明显的耦合结构建模; Clayton Copula 函数适合于下尾部厚尾特性明显而上尾部厚尾特性不明显的耦合结构建模; Frank Copula 的密度分布在“U”字形, 适合于描述具有对称厚尾结构变量的耦合关系。

常见二元 Copula 函数

Copula函数	概率分布函数	说明
正态Copula	$C(u_1, u_2) = \int_{-\infty}^{\phi^{-1}(u_1)} \int_{-\infty}^{\phi^{-1}(u_2)} \frac{1}{2\pi(1-\rho^2)^{1/2}} \exp\left\{-\frac{s^2-2\rho st+t^2}{2(1-\rho^2)}\right\} ds dt$	ϕ^{-1} 为标准正态分布函数的逆函数; ρ 是相关系数
t-Copula	$C(u_1, u_2, \rho, \nu) = \int_{-\infty}^{t_{\nu}^{-1}(u_1)} \int_{-\infty}^{t_{\nu}^{-1}(u_2)} \frac{1}{2\pi(1-\rho^2)^{1/2}} \exp\left\{\frac{\nu+2}{2} \log\left(1 + \frac{s^2-2\rho st+t^2}{\nu(1-\rho^2)}\right)\right\} ds dt$	t_{ν}^{-1} 为自由度为 ν 的 t 分布逆函数; ρ 是相关系数
Gumbel-Copula	$C(u_1, u_2) = \exp\left(-\left[(-\ln u_1)^{\theta} + (-\ln u_2)^{\theta}\right]^{1/\theta}\right)$	-
Clayton-Copula	$(u_1^{-\theta} + u_2^{-\theta} - 1)^{-1/\theta}$	-
Frank-Copula	$C(u_1, u_2) = -\frac{1}{\theta} \ln\left[1 + \frac{(e^{-\theta u_1}-1)(e^{-\theta u_2}-1)}{e^{-\theta}-1}\right]$	-

Most important Archimedean copulas

Name of copula	Bivariate copula $C_{\theta}(u, v)$	parameter θ
Ali-Mikhail-Haq	$\frac{uv}{1-\theta(1-u)(1-v)}$	$\theta \in [-1, 1]$
Clayton	$[\max\{u^{-\theta} + v^{-\theta} - 1; 0\}]^{-1/\theta}$	$\theta \in [-1, \infty) \setminus \{0\}$
Frank	$-\frac{1}{\theta} \log\left[1 + \frac{(\exp(-\theta u)-1)(\exp(-\theta v)-1)}{\exp(-\theta)-1}\right]$	$\theta \in \mathbb{R} \setminus \{0\}$
Gumbel	$\exp\left(-\left[(-\log u)^{\theta} + (-\log v)^{\theta}\right]^{1/\theta}\right)$	$\theta \in [1, \infty)$
Independence	uv	-
Joe	$1 - [(1-u)^{\theta} + (1-v)^{\theta} - (1-u)^{\theta}(1-v)^{\theta}]^{1/\theta}$	$\theta \in [1, \infty)$

Most important generators

name	generator $\psi_{\theta}(t)$	generator inverse $\psi_{\theta}^{-1}(t)$
Ali-Mikhail-Haq	$\log\left[\frac{1-\theta(1-t)}{1-\theta}\right]$	$\frac{1-\theta}{\exp(t)-\theta}$
Clayton	$\frac{1}{\theta}(t^{-\theta} - 1)$	$(1+\theta t)^{-1/\theta}$
Frank	$-\log\left(\frac{\exp(-\theta t)-1}{\exp(-\theta)-1}\right)$	$-\frac{1}{\theta} \log(1 + \exp(-t)(\exp(-\theta)-1))$
Gumbel	$(-\log t)^{\theta}$	$\exp(-t^{1/\theta})$
Independence	$-\log(t)$	$\exp(-t)$
Joe	$-\log(1 - (1-t)^{\theta})$	$1 - (1 - \exp(-t))^{1/\theta}$

(3) 等值集 (Level Sets)

- 定义 (Definition) :

对于单变量函数 $f(x)$, 令 $f(x) = C$ 通常会得到一组离散点 $\{x_1(C), \dots, x_n(C)\}$, 即使 $f(x)$ 是光滑的。对于二元光滑函数 $f(x, y)$, 令 $f(x, y) = C$ 会定义一族单参数光滑曲线, 这些曲线称为 $f(x, y)$ 的等值集 (level sets)。

- 例: 假设给定标量函数 $f(x, y) = x^2 + y^2$, 其等值集由 $x^2 + y^2 = C$ 给出, 这些是半径为 $\sqrt{C}$ 的圆 (当 $C > 0$ 时)。

2. (多元) 微分 Differentiation

(1) 微分与导数 Differentiation and Derivative

- 我们熟悉单变量函数的微分与积分，现在要推广到多变量函数。
- 理论上，需要先验证多元函数是否连续，这比单变量函数更复杂，因为在 x_0 处连续需要对所有趋近路径都连续。

- 在实际情况中，通常假设函数连续且光滑（无限可微），不连续或不光滑的情况比较少见，可单独处理。

元函数连续性的定义与证明：

设 $f(x, y)$ 在 (x_0, y_0) 附近有定义。若满足：

$$\lim_{(x,y) \rightarrow (x_0,y_0)} f(x, y) = f(x_0, y_0),$$

则称 f 在 (x_0, y_0) 处连续。

证明步骤：

- 检查定义域与函数值：验证 (x_0, y_0) 在定义域内，且 $f(x_0, y_0)$ 有定义。

- 计算极限值

计算 $\lim_{(x,y) \rightarrow (x_0,y_0)} f(x, y)$ ，并证明该极限存在且与路径无关。

- 可以先用极坐标代换： $x = x_0 + r \cos \theta, y = y_0 + r \sin \theta, r \rightarrow 0$ 。
- 也可以沿多条路径趋近 (x_0, y_0) ，验证极限值相同。
- 最严谨的方法是用 $\epsilon - \delta$ 定义证明。

- 比较极限与函数值

验证

$$\lim_{(x,y) \rightarrow (x_0,y_0)} f(x, y) = f(x_0, y_0)$$

则 f 在 (x_0, y_0) 处连续。

- 对于单变量函数 $f(x)$ ，若极限

$$\lim_{\delta x \rightarrow 0} \frac{\delta f}{\delta x} = \frac{df}{dx}$$

存在，则称其为 $f(x)$ 关于 x 的导数。

- 对于二元函数 $f(x, y)$ ， δf 的变化可能来自 δx 、 δy 或两者。

(2) 偏微分 (Partial Differentiation)

- 若固定 y 只改变 x ，则偏导数定义为

$$\lim_{\delta x \rightarrow 0, y, \text{fixed}} \frac{\delta f}{\delta x} = \frac{\partial f}{\partial x}$$

- 类似地，若固定 x 只改变 y ，则偏导数定义为

$$\lim_{\delta y \rightarrow 0, x, \text{fixed}} \frac{\delta f}{\delta y} = \frac{\partial f}{\partial y}$$

- 偏微分符号用 ∂ 代替 d 表示。

例：

考虑标量函数

$$f(x, y, z) = xy \cos z + yz \cos x + xz \cos y.$$

其偏导数为

$$\frac{\partial f}{\partial x} = y \cos z - yz \sin x + z \cos y,$$

$$\frac{\partial f}{\partial y} = x \cos z + z \cos x - xz \sin y,$$

$$\frac{\partial f}{\partial z} = -xy \sin z + y \cos x + x \cos y$$

例：Cobb-Douglas生产函数

已知生产函数： $Q(K, L) = 4K^{3/4}L^{1/4}$ ，其中 K 为资本投入， L 为劳动投入。

初始： $K = 10000$ ， $L = 625$ 。

企业决定增加 $\delta K = +10$ 单位资本，并减少 $\delta L = -16$ 单位劳动。

计算初始产量：

$$Q = 4(10000)^{3/4}(625)^{1/4} = 20000 \text{ 单位}$$

计算调整后的产量：

$$Q = 4(10010)^{3/4}(609)^{1/4} \approx 19886 \text{ 单位.}$$

故产量减少了 114 单位。

偏导近似计算：

生产函数的偏导为：

$$\frac{\partial Q}{\partial K} = 3K^{-1/4}L^{1/4}, \quad \frac{\partial Q}{\partial L} = K^{3/4}L^{-3/4}.$$

在 $K = 10000, L = 625$ 时：

$$\frac{\partial Q}{\partial K} = 1.5, \quad \frac{\partial Q}{\partial L} = 8.$$

使用近似公式：

$$\delta Q \approx \frac{\partial Q}{\partial K} \delta K + \frac{\partial Q}{\partial L} \delta L,$$

$$\delta Q \approx (1.5)(10) + (8)(-16) = -113.$$

该近似值与实际减少量 -114 非常接近。

柯布--道格拉斯Cobb-Douglas生产函数的定义与性质

定义：柯布--道格拉斯生产函数（Cobb--Douglas production function）是一种描述生产要素与产出之间关系的函数形式，常用于经济学生产分析。

一般形式为：

$$Q = AK^{\alpha}L^{\beta},$$

其中：

Q ：总产出（output）； $A > 0$ ：技术水平参数（total factor productivity）；资本投入量（capital input）；劳动投入量（labour input）； $\alpha, \beta > 0$ ：产出弹性（output elasticity）。

主要性质：

1. 正边际产量

$$MP_K = \frac{\partial Q}{\partial K} = A\alpha K^{\alpha-1}L^{\beta} > 0, \quad MP_L = \frac{\partial Q}{\partial L} = A\beta K^{\alpha}L^{\beta-1} > 0.$$

2. 边际产量递减

$$\frac{\partial^2 Q}{\partial K^2} < 0, \quad \frac{\partial^2 Q}{\partial L^2} < 0$$

3. 规模报酬

规模报酬由 $\alpha + \beta$ 决定：

$\alpha + \beta = 1$ ：规模报酬不变（CRS），即投入增加 t 倍，产出也增加 t 倍； $\alpha + \beta > 1$ ：规模报酬递增（IRS）； $\alpha + \beta < 1$ ：规模报酬递减（DRS）。

4. 要素产出弹性

资本产出弹性为 α ，劳动产出弹性为 β 。它们分别表示资本或劳动投入增加 1% 时产出的百分比变化。

5. 要素替代弹性

柯布-道格拉斯生产函数的要素替代弹性恒为：

$$\sigma = 1$$

即资本和劳动之间的替代能力保持不变。

(3) 全微分 (Total Differentiation)

- 定义：

对于足够小的 δx 和 δy ，有

$$\delta f \approx \frac{\partial f}{\partial x} \delta x + \frac{\partial f}{\partial y} \delta y.$$

当 $\delta x, \delta y \rightarrow 0$ 时，定义 $f(x, y)$ 的全微分为：

$$df = \frac{\partial f}{\partial x} dx + \frac{\partial f}{\partial y} dy$$

- 全微分的重要性：微分方程 $P(x, y)dx + Q(x, y)dy = 0$ 若能写成某个函数的全微分形式，则更易求解。（即恰当方程）

例：

设标量函数

$$f(x, y) = x^3 y + 3xy^3$$

则

$$\frac{\partial f}{\partial x} = 3x^2 y + 3y^3, \quad \frac{\partial f}{\partial y} = x^3 + 9xy^2.$$

因此，全微分为

$$df = (3x^2 y + 3y^3)dx + (x^3 + 9xy^2)dy$$

如果给定

$$(3x^2 y + 3y^3)dx + (x^3 + 9xy^2)dy = 0,$$

则有 $df = 0$ ，从而

$$f(x, y) = C,$$

其中 C 为常数，其值可由初始或边界条件确定。

- 多元函数的全微分：对于 n 元标量函数 $f(x_1, x_2, \dots, x_n)$ ，全微分为：

$$df = \frac{\partial f}{\partial x_1} dx_1 + \frac{\partial f}{\partial x_2} dx_2 + \dots + \frac{\partial f}{\partial x_n} dx_n.$$

- 向量函数的全微分：若 $\mathbf{F}(x_1, x_2, \dots, x_n) = \begin{bmatrix} F_1 & F_2 & \dots & F_m \end{bmatrix}$ ，其全微分是对每个分量的全微分：

设

$$\mathbf{F}(x_1, x_2, \dots, x_n) = \begin{bmatrix} F_1(x_1, x_2, \dots, x_n) \\ F_2(x_1, x_2, \dots, x_n) \\ \vdots \\ F_m(x_1, x_2, \dots, x_n) \end{bmatrix}$$

则

$$d\mathbf{F}(x_1, x_2, \dots, x_n) = \begin{bmatrix} dF_1 \\ dF_2 \\ \vdots \\ dF_m \end{bmatrix} = \begin{bmatrix} \frac{\partial F_1}{\partial x_1} dx_1 + \dots + \frac{\partial F_1}{\partial x_n} dx_n \\ \frac{\partial F_2}{\partial x_1} dx_1 + \dots + \frac{\partial F_2}{\partial x_n} dx_n \\ \vdots \\ \frac{\partial F_m}{\partial x_1} dx_1 + \dots + \frac{\partial F_m}{\partial x_n} dx_n \end{bmatrix}.$$

3. 隐函数求导 Implicit Functions

- **显函数**: 若 $f(x)$ 的解析形式已知, 即可以直接写成 $y = f(x)$, 则称为显函数。显函数可以直接用微分法则求导。
- **隐函数**: 若函数形式未知, 或者是通过代数方程或超越方程间接给出变量关系的函数, 就称为隐函数。隐函数可以用**隐函数求导法**来求导。

例: 隐函数 (线性方程)

已知:

$$4x + 2y = 5$$

显式解法: $y = \frac{5}{2} - 2x \Rightarrow \frac{dy}{dx} = -2$

隐式求导:

$$\frac{d}{dx}(4x + 2y) = 4 + 2\frac{dy}{dx} = 0 \Rightarrow \frac{dy}{dx} = -2$$

隐函数 (超越方程)

已知:

$$y^2 + \exp(xy) = \exp(x^2)$$

由于无法显式解出 $y = f(x)$, 对等式两边同时对 x 求导:

$$2y \frac{dy}{dx} + \left(y + x \frac{dy}{dx}\right) \exp(xy) = 2x \exp(x^2)$$

整理得:

$$\frac{dy}{dx} = \frac{2x \exp(x^2) - y \exp(xy)}{2y + x \exp(xy)}$$

例: 单位球面 (Unit sphere)

方程

$$x^2 + y^2 + z^2 = 1$$

该方程给出 z 作为 x 与 y 的隐函数。

为了求 $z(x, y)$ 的偏导数:

- 对 x 求偏导 (保持 y 不变):

$$2x + 2z \frac{\partial z}{\partial x} = 0$$

- 对 y 求偏导 (保持 x 不变) :

$$2y + 2z \frac{\partial z}{\partial y} = 0$$

解得:

$$\frac{\partial z}{\partial x} = -\frac{x}{z}, \quad \frac{\partial z}{\partial y} = -\frac{y}{z}.$$

- 隐函数定理

设函数 $G(x_1, x_2, \dots, x_n, y)$ 的所有偏导数存在, 且:

$$G(x_1, x_2, \dots, x_n, y) = 0$$

定义了 y 关于 $(x_1, x_2, \dots, x_n)$ 的隐函数 $y(x_1, x_2, \dots, x_n)$, 则其偏导数公式为:

$$\frac{\partial y}{\partial x_i} = -\frac{\frac{\partial G}{\partial x_i}}{\frac{\partial G}{\partial y}},$$

其中前提是 $\frac{\partial G}{\partial y} \neq 0$.

例:

我们重新考虑方程:

$$x^2 + y^2 + z^2 = 1$$

定义函数:

$$G(x, y, z) = x^2 + y^2 + z^2$$

其偏导数为:

$$\frac{\partial G}{\partial x} = 2x, \quad \frac{\partial G}{\partial y} = 2y, \quad \frac{\partial G}{\partial z} = 2z.$$

根据隐函数定理:

$$\frac{\partial z}{\partial x} = -\frac{\frac{\partial G}{\partial x}}{\frac{\partial G}{\partial z}} = -\frac{2x}{2z} = -\frac{x}{z}, \quad \frac{\partial z}{\partial y} = -\frac{\frac{\partial G}{\partial y}}{\frac{\partial G}{\partial z}} = -\frac{2y}{2z} = -\frac{y}{z}.$$

4. 换元法 Change of Independent Variables

- 独立变量的变换与偏微分链式法则

当我们要求解函数

$$f(x_1, \dots, x_n)$$

且它以独立变量 $x_1, \dots, x_n$ 表示时, 我们常常发现, 将它改写为另一组独立变量

$$y_1, \dots, y_n$$

会更容易求解。我们称下列方程组为独立变量的变换:

$$y_1 = y_1(x_1, \dots, x_n), \dots, y_n = y_n(x_1, \dots, x_n).$$

通常, 要求解 $f(x_1, \dots, x_n)$ 的方程是一个偏微分方程, 其涉及 f 关于 x_i 的偏导数。

我们需要将该偏微分方程改写为只涉及 f 关于 y_j 的偏导数的形式, 才能把它看作 $f(y_1, \dots, y_n)$ 的方程进行求解。

为此, 我们需要用到偏微分的链式法则。

- 偏微分的链式法则

若独立变量发生变换

$$y_1 = y_1(x_1, \dots, x_n), \dots, y_n = y_n(x_1, \dots, x_n),$$

则有

$$\frac{\partial f}{\partial x_i} = \frac{\partial f}{\partial y_1} \frac{\partial y_1}{\partial x_i} + \frac{\partial f}{\partial y_2} \frac{\partial y_2}{\partial x_i} + \dots + \frac{\partial f}{\partial y_n} \frac{\partial y_n}{\partial x_i}$$

球坐标系示例:

在笛卡尔坐标 (x, y, z) 中的标量函数 $f(x, y, z)$, 有时用球坐标 (r, θ, ϕ) 更方便:

$$r = (x^2 + y^2 + z^2)^{1/2}, \quad \theta = \cos^{-1} \frac{z}{(x^2 + y^2 + z^2)^{1/2}}, \quad \phi = \tan^{-1} \frac{y}{x}.$$

反变换为:

$$x = r \sin \theta \cos \phi, \quad y = r \sin \theta \sin \phi, \quad z = r \cos \theta.$$

偏导数为:

$$\begin{aligned} \frac{\partial r}{\partial x} &= \frac{x}{(x^2 + y^2 + z^2)^{1/2}} = \sin \theta \cos \phi, \\ \frac{\partial r}{\partial y} &= \frac{y}{(x^2 + y^2 + z^2)^{1/2}} = \sin \theta \sin \phi, \\ \frac{\partial r}{\partial z} &= \frac{z}{(x^2 + y^2 + z^2)^{1/2}} = \cos \theta, \\ \frac{\partial \theta}{\partial x} &= \frac{xz}{\sqrt{x^2 + y^2}(x^2 + y^2 + z^2)} = \frac{\cos \theta \cos \phi}{r}, \\ \frac{\partial \theta}{\partial y} &= \frac{yz}{\sqrt{x^2 + y^2}(x^2 + y^2 + z^2)} = \frac{\cos \theta \sin \phi}{r} \end{aligned}$$

(x, y, z) 与球坐标 (r, θ, ϕ) 的关系中, 有以下偏导数:

$$\begin{aligned} \frac{\partial \theta}{\partial z} &= -\frac{\sqrt{x^2 + y^2}}{x^2 + y^2 + z^2} = -\frac{\sin \theta}{r}, \\ \frac{\partial \phi}{\partial x} &= \frac{y}{x^2 + y^2} = -\frac{\sin \phi}{r \sin \theta}, \\ \frac{\partial \phi}{\partial y} &= \frac{x}{x^2 + y^2} = \frac{\cos \phi}{r \sin \theta}, \\ \frac{\partial \phi}{\partial z} &= 0. \end{aligned}$$

注意:

$$\frac{\partial r}{\partial x} \neq \frac{1}{r} \frac{\partial x}{\partial r},$$

因为偏导数的取法不同, 例如:

$$\frac{\partial r}{\partial x} = \left(\frac{\partial r}{\partial x} \right)_{y,z}, \quad \frac{\partial x}{\partial r} = \left(\frac{\partial x}{\partial r} \right)_{\theta,\phi}$$

- 因变量转换:

有时, 我们不仅会对自变量进行变换, 还需要进行因变量变换来解决偏微分方程。

若 $f(x_1, \dots, x_n)$ 是未知函数且是因变量, 则因变量变换可能是显式关系:

$$g = g(x_1, \dots, x_n; f),$$

或者隐式关系:

$$F(x_1, \dots, x_n; f, g) = 0,$$

从而得到 $g(x_1, \dots, x_n)$ 关于 $x_1, \dots, x_n$ 和 $f(x_1, \dots, x_n)$ 的表达式。

例：扩散方程

已知 $f(x, t)$ 满足方程

$$\frac{\partial f}{\partial t} + \frac{D}{2f(x, t)} \left(\frac{\partial f}{\partial x} \right)^2 - D \frac{\partial^2 f}{\partial x^2} = 0$$

定义 $g(x, t) = \sqrt{f(x, t)}$, 推导 $g(x, t)$ 满足的方程。

首先, 令 $f(x, t) = g^2(x, t)$, 则:

$$\begin{aligned} \frac{\partial f}{\partial t} &= 2g \frac{\partial g}{\partial t}, & \frac{\partial f}{\partial x} &= 2g \frac{\partial g}{\partial x}, \\ \frac{\partial^2 f}{\partial x^2} &= 2 \left(\frac{\partial g}{\partial x} \right)^2 + 2g \frac{\partial^2 g}{\partial x^2} \end{aligned}$$

将上述结果代入原方程:

$$0 = 2g \frac{\partial g}{\partial t} + \frac{D}{2g^2} \left(2g \frac{\partial g}{\partial x} \right)^2 - 2D \left(\frac{\partial g}{\partial x} \right)^2 - 2Dg \frac{\partial^2 g}{\partial x^2}.$$

化简得:

$$\frac{\partial g}{\partial t} - D \frac{\partial^2 g}{\partial x^2} = 0.$$

5. 向量运算 Vector Operations

(1) 梯度算子 (Gradient Operator)

- 对于标量函数 $f(x_1, \dots, x_n)$, 一阶偏导数可组织成向量, 记为梯度 (gradient), 符号 ∇f .
- 定义:

$$\nabla f = \begin{bmatrix} \frac{\partial}{\partial x_1} \\ \frac{\partial}{\partial x_2} \\ \vdots \\ \frac{\partial}{\partial x_n} \end{bmatrix} f(x_1, x_2, \dots, x_n) = \frac{\partial f}{\partial \mathbf{x}^T} = \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \frac{\partial f}{\partial x_2} \\ \vdots \\ \frac{\partial f}{\partial x_n} \end{bmatrix}$$

性质:

- 从几何上看, 梯度 $\nabla f(\mathbf{x})$ 表示函数 f 在点 $\mathbf{x}$ 增长最快的方向。更精确地说, 对于任意满足 $\|\mathbf{v}\| = \|\nabla f(\mathbf{u})\|$ 的向量 $\mathbf{v}$, 若 t 足够小, 则有:

$$f(\mathbf{u} + t\mathbf{v}) \leq f(\mathbf{u} + t\nabla f(\mathbf{u})).$$

证明:

(1) 命题: 梯度给出最陡上升方向:

设 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 在点 $\mathbf{u}$ 可微。则对所有满足

$\|\mathbf{v}\| = \|\nabla f(\mathbf{u})\|$ 的向量 $\mathbf{v}$, 存在 $t_0 > 0$,

当 $0 < t < t_0$ 时有

$$f(\mathbf{u} + t\mathbf{v}) \leq f(\mathbf{u} + t\nabla f(\mathbf{u})).$$

且当且仅当 $\mathbf{v}$ 与 $\nabla f(\mathbf{u})$ 同向时取等。

因此, 梯度 $\nabla f(\mathbf{u})$ 是 f 在 $\mathbf{u}$ 处增长最快的方向。

证明:

由可微性, 一阶泰勒展开显示对任意向量 $\mathbf{w}$ 且 $t \rightarrow 0^+$,

$$f(\mathbf{u} + t\mathbf{w}) = f(\mathbf{u}) + t \nabla f(\mathbf{u})^\top \mathbf{w} + o(t\|\mathbf{w}\|).$$

故方向导数 $D_{\mathbf{w}}f(\mathbf{u}) = \nabla f(\mathbf{u})^\top \mathbf{w}$.

固定长度 $\|\mathbf{w}\| = c$, 由柯西-施瓦茨不等式,

$$\nabla f(\mathbf{u})^\top \mathbf{w} \leq \|\nabla f(\mathbf{u})\| \|\mathbf{w}\| = c \|\nabla f(\mathbf{u})\|,$$

当且仅当 $\mathbf{w}$ 与 $\nabla f(\mathbf{u})$ 同向时取等。

这表明梯度方向使一阶增量最大, 即为最陡上升方向。

进一步令 $\|\mathbf{v}\| = \|\nabla f(\mathbf{u})\|$. 有

$$\begin{aligned} f(\mathbf{u} + t\mathbf{v}) &= f(\mathbf{u}) + t \nabla f(\mathbf{u})^\top \mathbf{v} + o(t\|\mathbf{v}\|), \\ f(\mathbf{u} + t\nabla f(\mathbf{u})) &= f(\mathbf{u}) + t \|\nabla f(\mathbf{u})\|^2 + o(t\|\nabla f(\mathbf{u})\|). \end{aligned}$$

两式相减并除以 t 得

$$\frac{f(\mathbf{u} + t\mathbf{v}) - f(\mathbf{u} + t\nabla f(\mathbf{u}))}{t} = \nabla f(\mathbf{u})^\top \mathbf{v} - \|\nabla f(\mathbf{u})\|^2 + o(1).$$

由柯西-施瓦茨且 $\|\mathbf{v}\| = \|\nabla f(\mathbf{u})\|$,

$$\nabla f(\mathbf{u})^\top \mathbf{v} \leq \|\nabla f(\mathbf{u})\|^2,$$

故上式右端的 $\limsup \leq 0$.

因此存在 $t_0 > 0$, 当 $0 < t < t_0$ 时

$$f(\mathbf{u} + t\mathbf{v}) \leq f(\mathbf{u} + t\nabla f(\mathbf{u})).$$

若且仅若 $\mathbf{v}$ 与 $\nabla f(\mathbf{u})$ 同向时等号成立。证毕。

(2) 矩阵微积分 (Basic Matrix Calculus)

- 设 $\mathbf{x}$ 是 p 维向量, $\mathbf{y}(\mathbf{x})$ 是 n 维向量函数, 则

$$\frac{\partial \mathbf{y}}{\partial \mathbf{x}} = \begin{bmatrix} \frac{\partial y_1}{\partial x_1} & \frac{\partial y_1}{\partial x_2} & \cdots & \frac{\partial y_1}{\partial x_p} \\ \frac{\partial y_2}{\partial x_1} & \frac{\partial y_2}{\partial x_2} & \cdots & \frac{\partial y_2}{\partial x_p} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial y_n}{\partial x_1} & \frac{\partial y_n}{\partial x_2} & \cdots & \frac{\partial y_n}{\partial x_p} \end{bmatrix}$$

- 其他记号习惯:

- 当 y 是标量时, $\partial y / \partial \mathbf{x}$ 有时写成列向量而不是行向量。
- 有时会写成 $\partial y / \partial \mathbf{x}^\top$, 以强调导数的列与 $\mathbf{x}^\top$ 的列对应关系。

- 常用恒等式 (直接带进去笔算即可)

- 若 $\mathbf{x} \in \mathbb{R}^p, \mathbf{y} \in \mathbb{R}^n$:

$$\frac{\partial \mathbf{y}}{\partial \mathbf{x}^\top} = \left(\frac{\partial \mathbf{y}}{\partial \mathbf{x}} \right)^\top.$$

- 若 $\mathbf{x} \in \mathbb{R}^p, \mathbf{A} \in \mathbb{R}^{n \times p}, \mathbf{B} \in \mathbb{R}^{p \times n}$ ($\mathbf{A}, \mathbf{B}$ 与 $\mathbf{x}$ 无关):

$$\frac{\partial \mathbf{A}\mathbf{x}}{\partial \mathbf{x}} = \mathbf{A}, \quad \frac{\partial \mathbf{x}^\top \mathbf{B}}{\partial \mathbf{x}^\top} = \mathbf{B}.$$

- 若 $\mathbf{x} \in \mathbb{R}^p, \mathbf{A} \in \mathbb{R}^{p \times p}$ ($\mathbf{A}$ 与 $\mathbf{x}$ 无关):

$$\frac{\partial (\mathbf{x}^\top \mathbf{A} \mathbf{x})}{\partial \mathbf{x}^\top} = (\mathbf{A} + \mathbf{A}^\top) \mathbf{x} = \{2\mathbf{A}\mathbf{x}, \text{ 若 } \mathbf{A} \text{ 对称}\}$$

- Hessian 矩阵 (Hessian Matrix)

对于 n 元函数 $f(x_1, \dots, x_n)$, 有 n^2 个二阶偏导数 $\frac{\partial^2 f}{\partial x_i \partial x_j}$, 其中 $i, j = 1, \dots, n$.

这些二阶偏导可以组织成 Hessian 矩阵:

$$[\nabla^2 f] = \frac{\partial^2 f}{\partial \mathbf{x} \partial \mathbf{x}^\top} = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \frac{\partial^2 f}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{bmatrix}.$$

- Young--Clairaut 定理

若 $f(x_1, \dots, x_n)$ 的所有二阶偏导在 $\mathbf{x}$ 处连续, 则

$$\frac{\partial^2 f}{\partial x_i \partial x_j} = \frac{\partial^2 f}{\partial x_j \partial x_i}.$$

这说明 Hessian 矩阵是对称的。

(课外)

证明:

令

$$\Delta(h, k) = f(a+h, b+k) - f(a+h, b) - f(a, b+k) + f(a, b)$$

第一种表示: 对固定 x , 有

$$f(x, b+k) - f(x, b) = \int_b^{b+k} f_y(x, t) dt,$$

故

$$\Delta(h, k) = \int_b^{b+k} (f_y(a+h, t) - f_y(a, t)) dt = \int_b^{b+k} \left(\int_a^{a+h} f_{yx}(s, t) ds \right) dt = \int_a^{a+h} \int_b^{b+k} f_{yx}(s, t) dt ds$$

第二种表示:

同理,

$$\Delta(h, k) = \int_a^{a+h} (f_x(s, b+k) - f_x(s, b)) ds = \int_a^{a+h} \left(\int_b^{b+k} f_{xy}(s, t) dt \right) ds = \int_a^{a+h} \int_b^{b+k} f_{xy}(s, t) dt ds.$$

由两式相等,

$$\int_a^{a+h} \int_b^{b+k} f_{yx}(s, t) dt ds = \int_a^{a+h} \int_b^{b+k} f_{xy}(s, t) dt ds.$$

两边同除以 hk 并令 $(h, k) \rightarrow (0, 0)$. 因 f_{xy}, f_{yx} 在 R 上连续,

$$\lim_{(h,k) \rightarrow (0,0)} \frac{1}{hk} \int_a^{a+h} \int_b^{b+k} f_{yx}(s, t) dt ds = f_{yx}(a, b), \quad \lim_{(h,k) \rightarrow (0,0)} \frac{1}{hk} \int_a^{a+h} \int_b^{b+k} f_{xy}(s, t) dt ds = f_{xy}(a, b).$$

遂得 $f_{yx}(a, b) = f_{xy}(a, b)$. 证毕。

备注:

1. 连续性假设可进一步放宽: 若 f_x, f_y 在邻域内连续, 且 f_{xy} 在邻域内连续, 同时 $f_{yx}(a, b)$ 存在 (或互换 xy 与 yx 角色), 结论仍成立。
2. 若缺少正则性, 存在反例使 $f_{xy} \neq f_{yx}$.
3. 结论可推广至更高维度的二阶混合偏导交换。

(课外)

- 二阶导数条件: 设 $f(x_1, x_2, \dots, x_n)$ 是一个二阶可微的实值函数, 则它的 Hessian 矩阵定义为:

$$H(f) = \begin{bmatrix} \frac{\partial^2 f}{\partial x_1^2} & \frac{\partial^2 f}{\partial x_1 \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_1 \partial x_n} \\ \frac{\partial^2 f}{\partial x_2 \partial x_1} & \frac{\partial^2 f}{\partial x_2^2} & \cdots & \frac{\partial^2 f}{\partial x_2 \partial x_n} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial^2 f}{\partial x_n \partial x_1} & \frac{\partial^2 f}{\partial x_n \partial x_2} & \cdots & \frac{\partial^2 f}{\partial x_n^2} \end{bmatrix}$$

我们可以发现Hessian矩阵的元素 H_{ij} 为：

$$H_{ij} = \frac{\partial^2 f}{\partial x_i \partial x_j}$$

- 若 $H(f)$ 在该点是**正定矩阵**，则为**局部极小值**。
- 若 $H(f)$ 在该点是**负定矩阵**，则为**局部极大值**。
- 若 $H(f)$ 既不是正定也不是负定，则该点可能是**鞍点 (saddle point)**。
- 补充：矩阵的正定性判别与定义

设 A 是一个实对称矩阵。根据向量二次型 $x^T A x$ 的符号，可以将矩阵 A 分类如下：

1. 正定矩阵：对任意非零向量 x ，有 $x^T A x > 0$
2. 负定矩阵：对任意非零向量 x ，有 $x^T A x < 0$
3. 半正定矩阵：对任意向量 x ，有 $x^T A x \geq 0$
4. 半负定矩阵：对任意向量 x ，有 $x^T A x \leq 0$
5. 不定矩阵：存在 x, y 使得 $x^T A x > 0$ 而 $y^T A y < 0$

判断矩阵正负定的方法：

1. 主子式判别法 (Sylvester 判别法)

设 A_k 为 A 的前 k 阶主子矩阵，则：

A 正定当且仅当所有主子式 $\det(A_k) > 0$

A 负定当且仅当主子式符号交替： $\det(A_1) < 0, \det(A_2) > 0, \det(A_3) < 0, \dots$

2. 特征值判别法

若 A 的特征值为 $\lambda_1, \lambda_2, \dots, \lambda_n$ ，则：

所有 $\lambda_i > 0$ ，则 A 正定；所有 $\lambda_i < 0$ ，则 A 负定；所有 $\lambda_i \geq 0$ ，则 A 半正定；所有 $\lambda_i \leq 0$ ，则 A 半负定；存在 $\lambda_i > 0$ 和 $\lambda_j < 0$ ，则 A 为不定矩阵。

通过上述判断方法可以得到以下推论：设 A 是 (半) 正定矩阵，则 $Tr(A)$ 和 $Det(A)$ 都是 (非负) 正的。

对于对角矩阵，对角元就是特征值，所以我们可以得到下面的推论：

设 $D = \text{diag}(d_1, d_2, \dots, d_n)$ ，则：

- D 是正定的当且仅当对所有 i 都有 $d_i > 0$ ；
- D 是半正定的当且仅当对于所有 i 都有 $d_i \geq 0$
- D 是负定的当且仅当对于所有 i 都有 $d_i < 0$
- D 是半负定的当且仅当对于所有 i 都有 $d_i \leq 0$

部分和正负定相关的定理和性质：

1. 引理1：设 $A \in R^{n \times n}$ 是正定矩阵，则 A 的对角线元素都大于0

证明：因为 A 是正定的，对于任意 $x \neq 0 \in R^n$ 都有 $x^T A x > 0$ ，于是对 $i \in \{1, 2, 3, \dots, n\}$ 有 $a_{ii} = e_i^T A e_i > 0$ ，其中 a_{ii} 是矩阵的对角元素。并且 $e_1 = [1, 0, \dots, 0]$ ，以此类推。

类似的证明我们可以得到以下引理2

2. 引理2：设 $A \in R^{n \times n}$ 是半正定矩阵，则 A 的对角线元素都非负

由定义可知, 若 A 是(半)负定的, 当且仅当 $-A$ 是(半)正定的, 因此有以下结论。

3. 引理3: 设 $A \in R^{n \times n}$ 是负定矩阵, 则 A 的对角线元素都小于0; 设 $A \in R^{n \times n}$ 是半负定矩阵, 则 A 的对角线元素都非正

4. 引理4: 设 A 是 $n \times n$ 的对称矩阵, 如果 A 的对角元素既有正值也有负值那么 A 是不定矩阵。

证明: 设 $a_{ii} > 0, a_{jj} < 0$, 则有

$$e_i^T A e_i = a_{ii} > 0, e_j^T A e_j = a_{jj} < 0$$

因此 A 是不定矩阵。

注意: 该结论反过来不一定成立, 即如果 A 是不定矩阵, A 的对角元素不一定既有正值也有负值。

■ 定理: 设 A 是 $n \times n$ 的对称矩阵, 则有:

1. A 是正定的, 当且仅当其所有特征值都是正的
2. A 是半正定的, 当且仅当其所有特征值都是非负的
3. A 是负定的, 当且仅当其所有特征值都是负的
4. A 是半负定的, 当且仅当其所有特征值都是非正的
5. A 是不定的, 当且仅当其至少存在一个正的特征值和负的特征值

■ 对角占优矩阵: 设 A 是一个 $n \times n$ 的对称矩阵, 则

1. A 被称为对角占优矩阵, 那么对所有的 $i = 1, 2, \dots, n$ 有

$$|a_{ii}| \geq \sum_{i \neq j} a_{ij}$$

2. A 被称为严格对角占优矩阵, 那么对所有的 $i = 1, 2, \dots, n$ 有

$$|a_{ii}| > \sum_{i \neq j} a_{ij}$$

■ 对角占优矩阵的正定性:

1. 如果 A 是对称的 $n \times n$ 的对角占优矩阵, 并且对角元非负, 则 A 是半正定的
2. 如果 A 是对称的 $n \times n$ 的严格对角占优矩阵, 并且对角元为正, 则 A 是正定的

证明: 先证明1, 反证法, 假设 A 存在福德特征值 λ , 对应的特征向量为 u , 则满足 $Au = \lambda u$, 设

$$|u_i| = \max\{|u_1|, |u_2|, \dots, |u_n|\}$$

则有

$$|a_{ii} - \lambda| \cdot |u_i| = \left| \sum_{i \neq j} a_{ij} u_j \right| \leq \left(\sum_{i \neq j} |a_{ij}| \right) |u_i| \leq |a_{ii}| |u_i|$$

其中等式由 $Au = \lambda u$ 得到, 第一个不等式由 $|u_i|$ 的定义得到

$$\left| \sum_{i \neq j} a_{ij} u_j \right| \leq \sum_{i \neq j} |a_{ij}| |u_i| \leq \left(\sum_{i \neq j} |a_{ij}| \right) |u_i|$$

第二个不等式由对角占有矩阵的定义得到。由上述不等式可以得到 $|a_{ii} - \lambda| \leq |a_{ii}|$, 这与 $\lambda < 0, a_{ii} > 0$ 矛盾。

下面证明2, 由1可知 A 半正定, 那么接下来我们只需要证明 A 的特征值不为0, 反证法, 假设存在一个特征值为0, 对应的特征向量 $u \neq 0$, 因此 $Au = 0$ 。设

$$|u_i| = \max\{|u_1|, |u_2|, \dots, |u_n|\}$$

则有

$$|a_{ii}| |u_i| = \left| \sum_{i \neq j} a_{ij} u_j \right| \leq \left(\sum_{i \neq j} |a_{ij}| \right) |u_i| < |a_{ii}| |u_i|$$

这显然是不可能的，因此矛盾。

- 注意：以上关于Hessian矩阵的内容为补充内容，课件上只要求掌握两个自变量的情况。
- 设函数 $f(x, y)$ 是两次可微的，并且其偏导数连续。假设 (x_0, y_0) 是一个驻点（极值点候选），则我们可以根据二阶偏导数判断该点的性质如下：

有以下判别式：

$$D = \frac{\partial^2 f}{\partial x^2}(x_0, y_0) \cdot \frac{\partial^2 f}{\partial y^2}(x_0, y_0) - \left(\frac{\partial^2 f}{\partial x \partial y}(x_0, y_0) \right)^2$$

如果 $D > 0$ 且 $\frac{\partial^2 f}{\partial x^2}(x_0, y_0) > 0$ ，则 (x_0, y_0) 是极小值点。

如果 $D > 0$ 且 $\frac{\partial^2 f}{\partial x^2}(x_0, y_0) < 0$ ，则 (x_0, y_0) 是极大值点。

如果 $D < 0$ ，则 (x_0, y_0) 是鞍点。

如果 $D = 0$ ，则不能确定 (x_0, y_0) 的性质，需要观察函数 $f(x, y)$ 的三维图像进行判断。

6. (有约束的) 优化问题(Constrained) Optimization

1. 临界点 (Critical Points)

- 对于一元标量函数 $f(x)$ ，临界点的判定方法如下：
先求一阶导数 $f'(x)$ ，若在 $x = a$ 处 $f'(a) = 0$ ，再由二阶导数 $f''(a)$ 判断其类型：
 - 若 $f'(a) = 0$ 且 $f''(a) < 0$ ，则 $x = a$ 为极大值点 (maximum)；
 - 若 $f'(a) = 0$ 且 $f''(a) > 0$ ，则 $x = a$ 为极小值点 (minimum)；
 - 若 $f'(a) = 0$ 且 $f''(a) = 0$ ，则 $x = a$ 为拐点 (point of inflexion)。

- 多元函数的推广

对于多元函数 $f(\mathbf{x})$ ，若在 $\mathbf{x} = \mathbf{a}$ 处

$$\nabla f(\mathbf{a}) = 0,$$

则称 $\mathbf{x} = \mathbf{a}$ 为一个临界点 (critical point)。

(补充：单变量的无约束优化)

- 最大最小值的定义：
 - 绝对最大最小值 (Absolute Extremes)：设 f 是定义在区域 D 上的函数， $c \in D$ ，则有以下定义：
若对所有 $x \in D$ ，都有 $f(c) \geq f(x)$ ，则称 $f(c)$ 为 f 在 D 上的绝对最大值 (全局最大值)
若对所有 $x \in D$ ，都有 $f(c) \leq f(x)$ ，则称 $f(c)$ 为 f 在 D 上的绝对最小值 (全局最小值)
 - 局部最大最小值 (Local Extremes)：设 $c \in D$ ，若存在包含 c 的开区间 I ，使得：
对所有 $x \in I \cap D$ ，都有 $f(c) \geq f(x)$ ，则称 $f(c)$ 为 f 的局部最大值
对所有 $x \in I \cap D$ ，都有 $f(c) \leq f(x)$ ，则称 $f(c)$ 为 f 的局部最小值
- 驻点的定义：若 f 是定义在某区间 D 上的函数，则称 $c \in D$ 为 f 的驻点 (critical number)，当且仅当满足下列条件之一：
 - $f'(c) = 0$
 - $f'(c)$ 不存在
- 定理：设 f 是定义在某区间上的连续函数， c 是 f 的一个驻点。则有：
 - 若在 $x < c$ 时 $f'(x) > 0$ ，而在 $x > c$ 时 $f'(x) < 0$ ，则 $f(c)$ 是 f 的绝对最大值
 - 若在 $x < c$ 时 $f'(x) < 0$ ，而在 $x > c$ 时 $f'(x) > 0$ ，则 $f(c)$ 是 f 的绝对最小值

- 若 $f'(x) < 0$ 在 $x < c$ 与 $x > c$ 均成立, 或 $f'(x) > 0$ 在 $x < c$ 与 $x > c$ 均成立, 则 f 在 c 处不能取到绝对最大值和绝对最小值。

• 定理: 二阶导数判别: 设函数 $f(x)$ 在点 $x = c$ 的某邻域内**两次可导**, 且满足 $f'(c) = 0$, 则:

- 若 $f''(c) < 0$, 则 $x = c$ 是函数 f 的局部最大值点
- 若 $f''(c) > 0$, 则 $x = c$ 是函数 f 的局部最小值点
- 若 $f''(c) = 0$, 并且在 c 附近 $f'(x)$ 的符号没有改变则 $x = c$ 是一个拐点

• 进一步讨论高阶的情况: 设函数 $f(x)$ 在某开区间内可导, 且满足:

$$f^{(k)}(c) = 0 \quad \text{对所有} \quad k = 1, 2, \dots, n-1$$

且 $f^{(n)}(c) \neq 0$, 那么:

- 若 n 为偶数:
 - 若 $f^{(n)}(c) > 0$, 则 $x = c$ 是 f 的局部最小值
 - 若 $f^{(n)}(c) < 0$, 则 $x = c$ 是 f 的局部最大值
- 若 n 为奇数, 则 f 在 $x = c$ 处没有局部最大值和局部最小值

• 补充内容: 关于极值点、拐点、驻点

◦ 极值点:

定义: $y = f(x)$ 在点 x_0 的某邻域内有定义, 如果对该邻域内任何 x , 恒有 $f(x) \leq f(x_0)$ (或者 $f(x) \geq f(x_0)$), 称 x_0 为 $f(x)$ 的一个极大值点 (或者极小值点), 称 $f(x_0)$ 为 $f(x)$ 的极大值 (或者极小值)。

综上所述, 极值点关键在于:

- 研究对象是一个**有定义的区间** $(x_0 - \xi, x_0 + \xi)$, 即 f 在去心邻域 $U(x_0)$ 和 x_0 都有定义
- 比较的方法, 是用去心邻域的函数值和 x_0 处的函数值相比较, 比较 $f(x_0)$ 和 $f(x)$ 。

◦ 驻点:

定义: 驻点在微积分中是指函数在一点处的一阶导数为零, 该点即函数的驻点。即驻点的关键在于一阶导数为0。

◦ 极值点和驻点的关系: 极值点可能是驻点, 驻点也可能是极值点

当 $f(x) = x^3$ 时, $f'(0) = 0, f(0 - \delta) < f(0) < f(0 + \delta)$, 此时 $x = 0$ 是驻点, 但并不是极值点。

当 $f(x) = |x|$ 时, $f'(0)$ 不存在, $f(0) < f(0 - \delta), f(0) < f(0 + \delta)$, 此时 $x = 0$ 是极值点, 但并不是驻点

当 $f(x) = x^2$ 时, $f'(0) = 0, f(0) < f(0 + \delta), f(0) < f(0 - \delta)$, 此时 $x = 0$ 是驻点, 同时也是极值点

通过以上对比我们可以知道:

- 驻点**要求一阶导数可导且导数值为0**。
- 极大值点**要求** $f(x_0) \geq f(x) \quad x \in \dot{U}(x_0, \xi_0)$, **并没有对这点导数提出要求。极小值同理。**
- 二者没有绝对的关系**

◦ 函数的保号性:

- 极限推区间:

$$\text{设} \quad \lim_{x \rightarrow x_0} f(x) = A$$

如果 $A > 0$ 那么 $\exists \xi \quad x \in \dot{U}(x_0, \xi)$
 $f(x) > 0$

即若一个函数某点极限大于0 (或小于0), 那么恒定有一个去心邻域大于0 (或小于0)。

- 区间推极限:

$$\text{设 } \lim_{x \rightarrow x_0} f(x) = A$$

$$\text{如果 } \exists \xi \quad x \in \dot{U}(x_0, \xi) \quad f(x) \geq 0$$

$$\text{那么 } A \geq 0$$

某点去心邻域非负（非正），我就知道这个点的极限肯定非负（非正）。

- 注意：极值点的定义只要求 $f(x_0) \geq f(x)$ $x \in \dot{U}(x_0, \xi)$ ，并没有对导数提出要求。但是我们通常说“求函数极值点则令一阶导数 = 0”，其实是建立在“某点可导”的假设前提，而大多数情况我们碰到的都是可导函数，所以这种做法被广泛接纳。在假设前提下（这个点可导，即上文中 $f(x) = x^2$ 的 $x = 0$ 处），这种说法方法是正确的，但是脱离了这个前提（如果这点不可导 $f(x) = |x|$ 的 $x = 0$ 处）这种说法并不全面。

- 极值点的必要条件：

- 证明：为什么极值点只能出现在 $f'(x) = 0$

若这一点可导，我们要证明如果 $f'(x_0) \neq 0$ ，那么 x_0 一定不是极值点。

反证法：不妨设 x_0 是 $f(x)$ 的极大值点，由极大值点的定义 x_0 的某个去心邻域 (x_0, δ) 上 $f(x)$ 有定义，且满足

$$f(x) \leq f(x_0)$$

于是当 $x < x_0$ 时，有 $\frac{f(x) - f(x_0)}{x - x_0} \geq 0$ ；当 $x > x_0$ 时，有 $\frac{f(x) - f(x_0)}{x - x_0} \leq 0$ ，

因为 $f(x)$ 在 x_0 可导，所以 $f'(x_0) = f'_-(x_0) = f'_+(x_0)$ ，由于

$$f'_-(x_0) = \lim_{x \rightarrow x_0} \frac{f(x) - f(x_0)}{x - x_0} \geq 0,$$

$$f'_+(x_0) = \lim_{x \rightarrow x_0} \frac{f(x) - f(x_0)}{x - x_0} \leq 0$$

因此，

$$f'(x_0) = 0$$

同理可证， x_0 为极小值点的情况。

综上所述： $x = x_0$ 为极值点的必要条件是 $f'(x_0) = 0$ 或 $f'(x_0)$ 不存在

- 极值点的充分条件：

- 极值的第一充分条件：设函数 $f(x)$ 在 x_0 处连续，且在 x_0 的某去心邻域 $U(x_0, \delta)$ 可导

- 若 $x \in (x_0 - \delta, x_0)$ 时， $f'(x) > 0$ ，而 $x \in (x_0, x_0 + \delta)$ 时， $f'(x) < 0$ ，则 $f(x)$ 在 x_0 处取得极大值
- 若 $x \in (x_0 - \delta, x_0)$ 时， $f'(x) < 0$ ，而 $x \in (x_0, x_0 + \delta)$ 时， $f'(x) > 0$ ，则 $f(x)$ 在 x_0 处取得极小值
- 若 $x \in U(x_0, \delta)$ 时， $f'(x)$ 的符号保持不变，则 $f(x)$ 在 x_0 处没有极值

证明：

已知若 $x \in (x_0 - \delta, x_0)$ 时， $f'(x) > 0$ ，而 $x \in (x_0, x_0 + \delta)$ 时， $f'(x) < 0$ ， $f(x)$ 在 $x = x_0$ 连续

任取 $x_1 \in (x_0 - \delta, x_0)$ ，因为点 x_1, x_0 都连续并且可导，所以我们使用拉格朗日中值定理可以得到：

$$f(x_1) - f(x_0) = (x_1 - x_0)f'(\eta) < 0 \Rightarrow f(x_1) < f(x_0)$$

同理，任取 $x_2 \in (x_0, x_0 + \delta)$ ，可以得到：

$$f(x_2) - f(x_0) = (x_2 - x_0)f'(\eta) < 0 \Rightarrow f(x_2) < f(x_0)$$

所以对于 $\forall x \in U(x_0, \delta)$ 都有 $f(x) < f(x_0)$

■ 极值的第二充分条件：设函数 $f(x)$ 在 x_0 处具有二阶导数且 $f'(x_0) = 0, f''(x_0) \neq 0$ ，则有：

1. 当 $f''(x_0) < 0$ 时，函数 $f(x)$ 在 x_0 处取得极大值
2. 当 $f''(x_0) > 0$ 时，函数 $f(x)$ 在 x_0 处取得极小值

■ 总结上述第一、第二充分条件：如果函数 $f(x)$ 在所讨论的区间连续，除了个别点之外处处可导，那么就可以按照下列步骤来求 $f(x)$ 在该区间的极值点和对应的极值：

1. 求出导数 $f'(x)$
2. 求出 $f(x)$ 的所有驻点和不可导点
3. 考察 $f'(x)$ 的符号在每个驻点或者不可导点的左右邻近清醒，以确定该点是否为极值点，如果是极值点，进一步确定是极大值点还是极小值点。

■ 极值的第三充分条件：设函数 $f(x)$ 在某邻域内存在直到 $(n-1)$ 阶的导数，且 $f^{(n)}(x_0)$ 存在，若 $f'(x_0) = f''(x_0) = \cdots = f^{(n-1)}(x_0) = 0, f^{(n)}(x_0) \neq 0$ ，则有：

1. 当 n 为偶数时：
 - 当 $f^{(n)}(x_0) > 0$ ， x_0 是极小值点
 - 当 $f^{(n)}(x_0) < 0$ ， x_0 是极大值点
2. 当 n 为奇数时， x_0 不是极值点

证明：因为 $f'(x_0) = f''(x_0) = \cdots = f^{(n-1)}(x_0) = 0, f^{(n)}(x_0) \neq 0$ ，使用泰勒展开，我们只需要研究：

$$f(x) - f(x_0) = \frac{f^{(n)}(x_0) + \alpha}{n!} (x - x_0)^n + o((x - x_0)^n)$$

引理：若 α 是 $x \rightarrow x_0$ 的无穷小，则 $[o(\alpha) + \alpha]$ 与 α 在去心邻域 $U(x_0, \delta)$ 同号

引理证明：因为 $\lim_{x \rightarrow x_0} \frac{o(\alpha) + \alpha}{\alpha} = 1 > 0$ ，由于保号性 $\exists \delta_0$ ，当 $x \in U(x_0, \delta_0)$ 时， $\frac{o(\alpha) + \alpha}{\alpha} > 0$ ，证毕。

显然 $\frac{f^{(n)}(x_0) + \alpha}{n!} (x - x_0)^n$ 是 $x \rightarrow x_0$ 的无穷小， $o((x - x_0)^n)$ 是 $x \rightarrow x_0$ 的高阶无穷小，那

么一定存在一个去心邻域 $U(x_0, \delta_0)$ ，有 $\frac{f^{(n)}(x_0) + \alpha}{n!} (x - x_0)^n + o((x - x_0)^n)$ 的符号和 $\frac{f^{(n)}(x_0) + \alpha}{n!} (x - x_0)^n$ 相同

对于 $x \in U(x_0, \delta_0)$ ：

若 n 为偶数， $f^{(n)}(x) > 0$ ，则 $f(x) - f(x_0) > 0 \Rightarrow$ 极小值；

若 n 为偶数， $f^{(n)}(x) < 0$ ，则 $f(x) - f(x_0) < 0 \Rightarrow$ 极大值；

若 n 为奇数， $f^{(n)}(x) > 0$

当 $x \in (x_0, x_0 + \delta_0)$ 时， $f(x) - f(x_0) > 0$ ；当 $x \in (x_0 - \delta_0, x_0)$ 时， $f(x) - f(x_0) < 0$ ；无极值

若 n 为奇数， $f^{(n)}(x) < 0$

当 $x \in (x_0, x_0 + \delta_0)$ 时， $f(x) - f(x_0) < 0$ ；当 $x \in (x_0 - \delta_0, x_0)$ 时， $f(x) - f(x_0) > 0$ ；无极值

证明完毕

○ 拐点：

■ 定义：一般地，设 $y = f(x)$ 在区间 I 上连续， x_0 是区间 I 内的点，如果曲线 $y = f(x)$ 在经过点 $(x_0, f(x_0))$ 时，曲线的凹凸性变了，那么就称点 $(x_0, f(x_0))$ 为这个曲线的拐点。

■ 凹凸性的定义：设函数 $y = f(x)$ 在区间 $[a, b]$ 上二阶可导，则

若在 (a, b) 内有 $f''(x) > 0$ ，则 $f(x)$ 在 $[a, b]$ 上的图形是凸的；

若在 (a, b) 内有 $f''(x) < 0$ ，则 $f(x)$ 在 $[a, b]$ 上的图形是凹的。

- 凹凸性的严格定义：

凸：如果对于函数 f 的任意两点 x_1, x_2 和任意 λ 满足 $0 \leq \lambda \leq 1$ 都有

$$f(\lambda x_1 + (1 - \lambda)x_2) \leq \lambda f(x_1) + (1 - \lambda)f(x_2)$$

这意味着函数的图形在任意两点间的线段始终位于或者刚好在函数图形之上。

严格凸：如果对于函数 f 的任意两点 x_1, x_2 和任意 λ 满足 $0 < \lambda < 1$ 都有

$$f(\lambda x_1 + (1 - \lambda)x_2) < \lambda f(x_1) + (1 - \lambda)f(x_2)$$

这意味着函数的图形在任意两点间的线段始终位于函数图形之上。

- 证明：当 $f''(x) \neq 0$ 时，它一定不是函数的拐点

如果 (x_0, y_0) 是拐点，且去心邻域二阶可导，不妨令

$$x \in (x_0 - \delta_0, x_0), f''(x) < 0; x \in (x_0, x_0 + \delta_0), f''(x) > 0$$

则 $f'(x)$ 在 $x \in (x_0 - \delta_0, x_0)$ 单调递减；则 $f'(x)$ 在 $x \in (x_0, x_0 + \delta_0)$ 单调递增。

由极值的第一充分条件， $f'(x_0)$ 是极小值点，再有费马引理，必有 $f''(x_0) = 0$ ，这样就说明了在二阶可导时：

如果 (x_0, y_0) 是拐点， $f''(x_0) = 0$ ；如果 $f''(x_0) \neq 0$ ， (x_0, y_0) 不是拐点。

- 拐点的必要条件：设 $y = f(x)$ 在点 x_0 处二阶可导，且点 $(x_0, f(x_0))$ 为曲线 $f(x)$ 的拐点，则 $f''(x_0) = 0$ 。

- 拐点的充分条件：

- 拐点的第二充分条件：设 $y = f(x)$ 在点 x_0 的去心邻域内二阶可导，且 $f''(x_0) = 0$ （或 $f(x)$ 在 x_0 处连续）

1. 若 $f''(x)$ 在 x_0 的左右两侧异号，则点 $(x_0, f(x_0))$ 为曲线 $y = f(x)$ 的拐点
2. 若 $f''(x)$ 在 x_0 的左右两侧同号，则点 $(x_0, f(x_0))$ 不为曲线 $y = f(x)$ 的拐点

- 拐点的第二充分条件：设 $y = f(x)$ 在点 x_0 处三阶可导，且 $f''(x_0) = 0$

1. 若 $f'''(x_0) \neq 0$ ，则点 $(x_0, f(x_0))$ 为曲线 $y = f(x)$ 的拐点
2. 若 $f'''(x_0) = 0$ ，则此方法不能判定 $(x_0, f(x_0))$ 是否为曲线 $(y = f(x))$ 的拐点

- 总结上述第一、第二充分条件

1. 求 $f''(x)$
2. 令 $f''(x) = 0$ ，解出方程在区间 I 内的实根，并且求出在区间 I 内 $f''(x)$ 不存在的点
3. 对于上一步中求出的每一个实根或二阶导数不存在的点 x_0 ，检查 $f''(x)$ 在 x_0 左右两侧邻近的符号，当左右两侧符号相反时，点 $(x_0, f(x_0))$ 是拐点，当左右两侧符号同时，点 $(x_0, f(x_0))$ 不是拐点

- 拐点的第三充分条件：同极值点的第三充分条件，不再赘言。

- 总结极值点和拐点：

- 当 $f(x)$ 二阶可导时， x_0 不能同时为极值点和拐点。因为如果二阶可导且为拐点，那么去心邻域二阶导数异号，则一阶导数在这点连续，由极值的第一充分条件，知这点 $f'(x_0)$ 是极值点。那么必然去心邻域一阶导数 $f'(x)$ 同号，所以不是极值点
- 在没有其他限制的情况下，拐点和极值点身份可以同时拥有（某点不连续）

(2) 多元函数的临界点 (Critical Points)

- 临界点 (Critical Points)

对于多元函数 $f(\mathbf{x})$ ，临界点的性质可由 Hessian 矩阵的特征值决定：

- $\nabla f(\mathbf{a}) = 0$ 且 $\lambda_i(\mathbf{a}) < 0$ 对所有 i 成立，则为极大值 (maximum) ；
- $\nabla f(\mathbf{a}) = 0$ 且 $\lambda_i(\mathbf{a}) > 0$ 对所有 i 成立，则为极小值 (minimum) ；
- $\nabla f(\mathbf{a}) = 0$ 且特征值有正有负，则为鞍点 (saddle point) 。

在实际中，鞍点比极值点更常见，除非 Hessian 矩阵满足特定的正定性条件。

(3) 二次优化 (Quadratic Optimization)

- 问题形式:

$$\min_{\mathbf{x} \in \mathbb{R}^p} \mathbf{x}^\top \mathbf{A} \mathbf{x} + \mathbf{b}^\top \mathbf{x},$$

其中 $\mathbf{A} \in \mathbb{R}^{p \times p}$ 对称, $\mathbf{b} \in \mathbb{R}^p$.

令 $f(\mathbf{x}) = \mathbf{x}^\top \mathbf{A} \mathbf{x} + \mathbf{b}^\top \mathbf{x}$.

一阶条件 (First order) : 若 $\mathbf{x}^*$ 为临界点, 则

$$\left. \frac{\partial f(\mathbf{x})}{\partial \mathbf{x}^\top} \right|_{\mathbf{x}=\mathbf{x}^*} = 0 \Rightarrow 2\mathbf{A}\mathbf{x}^* + \mathbf{b} = 0$$

二阶条件 (Second order)

必要条件 (Necessary) : 若 $\mathbf{x}^*$ 是局部极小值, 则 Hessian

$$\left. \frac{\partial^2 f(\mathbf{x})}{\partial \mathbf{x} \partial \mathbf{x}^\top} \right|_{\mathbf{x}=\mathbf{x}^*}$$


是半正定的, 即 $\mathbf{A} \succcurlyeq 0$.

充分条件 (Sufficient) : 若对所有 $\mathbf{x}$, Hessian 是半正定 ($\mathbf{A} \succcurlyeq 0$), 则任何满足一阶条件的点都是全局极小值。

例:


全局最小值 **Global Minimum**

$$z = x^2 + y^2, x, y \in [-2, 2]$$



鞍点 **Saddle Point**

$$z = x^2 - y^2, [x, y] \in [-2, 2]$$



全局和局部最大值Global and Local Maxima

$$z = 2 \exp\left(-\frac{(x^2 + y^2)}{2}\right) + \exp\left(-\frac{(x-3)^2 + (y-3)^2}{4}\right), x, y \in [5, -5]$$

(4) 求函数 f 全局极大值或极小值的一般策略General Strategy for Finding Global Maximum or Minimum of f


1. **确定定义域 D** : 先明确要求优化的函数 f 的定义域 D 。对于文字应用题, 这一步尤为重要。
2. **选取闭有界子集 R** : 有时需要在 D 中选取一个闭且有界的子集 R , 并论证最优值不会出现在 R 之外 (R 也可能等于 D)。
3. **存在性保证**: 如果 f 在 R 上连续 (通常如此), 那么 $\max_R f$ 和 $\min_R f$ 必然存在, 但它们可能出现在 R 的边界上。
4. **求解内部临界点**: 在 R 内求 f 的临界点, 以缩小搜索范围, 这会给出可能的内部极大值或极小值。
5. **边界优化**: 计算 f 在 R 边界上的最大值和最小值。边界优化问题可能降维, 如果 f 有 n 个变量, 则边界优化涉及 $n-1$ 个变量。
6. **比较结果**: 将 R 内和 R 边界上的所有极大值、极小值进行比较, 得到全局极大值或极小值。

(5) 有限制的优化Optimization with Constraints

- 在无约束优化中, 我们通过令 $\nabla f = 0$ 并检查临界点处 Hessian 矩阵的特征值来找到函数 $f(x, y)$ 的极大值或极小值。
- 在有些情况下, 优化必须满足各种**约束条件**。

例: 函数 $f(x, y) = -x^2 - y^2$ 的全局最大值出现在 $(x, y) = (0, 0)$, 最大值为 0。

如果增加约束条件 $x + y = 1$ (图中为平面交线), 则可以直观看出, $f(x, y)$ 的最大值仅为 $-\frac{1}{2}$, 并且出现在 $(x, y) = (\frac{1}{2}, \frac{1}{2})$ 。



(6) 拉格朗日乘数法Lagrange Multiplier Method

- 单变量情形:

对于单变量函数 $f(x)$, 若要求在约束条件

$$g(x) = 0$$

下的极大值, 可以使用拉格朗日乘数 λ 。

定义拉格朗日函数:

$$L(x; \lambda) = f(x) + \lambda g(x)。$$

取导并令其为零:

$$\frac{df}{dx} + \lambda \frac{dg}{dx} = 0, \quad g(x) = 0$$

解法步骤:

1. 从第一式求 $x^* = x^*(\lambda)$;
2. 将 $x^*(\lambda)$ 代入第二式求 λ^* ;
3. $x^*(\lambda^*)$ 即为极值点。

- 多变量情形

考虑约束优化问题:

$$\max_{\mathbf{x}} f(\mathbf{x}) \quad \text{s.t.} \quad g_1(\mathbf{x}) = 0, \dots, g_K(\mathbf{x}) = 0,$$

其中 $\mathbf{x} \in \mathbb{R}^N$, $f, g_1, \dots, g_K$ 可微。

定义拉格朗日函数:

$$L(\mathbf{x}; \boldsymbol{\lambda}) = f(\mathbf{x}) + \sum_{k=1}^K \lambda_k g_k(\mathbf{x}) = f(\mathbf{x}) + \boldsymbol{\lambda}^\top \mathbf{g}(\mathbf{x}),$$

其中 $\boldsymbol{\lambda} = (\lambda_1, \dots, \lambda_K)^\top$,
 $\mathbf{g}(\mathbf{x}) = (g_1(\mathbf{x}), \dots, g_K(\mathbf{x}))^\top$ 。

最优性条件:

$$\nabla_{\mathbf{x}, \boldsymbol{\lambda}} L(\mathbf{x}; \boldsymbol{\lambda}) = 0 \quad \Longleftrightarrow \quad \begin{cases} \nabla f(\mathbf{x}) + \sum_{k=1}^K \lambda_k \nabla g_k(\mathbf{x}) = 0, \\ g_k(\mathbf{x}) = 0, \quad k = 1, \dots, K. \end{cases}$$

解法步骤:

1. 从 $\nabla f(\mathbf{x}) + \sum_{k=1}^K \lambda_k \nabla g_k(\mathbf{x}) = 0$ 解 $\mathbf{x}^*(\boldsymbol{\lambda})$;
2. 从 $g(\mathbf{x}^*(\boldsymbol{\lambda})) = 0$ 解 $\boldsymbol{\lambda}^*$;
3. $\mathbf{x}^*(\boldsymbol{\lambda}^*)$ 即为极值点。

例: 投资组合优化

假设双资产投资组合 (x_1, x_2) 的期望收益率和方差分别为

$$\mu = x_1 \mu_1 + x_2 \mu_2$$

$$\sigma^2 = x_1^2 \sigma_1^2 + 2x_1 x_2 \rho_{12} \sigma_1 \sigma_2 + x_2^2 \sigma_2^2$$

其中, μ_1, μ_2 分别为两种资产的期望收益率, σ_1^2, σ_2^2 分别为方差, $\rho_{12} \sigma_1 \sigma_2$ 为两资产的协方差。

我们的目标是在给定收益率 $\mu = m$ 的情况下, 最小化组合的方差 σ^2 。约束条件为:

$$\begin{aligned} \mu &= m, \\ x_1 + x_2 &= 1. \end{aligned}$$

构造拉格朗日函数:

$$L = x_1^2 \sigma_1^2 + 2x_1 x_2 \rho_{12} \sigma_1 \sigma_2 + x_2^2 \sigma_2^2 + \lambda_1 (x_1 \mu_1 + x_2 \mu_2 - m) + \lambda_2 (x_1 + x_2 - 1)$$

求解:

对 $x_1, x_2, \lambda_1, \lambda_2$ 求偏导, 并令其为零:

$$\nabla L = 0$$

得到四元一次方程组。可写成矩阵形式:

$$\begin{bmatrix} 2\sigma_1^2 & 2\rho_{12}\sigma_1\sigma_2 & \mu_1 & 1 \\ 2\rho_{12}\sigma_1\sigma_2 & 2\sigma_2^2 & \mu_2 & 1 \\ \mu_1 & \mu_2 & 0 & 0 \\ 1 & 1 & 0 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \lambda_1 \\ \lambda_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ m \\ 1 \end{bmatrix}$$

显式解:

定义

$$\Sigma = \begin{bmatrix} \sigma_1^2 & \rho_{12}\sigma_1\sigma_2 \\ \rho_{12}\sigma_1\sigma_2 & \sigma_2^2 \end{bmatrix}, \quad \mu = \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix}$$
$$a = \mu^T \Sigma^{-1} \mu, \quad b = \mathbf{1}^T \Sigma^{-1} \mu, \quad c = \mathbf{1}^T \Sigma^{-1} \mathbf{1}.$$

则最优权重为:

$$x^* = \frac{1}{ac - b^2} \Sigma^{-1} [(cm - b)\mu + (a - bm)\mathbf{1}]$$

数值例: 若 $\mu_1 = 0.04, \mu_2 = 0.08, \rho_{12} = 0.8, \sigma_1 = 0.02, \sigma_2 = 0.06$, 可代入矩阵方程求得:

$$x_1^* = 2.0 - 25.0m, \quad x_2^* = -1.0 + 25.0m,$$

最小方差为:

$$\sigma^2 = 0.0004(2 - 25m)^2 + 0.00192(2 - 25m)(-1 + 25m) + 0.0036(-1 + 25m)^2$$

- 补充: 关于拉格朗日乘数法和影子价格
 - 假设有一个优化问题如下:

$$\begin{aligned} & \max / \min && f(x_1, x_2, \dots, x_n) \\ & s. t. && g_1(x_1, x_2, \dots, x_n) = c_1, \\ & && g_2(x_1, x_2, \dots, x_n) = c_2, \\ & \dots && g_m(x_1, x_2, \dots, x_n) = c_m, \end{aligned}$$

其中, 函数 $f, g_1, g_2, \dots, g_m$ 都是可导的, $c_1, c_2, \dots, c_m \in R$ 都是常数

定义拉格朗日函数 (Lagrangian) 为:

$$L(x_1, \dots, x_n, \lambda_1, \dots, \lambda_m) = f(x_1, \dots, x_n) + \sum_{j=1}^m \lambda_j (c_j - g_j(x_1, \dots, x_n))$$

若 $f(x_1^0, x_2^0, \dots, x_n^0)$ 是该优化问题的最优解, 则必定存在 $\lambda_1^0, \dots, \lambda_m^0$, 使得:

$$\frac{\partial L}{\partial x_i}(x_1^0, \dots, x_n^0, \lambda_1^0, \dots, \lambda_m^0) = 0, \quad \text{对于 } i = 1, 2, \dots, n$$

以及

$$\frac{\partial L}{\partial \lambda_j}(x_1^0, \dots, x_n^0, \lambda_1^0, \dots, \lambda_m^0) = 0, \quad \text{对于 } j = 1, 2, \dots, m$$

根据 **Weierstrass 定理**, 如果 f 是连续函数, 并且 (x, y) 的定义域是闭且有界的, 那么 f 保证存在最大值。

考虑两个变量 $x, y \in \mathbb{R}$, 我们希望最大化目标函数 $f(x, y)$, 但受到一个约束条件 $g(x, y) = c$ 。形式化地, 我们有:

$$\max f(x, y) \quad \text{s.t.} \quad g(x, y) = c$$

其中函数 f 和 g 可微, c 为常数。

假设我们可以通过约束条件求得一个函数 $y = h(x)$, 使得: $g(x, h(x)) = c$

那么原本带约束的最优化问题可以转化为单变量的无约束最优化问题: $\max f(x, h(x))$

因此在最优解 x^* 处, 我们有:

$$\frac{d}{dx} f(x, h(x)) = \frac{\partial f}{\partial x}(x, h(x)) + \frac{\partial f}{\partial y}(x, h(x)) \cdot \frac{dh}{dx}(x) = 0$$

为了求出 $\frac{dh}{dx}$, 可以对约束 $g(x, h(x)) = c$ 两边对 x 求导, 得到:

$$\frac{d}{dx} g(x, h(x)) = \frac{\partial g}{\partial x}(x, h(x)) + \frac{\partial g}{\partial y}(x, h(x)) \cdot \frac{dh}{dx}(x) = 0$$


解得:

$$\frac{dh}{dx}(x) = -\frac{\partial g / \partial x}{\partial g / \partial y}$$

将其代入最优条件得:

$$\frac{\partial f}{\partial x}(x, h(x)) + \frac{\partial f}{\partial y}(x, h(x)) \cdot \left(-\frac{\partial g / \partial x}{\partial g / \partial y} \right) = 0 \Rightarrow \frac{\partial f / \partial x}{\partial f / \partial y} = \frac{\partial g / \partial x}{\partial g / \partial y}$$

这表明最优处目标函数的等高线与约束函数的曲线相切。



考虑如下优化问题:

$$\max f(x, y) \quad \text{subject to} \quad g(x, y) = c$$

其中 f 与 g 可微, $c \in \mathbb{R}$ 为常数。定义拉格朗日函数为:

$$L(x, y, \lambda) = f(x, y) + \lambda(c - g(x, y))$$

若 (x^*, y^*) 是最优解, 则存在 λ^* 使得:

$$\frac{\partial L}{\partial x}(x^*, y^*, \lambda^*) = 0, \quad \frac{\partial L}{\partial y}(x^*, y^*, \lambda^*) = 0, \quad \frac{\partial L}{\partial \lambda}(x^*, y^*, \lambda^*) = 0$$

即：

$$\begin{aligned} \frac{\partial f}{\partial x}(x^*, y^*) - \lambda^* \frac{\partial g}{\partial x}(x^*, y^*) &= 0 \\ \frac{\partial f}{\partial y}(x^*, y^*) - \lambda^* \frac{\partial g}{\partial y}(x^*, y^*) &= 0 \\ g(x^*, y^*) &= c \end{aligned}$$

由前两式可得：

$$\lambda^* = \frac{\partial f / \partial x}{\partial g / \partial x} = \frac{\partial f / \partial y}{\partial g / \partial y}$$

这说明拉格朗日乘子 λ^* 等价于切线条件中两函数等高线斜率相等的表达。

- 影子价格的定义：定义 $F(c) = f(x^*(c), y^*(c))$ ，表示在约束值为 c 时最优目标函数的值。对 F 求导：

$$\frac{dF}{dc} = \frac{\partial f}{\partial x} \cdot \frac{dx^*}{dc} + \frac{\partial f}{\partial y} \cdot \frac{dy^*}{dc}$$

由拉格朗日乘子法得：

$$\frac{\partial f}{\partial x} = \lambda^* \frac{\partial g}{\partial x}, \quad \frac{\partial f}{\partial y} = \lambda^* \frac{\partial g}{\partial y}$$

代入上式：

$$\frac{dF}{dc} = \lambda^* \left(\frac{\partial g}{\partial x} \frac{dx^*}{dc} + \frac{\partial g}{\partial y} \frac{dy^*}{dc} \right)$$

对约束 $g(x^*(c), y^*(c)) = c$ 两边求导：

$$\text{对约束 } g(x^*(c), y^*(c)) = c \text{ 两边求导：}$$

因此有：

$$\frac{dF}{dc} = \lambda^*$$

结论： λ^* 表示当约束放松一个单位时，最优目标函数值 f 上升的速率，即约束的影子价格（Shadow Price）。

例：最大效用函数为 $U(x, y) = xy + 3x$ ，约束条件为： $4x + 3y = 40$ ， $x, y \geq 0$

定义拉格朗日函数：

$$\mathcal{L}(x, y, \lambda) = xy + 3x + \lambda(40 - 4x - 3y)$$

求一阶偏导并令其等于零：

$$\frac{\partial \mathcal{L}}{\partial x} = y + 3 - 4\lambda = 0 \quad (1)$$

$$\frac{\partial \mathcal{L}}{\partial y} = x - 3\lambda = 0 \quad (2)$$

$$\frac{\partial \mathcal{L}}{\partial \lambda} = 40 - 4x - 3y = 0 \quad (3)$$

由(1)与(2)得到：

$$\frac{y+3}{4} = \frac{x}{3} \Rightarrow 3(y+3) = 4x \Rightarrow 3y+9 = 4x \quad (4)$$

将(4)代入预算约束(3)：

$$4x + 3y = 40 \Rightarrow (3y + 9) + 3y = 40 \Rightarrow 6y + 9 = 40 \Rightarrow 6y = 31 \Rightarrow y = \frac{31}{6}$$

$$x = \frac{3y + 9}{4} = \frac{3 \cdot \frac{31}{6} + 9}{4} = \frac{\frac{93}{6} + \frac{54}{6}}{4} = \frac{147}{24} = \frac{49}{8}$$

故最优解为： $x^* = \frac{49}{8}$ ， $y^* = \frac{31}{6}$

对应的最大效用为：

$$U\left(\frac{49}{8}, \frac{31}{6}\right) = \frac{49}{8} \cdot \frac{31}{6} + 3 \cdot \frac{49}{8} = \frac{1519}{48} + \frac{147}{8} = \frac{2401}{48}$$


7.附录：可视化 Appendix: Visualization

- 单变量标量函数的可视化：

考虑函数：

$$f(x) = \frac{e^x}{e^x + 1}$$

其函数图像如下所示：



该函数呈典型的 S 型曲线（逻辑函数形式）：当 x 很小时， $f(x) \approx 0$ ；当 x 很大时， $f(x) \approx 1$ ；在 $x = 0$ 附近，函数值迅速上升。

- 多变量标量函数的可视化：


考虑函数Gumbel copula：

$$C_G(u, v) = \exp \left\{ - \left[(-\ln u)^\delta + (-\ln v)^\delta \right]^{1/\delta} \right\}$$


其中 u 和 v 为变量，参数 $\delta = 2$ 。

常见的可视化方法包括：曲面图（透视图）；等高线图；热力图；曲面与等高线的组合图。


Gumbel Copula透视图：




Gumbel Copula等高线图：



Gumbel Copula热力图:



Gumbel Copula曲面与等高线的组合图



- 多变量向量函数的可视化方法

对于向量函数:

$$\mathbf{F}(x, y) = \begin{bmatrix} x^3y + 3xy^3 \\ x^4 + 2x^2y^2 + y^4 \end{bmatrix}$$

其中 x 和 y 是变量, 在每个点 (x, y) 上都有一个向量。

我们可以使用以下方法来可视化向量场: 箭矢图 (quiver plot) 或者流线图 (stream plot)。

