

第二讲 特征值与特征向量

1.内积与正交

(1) 内积Inner Product

- 定义：设 $u, v \in V$ ，它们的内积记作 $(u, v) \in \mathbb{R}$ 或 $\langle u, v \rangle \in \mathbb{R}$ 。在实数域上的向量空间中，内积必须满足以下四条性质（对任意 $u, v, w \in V$ ，以及标量 $\lambda \in \mathbb{R}$ ）：
 - 对称性 (Symmetry) : $\langle u, v \rangle = \langle v, u \rangle$
 - 数量乘法的线性性 (Linearity with respect to scalar multiplication) :
 $\langle \lambda u, v \rangle = \lambda \langle u, v \rangle$
 - 向量加法的线性性 (Linearity with respect to vector addition) :
 $\langle u + v, w \rangle = \langle u, w \rangle + \langle v, w \rangle$
 - 正定性 (Positivity) : $\langle u, u \rangle \geq 0$ ，且当且仅当 $u = 0$ 时， $\langle u, u \rangle = 0$
- 如果一个向量空间配备了一个满足上述四条性质的内积，则称其为一个内积空间。
- 欧几里得空间中的标准内积可以写为矩阵乘法：

$$\langle x, y \rangle = x^T y$$

(2) 正交归一性Orthonormality

- 正交性 (Orthogonality) 定义：若两个向量 $u, v \in V$ 满足 $\langle u, v \rangle = 0$ ，则称它们是正交的。
- 规范化 (Normalization) 定义：若一个向量 $u \in V$ 满足 $\langle u, u \rangle = 1$ ，则称它是已规范化的。
- 正交归一性 (Orthonormality) 定义：若一组向量 $u_1, u_2, \dots, u_n$ 构成 V 的一组基，并且每个向量都已规范化，且两两正交，则称该组基为**正交归一基** (Orthonormal Basis)。

对于正交归一基 $U = u_1, u_2, \dots, u_n$ ，任意向量 $v \in V$ 可表示为：

$$v = v_1 u_1 + v_2 u_2 + \dots + v_n u_n, \quad \text{其中 } v_i = \langle v, u_i \rangle, \quad i = 1, \dots, n$$

通过低维度向高维度理解，标准直角坐标系相当于， $v_i = \langle v, u_i \rangle$ 就是把向量分解到各个坐标轴上的过程。

(3) 点积Dot Product

- 定义：设 $v, w \in V$ ，在一组正交归一基 $u_1, u_2, \dots, u_n$ 下，它们可表示为：

$$v = (v_1, v_2, \dots, v_n)^T = v_1 u_1 + v_2 u_2 + \dots + v_n u_n$$

$$w = (w_1, w_2, \dots, w_n)^T = w_1 u_1 + w_2 u_2 + \dots + w_n u_n$$

则它们的点积为：

$$v \cdot w = v_1 w_1 + v_2 w_2 + \dots + v_n w_n = \sum_{i=1}^n v_i w_i$$

点积也可以表示为矩阵乘法的形式： $v^T w$ ，其中 $v^T = [v_1, v_2, \dots, v_n]$ 为 $1 \times n$ 向量，

$w = \begin{bmatrix} w_1 \\ w_2 \\ \vdots \\ w_n \end{bmatrix}$ 为 $n \times 1$ 向量。

例：（标准正交基下的点积）

设我们有一组标准正交归一基：

$$u_1 = (1, 0, 0)^T, u_2 = (0, 1, 0)^T, u_3 = (0, 0, 1)^T$$

$$\text{向量 } v = (1, 2, 3)^T, w = (4, 5, 6)^T$$

在该基下, v 和 w 的分量分别为:

$$v_1 = 1, v_2 = 2, v_3 = 3, w_1 = 4, w_2 = 5, w_3 = 6$$

因此它们的点积为:

$$\langle v, w \rangle = v_1 w_1 + v_2 w_2 + v_3 w_3 = 4 + 10 + 18 = 32$$

例: (非标准正交归一基下的点积)

设另一组正交归一基为:

$$u_1 = \left(\frac{1}{2}, -\frac{\sqrt{2}}{2}, \frac{1}{2} \right)^T, u_2 = \left(\frac{1}{2}, \frac{\sqrt{2}}{2}, \frac{1}{2} \right)^T, u_3 = \left(\frac{\sqrt{2}}{2}, 0, -\frac{\sqrt{2}}{2} \right)^T$$

向量仍为:

$$v = (1, 2, 3)^T, w = (4, 5, 6)^T$$

通过点积计算出它们在该基下的分量:

$$\begin{aligned} v_1 &= v \cdot u_1 = 2 - \sqrt{2}, & v_2 &= v \cdot u_2 = 2 + \sqrt{2}, & v_3 &= v \cdot u_3 = -\sqrt{2} \\ w_1 &= w \cdot u_1 = 5 - \frac{\sqrt{5}}{2}, & w_2 &= w \cdot u_2 = 5 + \frac{\sqrt{5}}{2}, & w_3 &= w \cdot u_3 = -\sqrt{2} \end{aligned}$$

则点积为:

$$\langle v, w \rangle = v_1 w_1 + v_2 w_2 + v_3 w_3 = 32$$

结论: 即使更换了基底, 向量的点积保持不变 (只要基底是正交归一的)。

(4) 范数 (Norm)、夹角 (Angle)、投影 (Projection)

- 范数: 向量 $v \in \mathbb{R}^N$ 的范数 (也称长度) 定义为:

$$\|v\| = \sqrt{v \cdot v} = \sqrt{v_1^2 + v_2^2 + \dots + v_N^2}$$

- 两个向量的夹角: 设 v, w 为非零向量, 它们之间的夹角 θ 满足:

$$\cos \theta = \frac{v \cdot w}{\|v\| \|w\|}$$

当且仅当 $v \cdot w = 0$ 时, v 与 w 正交 (perpendicular 或 orthogonal)。

- 投影 (Projection): 向量 v 在向量 w 上的投影定义为:

$$P_w v = \frac{v \cdot w}{w \cdot w} w = \frac{v^T w}{w^T w} w$$

余向量 $v^\perp := v - P_w v$ 与 w 正交, 即:

$$v^\perp \perp w$$

也即:

$$\langle v^\perp, w \rangle = 0$$

给定两个向量 v 和 w , 我们可以将 v 拆分为两个正交部分:

$$v = P_w v + v^\perp$$

其中:

- $P_w v$ 是 v 在 w 上的投影, 方向与 w 相同;
- $v^\perp$ 是“余向量”, 即 v 减去其在 w 上的投影的剩余部分, 它与 w 正交 (垂直)。

(5) Gram-Schmidt 正交化过程 (Gram-Schmidt Process)

- Gram-Schmidt (GS) 过程是一种将一组线性无关向量转换为一组两两正交向量 (最终得到正交归一基) 的算法。

目的:

- 输入: K 个线性无关向量 $v_1, v_2, \dots, v_K$;
- 输出:
 - 正交集合 $w_1, w_2, \dots, w_K$;
 - 正交归一集合 $u_1, u_2, \dots, u_K$, 其中 $u_k = \frac{w_k}{\|w_k\|}$ 。

过程:

1. 初始化第一个向量:

$$w_1 = v_1, \quad u_1 = \frac{w_1}{\|w_1\|}$$

2. 对于 $k = 2, 3, \dots, K$, 执行以下步骤:

$$w_k = v_k - \sum_{j=1}^{k-1} P_{w_j} v_k = v_k - \sum_{j=1}^{k-1} \frac{\langle v_k, w_j \rangle}{\langle w_j, w_j \rangle} w_j$$

$$u_k = \frac{w_k}{\|w_k\|}$$

最终:

- $w_1, \dots, w_K$ 是一组正交向量;
- $u_1, \dots, u_K$ 是一组**正交归一向量** (即正交归一基)。

例: 验证以下 Gram-Schmidt 构造出的向量:

- $w_1 = v_1$
- $w_2 = v_2 - P_{w_1} v_2$
- $w_3 = v_3 - P_{w_1} v_3 - P_{w_2} v_3$

彼此正交。即要验证:

$$\langle w_1, w_2 \rangle = \langle w_1, w_3 \rangle = \langle w_2, w_3 \rangle = 0$$

证明:

1. 证明 $\langle w_1, w_2 \rangle = 0$

$$\begin{aligned} \langle w_1, w_2 \rangle &= \left\langle w_1, v_2 - \frac{\langle v_2, w_1 \rangle}{\langle w_1, w_1 \rangle} w_1 \right\rangle \\ &= \langle w_1, v_2 \rangle - \frac{\langle v_2, w_1 \rangle}{\langle w_1, w_1 \rangle} \langle w_1, w_1 \rangle \\ &= \langle w_1, v_2 \rangle - \langle w_1, v_2 \rangle = 0 \end{aligned}$$

2. 证明 $\langle w_1, w_3 \rangle = 0$

$$\begin{aligned}\langle w_1, w_3 \rangle &= \left\langle w_1, v_3 - \frac{\langle v_3, w_1 \rangle}{\langle w_1, w_1 \rangle} w_1 - \frac{\langle v_3, w_2 \rangle}{\langle w_2, w_2 \rangle} w_2 \right\rangle \\&= \langle w_1, v_3 \rangle - \frac{\langle v_3, w_1 \rangle}{\langle w_1, w_1 \rangle} \langle w_1, w_1 \rangle - \frac{\langle v_3, w_2 \rangle}{\langle w_2, w_2 \rangle} \langle w_1, w_2 \rangle \\&= \langle w_1, v_3 \rangle - \langle w_1, v_3 \rangle - 0 = 0\end{aligned}$$

3. 证明 $\langle w_2, w_3 \rangle = 0$

$$\begin{aligned}\langle w_2, w_3 \rangle &= \left\langle w_2, v_3 - \sum_{j=1}^2 \frac{\langle v_3, w_j \rangle}{\langle w_j, w_j \rangle} w_j \right\rangle \\&= \langle w_2, v_3 \rangle - \frac{\langle v_3, w_1 \rangle}{\langle w_1, w_1 \rangle} \langle w_2, w_1 \rangle - \frac{\langle v_3, w_2 \rangle}{\langle w_2, w_2 \rangle} \langle w_2, w_2 \rangle \\&= \langle w_2, v_3 \rangle - 0 - \langle v_3, w_2 \rangle = 0\end{aligned}$$

证毕。

(6) 正交变换 (Orthogonal Transformation)

- 定义：一个 $N \times N$ 的方阵 O 是正交矩阵当且仅当：

$$OO^T = O^T O = I$$

即 O 的列（或行）向量构成一组正交归一基（orthonormal basis）。

- 性质：

1. 若 $u_1, u_2, \dots, u_n$ 是向量空间 V 的一组正交归一基，且 O 是一个正交矩阵，则：

$$\{v_1, v_2, \dots, v_n\} = \{Ou_1, Ou_2, \dots, Ou_n\}$$

也是 V 的一组正交归一基。

证明：设 $v_i = Ou_i$ ，我们需证明 $\langle v_i, v_j \rangle = \delta_{ij}$ （即 v_i 与 v_j 正交归一）。（当 $i = j$ 时， $\delta_{ij} = 1$ ；当 $i \neq j$ 时， $\delta_{ij} = 0$ 。

$$\langle v_i, v_j \rangle = \langle Ou_i, Ou_j \rangle = \langle u_i, O^T Ou_j \rangle$$

由于 $O^T O = I$ ，故

$$\langle v_i, v_j \rangle = \langle u_i, u_j \rangle = \delta_{ij}$$

因此， $\{v_1, v_2, \dots, v_n\}$ 也是一组正交归一基。

2. 若 $\{u_1, u_2, \dots, u_n\}$ 与 $\{v_1, v_2, \dots, v_n\}$ 是 V 中两组正交归一基，令：

$$U = [u_1, u_2, \dots, u_n], \quad V = [v_1, v_2, \dots, v_n]$$

则存在一个正交矩阵 O ，使得：

$$V = UO$$

证明：

$$O^T O = (U^T V)^T (U^T V) = V^T U U^T V = V^T I V = V^T V = I$$

同理也可证 $OO^T = I$ ，因此 O 为正交矩阵。

- 结论：

- 若 O 为正交矩阵，则其作用于一组正交归一基后，仍是一组正交归一基；
- 任意两组正交归一基之间存在一个正交矩阵 O 使得 $V = UO$ 成立。

(7) 基变换的意义 (Relevance of Basis Transformation)

- 在金融中，我们通常用向量 $x = (x_1, x_2, \dots, x_N)$ 表示一个投资组合，其实这相当于在某一组基（如金融工具的标准基）下表示向量。进行投资组合优化时，如果选取一个合适的正交基，可以简化问题结构，从而使优化问题更易处理。

基变换：

若 $u_1, u_2, \dots, u_N$ 是原始基， $v_1, v_2, \dots, v_N$ 是新基，并且 $V = UO$ ，其中 O 为正交矩阵，则：

在新基下，同一个向量 x 可表示为：

$$y = O^T x \quad (y \text{ 是 } x \text{ 在新基下的坐标})$$

并可逆变换回原坐标：

$$x = Oy$$

- 在线性优化问题中的应用

假设我们的问题为：

$$Ax = p$$

我们左乘 O^T ，得到：

$$O^T Ax = O^T p$$

由于 $x = Oy$ ，代入得：

$$O^T AOy = O^T p \Rightarrow By = q$$

其中：

$$B = O^T AO, \quad q = O^T p$$

通过选取合适的正交矩阵 O ，使得 B 拥有更简单的结构（例如对角化、稀疏化等），可以简化求解过程。最后再由：

$$x = Oy$$

恢复原始解。

例：原始优化问题是：

$$\begin{bmatrix} 1 & -2 \\ -2 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}$$

我们通过如下正交基变换：

$$O = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \end{bmatrix}$$

在新基下，新的系数矩阵与常数向量为：

$$B = O^T A O = \begin{bmatrix} -1 & 0 \\ 0 & 3 \end{bmatrix}, \quad q = O^T p = \begin{bmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix}$$

由于 B 是对角矩阵，可以直接解得：

$$y = \begin{bmatrix} -\frac{1}{\sqrt{2}} \\ \frac{1}{3\sqrt{2}} \end{bmatrix}$$

回代至原坐标系下：

$$x = O y = \begin{bmatrix} -\frac{1}{3} \\ -\frac{2}{3} \end{bmatrix}$$

(8) 希尔伯特空间 (Hilbert Space)

- 定义：**希尔伯特空间 (Hilbert Space)** 是欧几里得空间的推广。它是带有**内积结构**的抽象向量空间，从而可以测量**长度与角度**。此外，它还具有一个关键性质：**完备性** (completeness)，即每个柯西序列都有极限存在于空间内，使得可以在其中使用微积分的方法。

希尔伯特空间可以是有限维的，也可以是无限维的。

- **有限维例子**：实数向量空间 $\mathbb{R}^N$ ，其内积为点积 $\langle v, u \rangle = v^T u$ 。
- **无限维例子**： L^2 空间，即所有满足 $\int_{-\infty}^{\infty} f(x)^2 dx < \infty$ 的实值函数 $f: \mathbb{R} \rightarrow \mathbb{R}$ ，其内积定义为：

$$\langle f, g \rangle = \int_{-\infty}^{\infty} f(x)g(x) dx$$

2.特征向量与特征值

(1) 特征值问题 (Eigenvalue Problem)

- 形式如下：

$$Ax = \lambda x$$

其中， $A \in \mathbb{R}^{N \times N}$ 是方阵； $x \in \mathbb{R}^N$ 是非零向量（特征向量）； $\lambda \in \mathbb{R}$ 是标量（特征值）。

- 注意：解不是唯一的。

若 x 是特征向量，则任意非零实数 $c \in \mathbb{R} \setminus \{0\}$ ， cx 也满足：

$$A(cx) = cAx = c\lambda x = \lambda(cx)$$

因此 cx 也是一个特征向量。

- 单位长度的规范化：

为消除非唯一性，我们通常规定特征向量为单位向量，即满足：

$$\|x\| = \sqrt{x^T x} = \sqrt{x_1^2 + x_2^2 + \cdots + x_N^2} = 1$$

在这种规范下，特征向量的解是唯一的（除符号外），因为若 x 是单位长度的解，则 $-x$ 也是。

(2) 特征值与特征向量 Eigenvalues and Eigenvectors

- 特征值问题的基本形式为：

$$Ax = \lambda x$$

其中 $A \in \mathbb{R}^{N \times N}$ 为一个实方阵， $x \in \mathbb{R}^N$ 为非零向量， $\lambda \in \mathbb{R}$ 为标量。

- 满足该方程的一组 (λ_i, x_i) 称为 A 的特征值与特征向量对。
- 对于一个 $N \times N$ 的矩阵 A ，最多有 N 个特征值-特征向量对。
- 所有特征值 $\{\lambda_i\}$ 组成 A 的谱 (spectrum)。

注意：如果 A 是非奇异的 (invertible) 即 $\det(A) \neq 0$ ，那么其所有特征值 $\lambda_i \neq 0$ 。此外，当 A 是对称矩阵 ($A = A^T$) 时，其特征向量组成一组正交基。

(3) 特征多项式与特征方程 Characteristic Polynomial and Equation

- 定义：设 $A = [a_{ij}] \in \mathbb{R}^{N \times N}$ ，则

$$f(\lambda) = \det(A - \lambda I)$$

称为 A 的特征多项式，其对应的特征方程为：

$$\det(A - \lambda I) = 0$$

性质：

- $f(\lambda)$ 是一个 N 次多项式；
- 根据 Abel 不可解定理 (Abel's Impossibility Theorem)，五次及以上的一般多项式没有封闭形式的根；
- 我们可以使用数值方法 (如 QR 分解、幂法等) 求解这些根。

(4) 求解特征值和特征向量 Computing Eigenvalues and Eigenvectors

- 矩阵的特征值和特征向量的求法：

对上式变形得到特征方程：

$$(A - \lambda I)x = 0$$

其中， I 是一个单位矩阵。解特征方程 $f(\lambda) = |A - \lambda I| = 0$ ，求出 A 的所有特征值 $\lambda_1, \lambda_2, \dots, \lambda_n$ ，其中 $f(\lambda)$ 的 r 重根对于 A 的 r 个值相同的特征值。

对于每一个特征值 λ_i ，将其代入：

$$(A - \lambda_i I)x = 0$$

解这个齐次线性方程组，得到的非零解即为对应的特征向量 (可以有无穷多个)

- 注意当特征根有重根时可能有两种情况：

首先定义两个概念：

- 代数重数 (Algebraic multiplicity)**：指 λ 作为特征多项式根的重数。
- 几何重数 (Geometric multiplicity)**：指 λ 所对应的线性无关特征向量的个数。也可以直接理解为上述的齐次线性方程组的自由空间的维数即 $n - R(A - \lambda I)$

1. 代数重数 $\neq$ 几何重数, 矩阵**不可以**对角化

例: 设矩阵:

$$A = \begin{bmatrix} -1 & 1 & 1 \\ 1 & -1 & 1 \\ -1 & 3 & -1 \end{bmatrix}$$

计算特征多项式, 得 $\lambda = 1, -2, -2$

对于 $\lambda_1 = 1$

$$A - I = \left[\begin{array}{ccc|c} -2 & 1 & 1 & 0 \\ 1 & -2 & 1 & 0 \\ -1 & 3 & -2 & 0 \end{array} \right] \Rightarrow \left[\begin{array}{ccc|c} 1 & 0 & -1 & 0 \\ 0 & 1 & -1 & 0 \\ 0 & 0 & 0 & 0 \end{array} \right]$$

把 z 作为自由变量, 故我们得到

$$\begin{bmatrix} x \\ y \\ z \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} z$$

所以 $\lambda_1 = 1$ 对应的特征向量为

$$\varepsilon_1 = \mu_1 \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}$$

其中, μ_1 可以取任意实数, 这里我们取 $\mu_1 = 1$, 得到特征向量

$$\varepsilon_1 = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}$$

对于两个重根 $\lambda_{2,3} = -2$

$$A - I = \left[\begin{array}{ccc|c} 1 & 1 & 1 & 0 \\ 1 & 1 & 1 & 0 \\ -1 & 3 & 1 & 0 \end{array} \right] \Rightarrow \left[\begin{array}{ccc|c} 1 & 1 & 1 & 0 \\ 0 & 1 & \frac{1}{2} & 0 \\ 0 & 0 & 0 & 0 \end{array} \right]$$

此时我们可以发现几何重数为 $n - R(A - I) = 3 - 2 = 1$ 与代数重数 2 不相等, 所以这种情况下矩阵**不可**对角化, 只能进行**约旦标准形 (Jordan Canonical Form)** 的分解。**这样的矩阵称为缺陷矩阵 (Defective Matrix)**, 因为它缺少足够多的线性无关特征向量。

把 z 作为自由变量, 故我们得到

$$\begin{bmatrix} x \\ y \\ z \end{bmatrix} = \begin{bmatrix} \frac{1}{2} \\ \frac{1}{2} \\ -1 \end{bmatrix} z$$

所以 $\lambda_{2,3} = -2$ 对应的特征向量为

$$\varepsilon_2 = \mu_2 \begin{bmatrix} \frac{1}{2} \\ \frac{1}{2} \\ -1 \end{bmatrix}$$

其中, μ_2 可以取任意实数, 这里我们取 $\mu_2 = 1$, 得到特征向量

$$\varepsilon_2 = \begin{bmatrix} \frac{1}{2} \\ \frac{1}{2} \\ 1 \end{bmatrix}$$

2. 代数重数=几何重数。这是最理想的情况，矩阵可以**对角化 (Diagonalizable)**

例：

设矩阵：

$$A = \begin{bmatrix} 3 & 0 & 2 \\ 1 & 5 & 1 \\ 1 & 0 & 4 \end{bmatrix}$$

计算特征多项式，得 $\lambda = 2, 5, 5$

对于 $\lambda_1 = 2$

$$A - I = \begin{bmatrix} -1 & 0 & 2 & | & 0 \\ -1 & 3 & 1 & | & 0 \\ 1 & 0 & 2 & | & 0 \end{bmatrix} \Rightarrow \begin{bmatrix} 1 & 0 & 2 & | & 0 \\ 0 & 1 & 1 & | & 0 \\ 0 & 0 & 0 & | & 0 \end{bmatrix}$$

把 z 作为自由变量，故我们得到

$$\begin{bmatrix} x \\ y \\ z \end{bmatrix} = \begin{bmatrix} 2 \\ 1 \\ -1 \end{bmatrix} z$$

所以 $\lambda_1 = 1$ 对应的特征向量为

$$\varepsilon_1 = \mu_1 \begin{bmatrix} 2 \\ 1 \\ -1 \end{bmatrix}$$

其中， μ_1 可以取任意实数，这里我们取 $\mu_1 = 1$ ，得到特征向量

$$\varepsilon_1 = \begin{bmatrix} 2 \\ 1 \\ -1 \end{bmatrix}$$

对于两个重根 $\lambda_{2,3} = -5$

$$A - I = \begin{bmatrix} -2 & 0 & 2 & | & 0 \\ -1 & 0 & 1 & | & 0 \\ 1 & 0 & -1 & | & 0 \end{bmatrix} \Rightarrow \begin{bmatrix} 1 & 0 & -1 & | & 0 \\ 0 & 0 & 0 & | & 0 \\ 0 & 0 & 0 & | & 0 \end{bmatrix}$$

此时我们可以发现几何重数为 $n - R(A - I) = 3 - 1 = 2$ 与代数重数 2 相等，所以这种情况下矩阵可以对角化。

把 y, z 作为自由变量，故我们得到

$$\begin{bmatrix} x \\ y \\ z \end{bmatrix} = \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix} z + \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} y$$

所以 $\lambda_{2,3} = 5$ 对应的特征向量为

$$\varepsilon = \mu_2 \begin{bmatrix} 1 \\ 0 \\ -1 \end{bmatrix} + \mu_3 \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}$$

其中, μ_2, μ_3 可以取任意实数, 这里我们分别取取 $\mu_1 = 1, \mu_2 = 0$ 以及 $\mu_1 = 0, \mu_2 = 1$, 得到特征向量

$$\varepsilon_2 = \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}, \varepsilon_3 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}$$

- 矩阵的迹的定义: 一个 $n \times n$ 矩阵 A 的迹 (trace) 就是 A 的对角线元素之和, 记为 $\text{tr}(A)$ 。
- 那么假设一个 $n \times n$ 矩阵 A 的特征值分别为 $\lambda_1, \lambda_2, \dots, \lambda_n$, 我们可以知道
 - $\text{tr}(A) = \lambda_1 + \lambda_2 + \dots + \lambda_n = \sum_{i=1}^n \lambda_i$
 - $\det(A) = \lambda_1 \cdot \lambda_2 \cdot \dots \cdot \lambda_n = \prod_{i=1}^n \lambda_i$

(5) 特征值与特征向量的性质 Properties of Eigenvalues and Eigenvectors

1. 若 A 是实对称矩阵, 则 A 的所有特征值均为实数。
2. 若 A, B 均为 $N \times N$ 矩阵, 且 A 可逆, 则矩阵 AB 与 BA 的特征值相同。
3. 矩阵 A 与其转置矩阵 A^T 具有相同的特征值。
4. 若 $A \in \mathbb{R}^{N \times N}$ 可逆, 且其特征值为 $\lambda_1, \lambda_2, \dots, \lambda_n$, 则 A^{-1} 的特征值为

$$\frac{1}{\lambda_1}, \frac{1}{\lambda_2}, \dots, \frac{1}{\lambda_n}.$$

5. 若 $A \in \mathbb{R}^{N \times N}$ 是对称矩阵, 且 λ_i, λ_j 是 A 的两个不同的特征值, 则对应的特征向量 x_i 和 x_j 必正交, 即

$$x_i^T x_j = 0$$

6. 行列式与特征值的关系:

$$\det(A) = \prod_{i=1}^n \lambda_i.$$

7. 若存在某个特征值 $\lambda_i = 0$, 则 $\det(A) = 0$, 矩阵 A 奇异。即不可逆。若所有特征值均非零, 则 $\det(A) \neq 0$, 矩阵 A 可逆。
8. 迹与特征值的关系:

$$\text{tr}(A) = \sum_{i=1}^n \lambda_i.$$

3. 对角化 Diagonalization

(1) 相似对角化 Similar and Diagonalization

- 首先我们先给出矩阵相似的定义: 假设 A 和 B 是两个 $n \times n$ 的方阵, 存在一个可逆矩阵 P , 使得

$$B = P^{-1}AP$$

则称矩阵 A 和 B 是相似的, 记作 $A \sim B$ 。

相似的两个矩阵有以下性质:

1. 特征值相同 (重数也相同)
2. 行列式相同

3. 迹相同

4. 秩相同

- 相似对角化的定义：一个 $n \times n$ 方阵 A 若存在可逆矩阵 P 和对角矩阵 D ，使得：

$$A = PDP^{-1}$$

则称 A 可对角化 (diagonalizable)，且 D 为 A 的相似对角矩阵。

对角化的充要条件： A 有 n 个线性无关的特征向量，即其所有特征值的几何重数之和为 n 。

- 相似对角化的步骤：

设 A 为一个 $n \times n$ 的方阵，对角化 A 的步骤如下：

- 求特征多项式： $\det(A - \lambda I) = 0$ ，解此方程得到所有特征值 $\lambda_1, \lambda_2, \dots, \lambda_k$ 及其代数重数。
- 对每个特征值 λ_i ，求解齐次线性方程组： $(A - \lambda_i I)\mathbf{x} = 0$ ，得到该特征值对应的特征向量组。
- 判断能否相似对角化：若所有特征值对应的特征向量共计有 n 个线性无关向量（即几何重数之和为 n ），则 A 可对角化。
- 构造对角化所需的矩阵：将上述 n 个线性无关的特征向量作为列向量，构成可逆矩阵 P ，即： $P = [\mathbf{v}_1 \ \mathbf{v}_2 \ \cdots \ \mathbf{v}_n]$
- 构造对应的对角矩阵 D ，其对角元为对应的特征值：

$$D = \begin{bmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_n \end{bmatrix}$$

得到对角化结果， $A = PDP^{-1}$ ，或等价地， $D = P^{-1}AP$

(2) 对称矩阵的对角化 orthogonally diagonalizable

- 在可对角化的矩阵中，有一类特殊的矩阵被称为正交矩阵。其定义为：设 $Q \in \mathbb{R}^{n \times n}$ ，若满足：

$$Q^T Q = Q Q^T = I$$

则称 Q 为正交矩阵，即 $Q^{-1} = Q^T$ 。

- 正交对角化的定义与条件：若存在正交矩阵 Q 和实对角矩阵 D ，使得：

$$A = QDQ^T$$

则称 A 可正交对角化。

注意，可正交对角化的充分必要条件是：任意实对称矩阵 A 都可以正交对角化。

- 正交对角化的步骤：设 $A \in \mathbb{R}^{n \times n}$ 是实对称矩阵，即 $A^T = A$ ，则其可正交对角化。步骤如下：
 - 验证对称性： $A^T = A$ ，若成立，则可继续进行正交对角化。
 - 求特征值：解特征方程

$$\det(A - \lambda I) = 0$$

得到所有特征值 $\lambda_1, \lambda_2, \dots, \lambda_k$ 。

- 对每个特征值 λ_i ，求解特征向量：

$$(A - \lambda_i I)\mathbf{x} = 0$$

得到特征空间的基。

4. 正交归一化特征向量:

- 这里需要重点注意特征值有重根的情况, 若几何重数等于代数重数, 则有:

$$\xi_1 = \frac{1}{\sqrt{\varepsilon_1^T \varepsilon_1}} \varepsilon_1, \xi_2 = \frac{1}{\sqrt{\varepsilon_2^T \varepsilon_2}} \varepsilon_2, \dots, \xi_n = \frac{1}{\sqrt{\varepsilon_n^T \varepsilon_n}} \varepsilon_n$$

此时的正交矩阵为 $P = [\xi_1, \xi_2, \dots, \xi_n]$

若有重根并且几何重数不等于代数重数, 那么对于单根 $\eta_i = \varepsilon_i$, 对于几何重数不等于代数重数的重根, 进行 Gram-Schmidt 正交化, 方式如下:

$$\begin{aligned} \eta_i &= \varepsilon_i, \\ \eta_{i+1} &= \varepsilon_{i+1} - \left(\frac{\varepsilon_{i+1}^T \eta_i}{\eta_i^T \eta_i} \right) \eta_i, \\ \eta_{i+2} &= \varepsilon_{i+2} - \left(\frac{\varepsilon_{i+2}^T \eta_i}{\eta_i^T \eta_i} \right) \eta_i - \left(\frac{\varepsilon_{i+2}^T \eta_{i+1}}{\eta_{i+1}^T \eta_{i+1}} \right) \eta_{i+1} \\ &\quad \dots \\ \eta_{i+k} &= \varepsilon_{i+k} - \left(\frac{\varepsilon_{i+k}^T \eta_i}{\eta_i^T \eta_i} \right) \eta_i - \left(\frac{\varepsilon_{i+k}^T \eta_{i+1}}{\eta_{i+1}^T \eta_{i+1}} \right) \eta_{i+1} - \dots - \left(\frac{\varepsilon_{i+k}^T \eta_{i+k-1}}{\eta_{i+k-1}^T \eta_{i+k-1}} \right) \eta_{i+k-1} \end{aligned}$$

在构造了上述向量之后, 我们让:

$$\xi_1 = \frac{1}{\sqrt{\eta_i^T \eta_i}} \eta_i, \xi_2 = \frac{1}{\sqrt{\eta_{i+1}^T \eta_{i+1}}} \eta_{i+1}, \dots, \xi_{i+k} = \frac{1}{\sqrt{\eta_{i+k}^T \eta_{i+k}}} \eta_{i+k}$$

此时的正交矩阵为 $P = [\xi_1, \xi_2, \dots, \xi_n]$

- 若对应特征值的特征空间维数大于 1, 则使用 Gram-Schmidt 正交化;
- 将所有特征向量单位化, 使其成为单位正交向量。

5. 构造正交矩阵 Q :

将单位正交的特征向量作为列向量, 排列成矩阵:

$$Q = [\mathbf{v}_1 \ \mathbf{v}_2 \ \dots \ \mathbf{v}_n], \quad \text{满足 } Q^T Q = I$$

6. 构造对角矩阵 D : 将特征值依照对应顺序排列于对角线上:

$$D = \text{diag}(\lambda_1, \lambda_2, \dots, \lambda_n)$$

(3) 特征值分解 (Eigendecomposition)

- 若 A 可对角化且

$$A = P D P^{-1},$$

则对任意整数 k , 有

$$A^k = P D^k P^{-1}.$$

若 A 可逆, 则

$$A^{-1} = P D^{-1} P^{-1}$$

4.二次型和正定矩阵Quadratic Forms and Positive-definite Ma

(1) 二次型Quadratic Forms

- 定义:

给定矩阵 $A \in \mathbb{R}^{N \times N}$ 和向量 $x \in \mathbb{R}^{N \times 1}$, 表达式

$$x^T A x$$

称为 x 关于 A 的二次型。

例: 令

$$A = \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix}, \quad x = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix},$$

则

$$x^T A x = [x_1, x_2] \begin{pmatrix} 1 & 2 \\ 3 & 4 \end{pmatrix} \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} = x_1^2 + 5x_1x_2 + 4x_2^2.$$

(2) 正定矩阵 Positive-definite Matrices

- 定义:

若矩阵 A 是对称矩阵, 且对任意非零向量 $x \neq 0$ 有

$$x^T A x > 0,$$

则称 A 是正定矩阵。

若对所有 x 满足

$$x^T A x \geq 0,$$

则称 A 是半正定矩阵。

- 性质:

1. 一个对称矩阵 $A \in \mathbb{R}^{N \times N}$ 是正定矩阵, 当且仅当 A 的所有特征值均为正:

$$\lambda_i > 0, \quad i = 1, 2, \dots, N.$$

2. 矩阵 A 是半正定矩阵, 当且仅当所有特征值均非负:

$$\lambda_i \geq 0, \quad i = 1, 2, \dots, N.$$

例如, 矩阵

$$A = \begin{pmatrix} 1 & 3 \\ 3 & 4 \end{pmatrix}$$

不是正定矩阵。其特征多项式满足

$$\det(A - \lambda I) = 0 \implies \lambda^2 - 5\lambda - 5 = 0$$

解得特征值

$$\lambda_1 = 5.85, \quad \lambda_2 = -0.85 < 0$$

由于存在负特征值，故 A 非正定。

3. 若 A 是正定矩阵，则其逆矩阵 A^{-1} 也正定。

4. 对任意矩阵 $B \in \mathbb{R}^{N \times M}$ ，矩阵

$$B^T B \quad \text{和} \quad B B^T$$

都是半正定的。

证明：对任意向量 $x \in \mathbb{R}^M$ ，有

$$x^T (B^T B) x = (Bx)^T (Bx) = \|Bx\|^2 \geq 0$$

其中 $\|\cdot\|$ 表示欧几里得范数。由于任意向量的范数平方非负，因此 $B^T B$ 是半正定矩阵。

同理，对任意向量 $y \in \mathbb{R}^N$ ，有

$$y^T (B B^T) y = (B^T y)^T (B^T y) = \|B^T y\|^2 \geq 0.$$

同样， $B B^T$ 也是半正定矩阵。

综上所述，矩阵 $B^T B$ 和 $B B^T$ 均为半正定矩阵。

- 补充：

- 矩阵的正定性判别与定义

设 A 是一个实对称矩阵。根据向量二次型 $x^T A x$ 的符号，可以将矩阵 A 分类如下：

1. 正定矩阵：对任意非零向量 x ，有 $x^T A x > 0$
2. 负定矩阵：对任意非零向量 x ，有 $x^T A x < 0$
3. 半正定矩阵：对任意向量 x ，有 $x^T A x \geq 0$
4. 半负定矩阵：对任意向量 x ，有 $x^T A x \leq 0$
5. 不定矩阵：存在 x, y 使得 $x^T A x > 0$ 而 $y^T A y < 0$

判断矩阵正负定的方法：

1. 主子式判别法 (Sylvester 判别法)

设 A_k 为 A 的前 k 阶主子矩阵，则：

A 正定当且仅当所有主子式 $\det(A_k) > 0$

A 负定当且仅当主子式符号交替： $\det(A_1) < 0, \det(A_2) > 0, \det(A_3) < 0, \dots$

2. 特征值判别法

若 A 的特征值为 $\lambda_1, \lambda_2, \dots, \lambda_n$ ，则：

所有 $\lambda_i > 0$ ，则 A 正定；所有 $\lambda_i < 0$ ，则 A 负定；所有 $\lambda_i \geq 0$ ，则 A 半正定；所有 $\lambda_i \leq 0$ ，则 A 半负定；存在 $\lambda_i > 0$ 和 $\lambda_j < 0$ ，则 A 为不定矩阵。

通过上述判断方法可以得到以下推论：设 A 是（半）正定矩阵，则 $\text{Tr}(A)$ 和 $\text{Det}(A)$ 都是（非负）正的。

对于对角矩阵，对角元就是特征值，所以我们可以得到下面的推论：

设 $D = \text{diag}(d_1, d_2, \dots, d_n)$ ，则：

- D 是正定的当且仅当对所有 i 都有 $d_i > 0$ ；
- D 是半正定的当且仅当对于所有 i 都有 $d_i \geq 0$
- D 是负定的当且仅当对于所有 i 都有 $d_i < 0$
- D 是半负定的当且仅当对于所有 i 都有 $d_i \leq 0$

部分和正负定相关的定理和性质：

1. 引理1: 设 $A \in R^{n \times n}$ 是正定矩阵, 则 A 的对角线元素都大于0

证明: 因为 A 是正定的, 对于任意 $x \neq 0 \in R^n$ 都有 $x^T A x > 0$, 于是对 $i \in \{1, 2, 3, \dots, n\}$ 有 $a_{ii} = e_i^T A e_i > 0$, 其中 a_{ii} 是矩阵的对角元素。并且 $e_1 = [1, 0, \dots, 0]$, 以此类推。

类似的证明我们可以得到以下引理2

2. 引理2: 设 $A \in R^{n \times n}$ 是半正定矩阵, 则 A 的对角线元素都非负

由定义可知, 若 A 是 (半) 负定的, 当且仅当 $-A$ 是 (半) 正定的, 因此有以下结论。

3. 引理3: 设 $A \in R^{n \times n}$ 是负定矩阵, 则 A 的对角线元素都小于0; 设 $A \in R^{n \times n}$ 是半负定矩阵, 则 A 的对角线元素都非正

4. 引理4: 设 A 是 $n \times n$ 的对称矩阵, 如果 A 的对角元素既有正值也有负值那么 A 是不定矩阵。

证明: 设 $a_{ii} > 0, a_{jj} < 0$, 则有

$$e_i^T A e_i = a_{ii} > 0, e_j^T A e_j = a_{jj} < 0$$

因此 A 是不定矩阵。

注意: 该结论反过来不一定成立, 即如果 A 是不定矩阵, A 的对角元素不一定既有正值也有负值。

◦ 定理: 设 A 是 $n \times n$ 的对称矩阵, 则有:

1. A 是正定的, 当且仅当其所有特征值都是正的
2. A 是半正定的, 当且仅当其所有特征值都是非负的
3. A 是负定的, 当且仅当其所有特征值都是负的
4. A 是半负定的, 当且仅当其所有特征值都是非正的
5. A 是不定的, 当且仅当其至少存在一个正的特征值和负的特征值

◦ 对角占优矩阵: 设 A 是一个 $n \times n$ 的对称矩阵, 则

1. A 被称为对角占优矩阵, 那么对所有的 $i = 1, 2, \dots, n$ 有

$$|a_{ii}| \geq \sum_{i \neq j} a_{ij}$$

2. A 被称为严格对角占优矩阵, 那么对所有的 $i = 1, 2, \dots, n$ 有

$$|a_{ii}| > \sum_{i \neq j} a_{ij}$$

◦ 对角占优矩阵的正定性:

1. 如果 A 是对称的 $n \times n$ 的对角占优矩阵, 并且对角元非负, 则 A 是半正定的
2. 如果 A 是对称的 $n \times n$ 的严格对角占优矩阵, 并且对角元为正, 则 A 是正定的

证明: 先证明1, 反证法, 假设 A 存在福德特征值 λ , 对应的特征向量为 u , 则满足 $Au = \lambda u$, 设

$$|u_i| = \max\{|u_1|, |u_2|, \dots, |u_n|\}$$

则有

$$|a_{ii} - \lambda| \cdot |u_i| = \left| \sum_{i \neq j} a_{ij} u_j \right| \leq \left(\sum_{i \neq j} |a_{ij}| \right) |u_i| \leq |a_{ii}| \cdot |u_i|$$

其中等式由 $Au = \lambda u$ 得到，第一个不等式由 $|u_i|$ 的定义得到

$$\left| \sum_{i \neq j} a_{ij} u_j \right| \leq \sum_{i \neq j} |a_{ij}| |u_i| \leq \left(\sum_{i \neq j} |a_{ij}| \right) |u_i|$$

第二个不等式由对角占有矩阵的定义得到。由上述不等式可以得到 $|a_{ii} - \lambda| \leq |a_{ii}|$ ，这与 $\lambda < 0, a_{ii} > 0$ 矛盾。

下面证明2，由1可知 A 半正定，那么接下来我们只需要证明 A 的特征值不为0，反证法，假设存在一个特征值为0，对应的特征向量 $u \neq 0$ ，因此 $Au = 0$ 。设

$$|u_i| = \max\{|u_1|, |u_2|, \dots, |u_n|\}$$

则有

$$|a_{ii}| |u_i| = \left| \sum_{i \neq j} a_{ij} u_j \right| \leq \left(\sum_{i \neq j} |a_{ij}| \right) |u_i| < |a_{ii}| |u_i|$$

这显然是不可能的，因此矛盾。

(3) 平方根矩阵

- 设 $A \in \mathbb{R}^{N \times N}$ 是对称正定矩阵。利用特征值分解（EVD），定义平方根矩阵：

$$A^{1/2} = U \Lambda^{1/2} U^\top$$

其中

$$\Lambda^{1/2} = \begin{bmatrix} \lambda_1^{1/2} & 0 & \cdots & 0 \\ 0 & \lambda_2^{1/2} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n^{1/2} \end{bmatrix}$$

验证：

$$A^{1/2} A^{1/2} = (U \Lambda^{1/2} U^\top)(U \Lambda^{1/2} U^\top) = U \Lambda U^\top = A.$$

- 逆平方根矩阵：

$$A^{-1/2} = U \Lambda^{-1/2} U^\top$$

其中

$$\Lambda^{-1/2} = \begin{bmatrix} \lambda_1^{-1/2} & 0 & \cdots & 0 \\ 0 & \lambda_2^{-1/2} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n^{-1/2} \end{bmatrix}$$

验证：

$$A^{-1/2} A^{-1/2} = (U \Lambda^{-1/2} U^\top)(U \Lambda^{-1/2} U^\top) = U \Lambda^{-1} U^\top = A^{-1}.$$

5.附录一：特征值算法 Eigenvalue Algorithms

(1) 幂迭代 (Power Iteration)

- 定义：给定一个可对角化矩阵 A ，算法会生成一个数 λ_1 ，它是 A 的绝对值最大的特征值（主特征值），以及一个非零向量 x_1 ，它是对应的特征向量，满足：

$$Ax_1 = \lambda_1 x_1$$

算法步骤：

- 设 $k = 0$ ，并取初始向量 $b_k = v$ ，其中 v 是随机向量。

2. 重复：

- 计算 $v = Ab_k$ ；
- 令 $k = k + 1$ ，并令 $b_k = \frac{v}{\|v\|}$ ；

■ 停止条件：

- $k = K_{\max}$ ，或
- $\|b_k - b_{k-1}\| < \varepsilon$ 。

- 最大特征值与对应特征向量近似为：

\$\$\$

$$\lambda_1 \approx \frac{b_k^T A b_k}{b_k^T b_k}, \quad x_1 \approx b_k$$

Rayleigh商定义为：

$$R(A, x) = \frac{x^T A x}{x^T x}$$

\$\$\$

- 总结：

适用对象：一般矩阵

输出结果：具有最大/主特征值的特征对

备注：算法非常简单，但可能收敛较慢；适用于非常大的稀疏矩阵；被用于 Google PageRank。

- 额外说明：

若 A 可逆，且特征值满足：

$$\lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_N$$

则 A^{-1} 的特征值为：

$$\lambda_N^{-1} \geq \lambda_{N-1}^{-1} \geq \cdots \geq \lambda_1^{-1}$$

因此，对 A^{-1} 进行幂迭代，可得到 λ_N^{-1} 及其对应特征向量。

- 幂迭代符号表示

若记幂迭代为 $\text{Power}(A, K_{\max})$ ，则有：

$$(\lambda_1, x_1) = \text{Power}(A, K_{\max})$$

$$(\lambda_N^{-1}, x_N) = \text{Power}(A^{-1}, K_{\max})$$

(2) 反迭代 (逆幂法) Inverse Iteration

- 定义：用于在已知某个特征值近似值的情况下，找到对应的特征向量近似。
- 算法：
 1. 设 $k = 0$ ，并取初始向量 $b_k = v$ ，其中 v 是随机向量。

2. 重复：

- 计算 $v = (A - \mu I)^{-1} b_k$;
- 令 $k = k + 1$ ，并令 $b_k = \frac{v}{\|v\|}$;
- 停止条件：
 - $k = K_{\max}$ ，或
 - $\|b_k - b_{k-1}\| < \varepsilon$ 。

3. 收敛结果：

$$\lambda_{\sim\mu} \approx \frac{b_k^\top A b_k}{b_k^\top b_k}, \quad x_{\sim\mu} \approx b_k$$

等价表示：

$$((\lambda_{\sim\mu} - \mu)^{-1}, x_{\sim\mu}) = \text{Power}((A - \mu I)^{-1}, K_{\max})$$

(3) Rayleigh 商迭代 (Rayleigh Quotient Iteration)

- 定义：Rayleigh 商迭代在反迭代基础上，利用 Rayleigh 商动态更新 μ ，从而获得更高精度的特征值近似。
- 算法：输入 $A, \mu, K_{\max}$ (或 ε)。

1. 设 $k = 0$ ， $\mu_k = \mu$ ，并取初始向量 $b_k = v$ ，其中 v 是随机向量。

2. 重复：

- 计算 $v = (A - \mu_k I)^{-1} b_k$;
- 令 $k = k + 1$;
- 单位化 $b_k = \frac{v}{\|v\|}$;
- 更新 $\mu_k = \frac{b_k^\top A b_k}{b_k^\top b_k}$;
- 停止条件：
 - $k = K_{\max}$ ，或
 - $\|b_k - b_{k-1}\| < \varepsilon$ 。

3. 收敛结果：

$$\lambda_{\sim\mu} \approx \mu_k, \quad x_{\sim\mu} \approx b_k$$

(4) QR 算法 (QR Algorithm)

- 定义：QR 算法是一种标准的迭代方法，用于计算矩阵的特征值和特征向量。其基本思想是：对矩阵 A 做 QR 分解，将其写成正交矩阵 Q 与上三角矩阵 R 的乘积，然后反向相乘并迭代。
- 算法：

1. 设 $k = 0$ ， $A_0 = A$ 。

2. 对于 $k = 1, \dots, K_{\max}$:

- 计算 QR 分解:

$$A_{k-1} = Q_{k-1} R_{k-1}$$

- 形成:

$$A_k = R_{k-1} Q_{k-1}$$

- 并注意:

$$A_k = R_{k-1} Q_{k-1} = Q_{k-1}^\top Q_{k-1} R_{k-1} Q_{k-1} = Q_{k-1}^\top A_{k-1} Q_{k-1}$$

- 停止条件: 当 A_k 的下三角部分元素的最大绝对值足够小时停止。

3. 收敛结果: 方法收敛到上三角矩阵 A_∞ , 其对角元为 A 的特征值。

- QR 算法的性质:

- 所有 A_k 两两相似, 特征值相同。

具体形式:

$$A_{k+l} = Q_{k+l-1}^\top \cdots Q_k^\top A_k Q_k \cdots Q_{k+l-1}, \quad \forall k \geq 0, l \geq 1$$

或

$$A_k = Q_k \cdots Q_{k+l-1} A_{k+l} Q_{k+l-1}^\top \cdots Q_k^\top$$

特别地:

$$A = O A_\infty O^\top, \quad O = Q_\infty \cdots Q_1 Q_0$$

若 A 对称, 则 A_∞ 是对角矩阵:

$$A = O \Lambda O^\top$$

其中 Λ 为特征值对角矩阵, O 的列为对应特征向量。特征值已知后, 特征向量可通过解齐次线性方程组, 或使用反迭代 / Rayleigh 商迭代获得。

(5) Krylov 子空间方法 (Krylov Subspace Methods)

- 定义: QR 算法用于求解稠密矩阵的全部特征值和特征向量时, 计算量较大。在实际中, 通常先将稠密矩阵通过相似变换转化为具有特殊形式的稀疏矩阵, 然后再对该稀疏矩阵应用 QR 算法。如果我们只关心少数几个特征值和特征向量, 使用 Krylov 子空间方法会更快。
- 常见的 Krylov 子空间方法
 - **Arnoldi 迭代** (Arnoldi Iteration): 适用于一般矩阵。
 - **Lanczos 算法** (Lanczos Algorithm): 适用于 Hermitian (厄米) 矩阵。

6.附录二: 奇异值分解 Singular Value Decomposition, SVD

- 定义: 设 A 是一个 $M \times N$ 矩阵, 秩为 r 。则存在一个 $M \times N$ 矩阵 Σ :

$$\Sigma = \begin{bmatrix} \sigma_1 & & & & \\ & \sigma_2 & & & \\ & & \ddots & & \\ & & & \sigma_r & \\ & & & & 0 \\ & & & & & \ddots \end{bmatrix}$$

其中 $\sigma_1 \geq \sigma_2 \geq \cdots \geq \sigma_r > 0$ 是 A 的奇异值, 且存在 $M \times M$ 正交矩阵 U 和 $N \times N$ 正交矩阵 V , 使得:

$$A = U\Sigma V^T$$

• 性质:

- 奇异值是 $A^T A$ 或 AA^T 特征值的平方根。
- U 的列是 AA^T 的特征向量 (左奇异向量)。
- V 的列是 $A^T A$ 的特征向量 (右奇异向量)。

• 注意:

- U 和 V 不唯一, 但 Σ 的对角元唯一。
- 任意形如 $A = U\Sigma V^T$ 且 U, V 正交、 Σ 为上述形式的分解称为 SVD。
- 应用:

- 计算矩阵秩;
- 解齐次方程 $Ax = 0$;
- 解最小二乘问题;
- 矩阵近似 (主成分分析)。

• SVD 的计算过程

1. 找到 $A^T A$ 的特征向量正交基 $\{v_1, \dots, v_N\}$, 按特征值降序排列, 前 $r = \text{rank}(A)$ 个特征值 > 0 。
2. 构造 $V = [v_1, \dots, v_N]$ 。
3. 令 $\sigma_j = \sqrt{\lambda_j}$ ($1 \leq j \leq r$), 构造 Σ 。
4. 令 $u_j = \frac{1}{\sigma_j} A v_j$ ($1 \leq j \leq r$), $\{A v_1, \dots, A v_r\}$ 是正交集。
5. 将 $\{u_1, \dots, u_r\}$ 扩展为 $\mathbb{R}^M$ 的正交基, 形成 U 。
6. 得到 $A = U\Sigma V^T$ 。