

第四讲 假设检验

(1) 信息与数据精简 Information and Data Reduction

- 在统计分析中，我们经常对原始数据做**数值或图形的变换**来更好地呈现与压缩信息。例如
 - 原始样本： $X_1, \dots, X_n$
 - 次序统计量： $X_{(1)}, \dots, X_{(n)}$
 - 直方图（图形化总结）
 - 样本均值： $\bar{X}$
 - 样本方差： $\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$
- 数据约简 (data reduction)** 通过这些变换把信息“浓缩”为更少的数字/图形，便于传达；但一般会**引起信息损失**：并不是所有与参数相关的信息都能被保留下来。
- 因此提出关键问题：**是否存在一个统计量 $T(X_1, \dots, X_n)$ ，它包含了样本中关于参数 θ 的全部信息？**
- 充分统计量
 - 定义 (直观)**：若给定统计量 $T(X)$ 的值后，样本 X 对参数 θ 不再提供额外信息，则称 $T(X)$ 是关于 θ 的**充分统计量**。
 - Fisher-Neyman 因子分解定理 (判定标准)**：
设样本的联合密度/概率质量函数为 $f(x | \theta)$ 。若存在函数 g 与 h 使得

$$f(x | \theta) = g(T(x), \theta) h(x),$$

则 $T(X)$ 是 θ 的充分统计量。此时关于 θ 的信息完全通过 $T(X)$ 传递（对 θ 无信息的部分被吸收到 $h(x)$ 中）。

为什么“充分”重要？

- 它给出了一种**无信息损失**的约简：在作关于 θ 的推断（估计/检验/区间）时，用 $T(X)$ 与用全样本等价。
- 进一步还可寻找**极小充分统计量** (minimal sufficient)，在所有充分统计量中最“精炼”。

常见例子

1. **Bernoulli/Binomial**: $X_i \stackrel{iid}{\sim} \text{Bernoulli}(p)$ 。

联合 pmf:

$$f(x | p) = \prod_{i=1}^n p^{x_i} (1-p)^{1-x_i} = p^{\sum x_i} (1-p)^{n-\sum x_i} \cdot 1.$$

由因子分解， $T(X) = \sum_{i=1}^n X_i$ (或样本均值 $\bar{X}$) 对 p 充分。

$g(T(x), p) = p^{\sum x_i} (1-p)^{n-\sum x_i}$ (只依赖于 $T(x) = \sum x_i$ 和参数 p)

$h(x) = 1$ (不依赖于 p)

2. **正态均值已知方差**: $X_i \stackrel{iid}{\sim} N(\mu, \sigma^2)$ (σ^2 已知)。

联合密度:

$$f(x | \mu) \propto \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \right\} = \exp \left\{ -\frac{n}{2\sigma^2} (\bar{x} - \mu)^2 \right\} \cdot h(x).$$

$$g(T(x), \mu) = \exp \left\{ -\frac{n(\bar{x} - \mu)^2}{2\sigma^2} \right\} \quad (\text{只依赖于 } \bar{x} \text{ 和 } \mu)$$

$$h(x) = \exp \left\{ -\frac{\sum x_i^2 - n(\bar{x})^2}{2\sigma^2} \right\} \quad (\text{不依赖于 } \mu)$$

3. 正态均值与方差均未知: $X_i \stackrel{iid}{\sim} N(\mu, \sigma^2)$.

联合密度依赖于 $\sum x_i$ 与 $\sum x_i^2$, 故

$$T(X) = \left(\sum_{i=1}^n X_i, \sum_{i=1}^n X_i^2 \right)$$

是关于 (μ, σ^2) 的极小充分统计量 (与 $(\bar{X}, S^2)$ 等价)。

$$T(X) = \left(\sum X_i, \sum X_i^2 \right)$$

等价于 $(\bar{X}, S^2)$, 其中 $S^2 = \frac{1}{n-1} \sum (X_i - \bar{X})^2$

• Sufficient Statistics

定义: 统计量 $T(X_1, \dots, X_n)$ 对参数 θ **充分 (sufficient)**, 当且仅当: 对任意取值 t , 条件分布

$$f(x_1, \dots, x_n | T = t)$$

不依赖于 θ 。直观含义: 一旦知道 $T = t$, 完整样本关于 θ 的信息已被用尽。

例: 正态, 方差已知

设 $X_1, \dots, X_n \stackrel{i.i.d.}{\sim} N(\mu, \sigma_0^2)$, 其中 σ_0^2 已知。证明样本均值

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

是对 μ 的充分统计量。

证明 (按照定义):

考虑条件密度

$$f(x_1, \dots, x_n | \bar{X} = \bar{x}) = \frac{f(x_1, \dots, x_n)}{f_{\bar{X}}(\bar{x})}.$$

◦ 联合密度 (忽略与 μ 无关的常数):

$$f(x_1, \dots, x_n) \propto \exp \left\{ -\frac{1}{2\sigma_0^2} \sum_{i=1}^n (x_i - \mu)^2 \right\}.$$

使用恒等分解

$$\sum_{i=1}^n (x_i - \mu)^2 = \sum_{i=1}^n (x_i - \bar{x})^2 + n(\bar{x} - \mu)^2.$$

得

$$f(x_1, \dots, x_n) \propto \exp \left\{ -\frac{1}{2\sigma_0^2} \sum_{i=1}^n (x_i - \bar{x})^2 \right\} \cdot \exp \left\{ -\frac{n(\bar{x} - \mu)^2}{2\sigma_0^2} \right\}.$$

◦ $\bar{X}$ 的边缘密度为 $N(\mu, \sigma_0^2/n)$, 因此

$$f_{\bar{X}}(\bar{x}) \propto \exp \left\{ -\frac{n(\bar{x} - \mu)^2}{2\sigma_0^2} \right\}.$$

◦ 取比值得到

$$f(x_1, \dots, x_n \mid \bar{X} = \bar{x}) \propto \exp\left\{-\frac{1}{2\sigma_0^2} \sum_{i=1}^n (x_i - \bar{x})^2\right\},$$

不含 μ 。故由定义可知 $\bar{X}$ 对 μ 充分。

证明（因子分解定理）：

联合密度可写成

$$f(x_1, \dots, x_n \mid \mu) = h(x_1, \dots, x_n) g(\bar{x}, \mu),$$

其中

$$h(x) \propto \exp\left\{-\frac{1}{2\sigma_0^2} \sum (x_i - \bar{x})^2\right\},$$

$$g(\bar{x}, \mu) \propto \exp\left\{-\frac{n(\bar{x} - \mu)^2}{2\sigma_0^2}\right\}.$$

由 Fisher-Neyman 因子分解定理, $\bar{X}$ 是关于 μ 的充分统计量。

- Factorization Theorem (因子分解定理)

$T(X_1, \dots, X_n)$ 对参数 θ 充分 **当且仅当** 联合密度/概率函数可以写成

$$f(x_1, \dots, x_n \mid \theta) = g(T(x_1, \dots, x_n), \theta) h(x_1, \dots, x_n),$$

其中 h 与 θ 无关, 所有关于 θ 的依赖都只通过 $T(x_1, \dots, x_n)$ 出现。

- 含义: 样本关于 θ 的信息被压缩在 T 中; 给定 T 后, $X_1, \dots, X_n$ 的条件分布不再依赖 θ 。
- 使用步骤:

1. 写出联合密度/似然 $f(\mathbf{x} \mid \theta) = \prod_{i=1}^n f(x_i \mid \theta)$ 。
2. 代数整理成“ θ -相关部分” $\times$ “ θ -无关部分”的形式。
3. 若能写成上式, 则 $T(\mathbf{x})$ 为 θ 的充分统计量。

- Corollary (推论: MLE 与充分统计量)

若 T 对 θ 充分, 则 θ 的极大似然估计 $\hat{\theta}$ 必是 T 的函数。

理由: 由因子分解

$$L(\theta \mid \mathbf{x}) = g(T(\mathbf{x}), \theta) h(\mathbf{x}),$$

对 θ 最大化 L 与最大化 $g(T(\mathbf{x}), \theta)$ 等价, 而 g 仅依赖于 $T(\mathbf{x})$, 故 $\hat{\theta} = \hat{\theta}(T(\mathbf{x}))$ 。

2. 假设检验导论 Introduction to Hypothesis Testing

- 假设检验的定义: 利用样本信息去判断一个关于总体参数的主张 (原假设 H_0) 是否与数据相符。

例: 单样本 t 检验

设 $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$, σ^2 未知。记样本均值与样本标准差分别为

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i, \quad S = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2}.$$

则检验统计量

$$T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t_{n-1}.$$

需要在下列二者中做出判断:

- 原假设: $H_0: \mu = \mu_0$ (μ_0 给定)

- 备择假设: $H_1: \mu \neq \mu_0$ (双侧)

在 H_0 下,

$$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \sim t_{n-1}.$$

决策规则 (双侧, 显著性水平 $\alpha = 0.05$)

- 临界值: $t_{n-1}(\alpha/2)$ 为 t 分布上 $\alpha/2$ 分位点。
- **拒绝域**: 若 $|T| > t_{n-1}(0.025)$, 拒绝 H_0 ; 否则“不拒绝 H_0 ”。

例如: $n = 11$ (自由度 10) 时, $t_{10}(0.025) = 2.23$, 且在 H_0 成立时

$$P(|T| \leq 2.23) \approx 0.95.$$

基于样本的结论解读

- 若计算得到的 $|T|$ **很大** (如 5.45), 则它**极不可能**来自 t_{10} , 因此**拒绝** H_0 。
- 若 $|T|$ **较小**, 如 $T \in (-2.23, 2.23)$, 则没有足够证据拒绝 H_0 (在 $\alpha = 0.05$ 下)。

p 值

双侧情形的 p 值为

$$p = 2 \cdot P(t_{n-1} \geq |T_{\text{obs}}|).$$

- 若 $p < \alpha$, 拒绝 H_0 ;
- 若 $p \geq \alpha$, 不拒绝 H_0 。

• Strategy of Hypothesis Testing

Translate the scientific question into statistical hypotheses.

把科学问题形式化为两种互斥主张: 原假设 H_0 与备择假设 H_1 。

- 例: $H_0: \mu = \mu_0$, $H_1: \mu \neq \mu_0$ (双侧) 或 $H_1: \mu > \mu_0 / \mu < \mu_0$ (单侧)。

Start by assuming H_0 is true.

在推理上先假定 H_0 成立, 设定显著性水平 α , 据此定义犯第一类错误 (错拒 H_0) 的上限概率 α 。

Collect data.

通过实验/抽样获得观测样本 $\mathbf{X} = (X_1, \dots, X_n)$, 计算与假设相关的**检验统计量** $T = T(\mathbf{X})$ 。

Decide whether the data contradict H_0 .

在 H_0 前提下求出 T 的分布, 据此作出判定:

- **拒绝域法**: 构造拒绝域 R_α 使得在 H_0 下 $P(T \in R_\alpha) \leq \alpha$ 。若观测到的 $t_{\text{obs}} \in R_\alpha$, 则认为数据与 H_0 矛盾, **拒绝** H_0 ; 否则**不拒绝** H_0 。
- **p 值法**: 计算 $p = P_{H_0}(\text{“}T \text{ 至少像 } t_{\text{obs}} \text{ 这样极端”})$ 。若 $p < \alpha$, 拒绝 H_0 ; 否则不拒绝 H_0 。

• Elements of a Hypothesis Test 假设检验中的要素

1. 假设 (Hypotheses)

- 设样本 $X \sim f(x|\theta)$, 参数空间 Ω 被分成互不相交的两部分 ω_0, ω_1 。
- 我们要在下面两种陈述之间作判断:
 $H_0: \theta \in \omega_0$ vs. $H_1: \theta \in \omega_1$ 。
- H_0 称为**原假设 (null hypothesis)**, H_1 称为**备择假设 (alternative hypothesis)**。

■ 常见形式

- 双侧: $H_0: \theta = \theta_0, H_1: \theta \neq \theta_0$;
- 右单侧: $H_0: \theta \leq \theta_0, H_1: \theta > \theta_0$;
- 左单侧: $H_0: \theta \geq \theta_0, H_1: \theta < \theta_0$.

2. 决策与可能的错误

在假设检验中, 我们依据数据判断 H_0 或 H_1 哪个更能解释数据。可能犯两类错误:

决策	自然真实状态 H_0 为真	自然真实状态 H_1 为真
拒绝 H_0	第一类错误 (Type I)	正确检测 (功效)
拒绝 H_1 (即不拒绝 H_0)	正确决策	第二类错误 (Type II)

○ 第一类错误概率 (显著性水平)

$$\alpha \equiv P(\text{拒绝 } H_0 \mid H_0 \text{ 为真}).$$

○ 第二类错误概率

$$\beta = P(\text{不拒绝 } H_0 \mid H_1 \text{ 为真}).$$

○ 功效 (Power): 在 H_1 为真时正确拒绝 H_0 的概率

$$1 - \beta.$$

目标是让 α 与 β 都尽量小, 但二者存在权衡: 通常在固定样本量下, α 降低往往会使 β 增大, 反之亦然。

例: 两侧检验的大小、功效

检验

$$H_0: p = 0.4 \quad \text{vs.} \quad H_1: p \neq 0.4,$$

样本来自 $\text{Bernoulli}(p)$, 样本量 $n = 10$ 。设

$$Y = \sum_{i=1}^{10} X_i \sim \text{Bin}(10, p).$$

拒绝域取

$$\mathcal{C} = \{Y \leq 0\} \cup \{Y \geq 8\},$$

即当 $Y \leq 0$ 或 $Y \geq 8$ 时拒绝 H_0 。

检验大小 (显著性水平)

在 H_0 下 $p_0 = 0.4$,

$$\alpha = \Pr_{p=0.4}(Y \leq 0 \text{ or } Y \geq 8) = 1 - \Pr_{p=0.4}(1 \leq Y \leq 7) = 1 - \sum_{k=1}^7 \binom{10}{k} 0.4^k 0.6^{10-k}.$$

数值为:

$$\alpha = 1 - \Pr(1 \leq Y \leq 7 \mid p = 0.4) = 0.0183.$$

等价地也可写为

$$\alpha = (1 - 0.4)^{10} + \sum_{k=8}^{10} \binom{10}{k} 0.4^k 0.6^{10-k}.$$

第二类错误概率与功效 (给定 $p \neq 0.4$)

对于任意 p (在 H_1 下), 不拒绝域是 $1 \leq Y \leq 7$, 故

$$\beta(p) = \Pr_p(1 \leq Y \leq 7) = \sum_{k=1}^7 \binom{10}{k} p^k (1-p)^{10-k},$$

而功效函数为

$$\text{power}(p) = 1 - \beta(p) = \Pr_p(Y \leq 0 \text{ or } Y \geq 8) = (1-p)^{10} + \sum_{k=8}^{10} \binom{10}{k} p^k (1-p)^{10-k}.$$

- Neyman-Pearson Paradigm 内曼-皮尔逊引理

1. Simple hypothesis (简单假设)

- **简单假设**: 把样本的联合分布完全确定。

例如: $H_0: X \sim \text{Binom}(25, 1/3)$ 。

2. Likelihood ratio (似然比)

- 有两个模型 (参数) θ_0 与 θ_1 , 观测到数据为 $\mathbf{x}$, 其似然分别为

$$L(\theta) = f(\mathbf{x} | \theta).$$

- **似然比** 定义为

$$\Lambda(\mathbf{x}) = \frac{L(\theta_0)}{L(\theta_1)} = \frac{f(\mathbf{x} | \theta_0)}{f(\mathbf{x} | \theta_1)}.$$

- **直觉**: $\Lambda(\mathbf{x})$ 小意味着“在 H_1 下的数据更可能”, 因此更倾向于**拒绝** H_0 。

Question: 当 Λ 很小时该怎么做? ——见下文 Neyman-Pearson 引理。

3. Most Powerful (MP) test (最强检验)

- 在给定大小 (显著性水平) α 的所有检验中, **功效最大的检验称为最强 (MP) 检验**。“功效更大”即对每个备择下的拒绝概率都不低于其它任何同大小检验。

4. Theorem — Neyman-Pearson Lemma (核心结论)

设检验

$$H_0: \theta = \theta_0 \quad \text{vs} \quad H_1: \theta = \theta_1,$$

其中 $f(\mathbf{x} | \theta)$ 是对应的 pdf/pmf (均为**简单假设**)。

则大小为 α 的最强检验是: 存在常数 $c > 0$, 当

$$\Lambda(\mathbf{x}) = \frac{f(\mathbf{x} | \theta_0)}{f(\mathbf{x} | \theta_1)}$$

时**拒绝** H_0 。阈值 c 由“大小”为 α 的约束确定, 即

$$\alpha = \int_R f(\mathbf{x} | \theta_0) d\mathbf{x}, \quad R = \{\mathbf{x} : \Lambda(\mathbf{x}) < c\}.$$

这说明: **沿着似然比从小到大排列样本点, 优先把似然比最小的样本点划入拒绝域**, 直到在 H_0 下的概率质量 (或概率) 正好等于 α , 即可得到**最强**的大小为 α 的检验。

5. 应用步骤 (配方)

- 写出 $f(\mathbf{x} | \theta_0)$ 与 $f(\mathbf{x} | \theta_1)$ 。
- 形成似然比 $\Lambda(\mathbf{x}) = f(\mathbf{x} | \theta_0) / f(\mathbf{x} | \theta_1)$ 。
- 选择阈值 c 使得

$$\Pr_{H_0}(\Lambda(\mathbf{X}) < c) = \alpha.$$

- 采用规则：若 $\Lambda(\mathbf{x}) < c$ 则拒绝 H_0 ，否则不拒绝。

6. 备注

- 当检验统计量具有**单调似然比 (MLR)** 性质时，NP 思路常推广为**统一最强 (UMP)** 检验（针对一类备择都最强）。
- 复合假设下可基于**广义似然比 (GLR)**：

$$\Lambda(\mathbf{x}) = \frac{\sup_{\theta \in \Theta_0} L(\theta)}{\sup_{\theta \in \Theta_1} L(\theta)}$$

再用渐近分布或置换法确定阈值。

例：正态均值的最强检验（已知方差）

模型与假设

- 样本： $X_1, \dots, X_n \stackrel{\text{i.i.d.}}{\sim} N(\mu, \sigma^2)$ ，其中 σ^2 已知。
- 简单假设： $H_0: \mu = \mu_0$ vs $H_1: \mu = \mu_1$ (μ_0, μ_1 为给定常数)。

1. 构造似然比

两假设下的联合密度分别为

$$f(\mathbf{X} | \mu_j) = (2\pi\sigma^2)^{-n/2} \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (X_i - \mu_j)^2\right\}, \quad j = 0, 1.$$

似然比统计量

$$\Lambda(\mathbf{X}) = \frac{f(\mathbf{X} | \mu_0)}{f(\mathbf{X} | \mu_1)} = \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n [(X_i - \mu_0)^2 - (X_i - \mu_1)^2]\right\}.$$

将平方差展开并化简（用 $\bar{X} = \frac{1}{n} \sum_i X_i$ ）：

$$\sum_{i=1}^n [(X_i - \mu_0)^2 - (X_i - \mu_1)^2] = n(\mu_0^2 - \mu_1^2) - 2n(\mu_0 - \mu_1)\bar{X}.$$

代回得

$$\Lambda(\mathbf{X}) = \exp\left\{\frac{1}{2\sigma^2} \left[2n\bar{X}(\mu_0 - \mu_1) + n\mu_1^2 - n\mu_0^2\right]\right\}.$$

结论：当 $\mu_0 < \mu_1$ 时， $\mu_0 - \mu_1 < 0$ ，因此 $\Lambda(\mathbf{X})$ 是 $\bar{X}$ 的**严格下降函数**；即 $\bar{X}$ 越大， Λ 越小。

2. Neyman-Pearson 引理 → 最强 (MP) 检验

- 由 NP 引理，大小为 α 的最强检验应**拒绝 H_0** **当且仅当** 似然比足够小。
在 $\mu_0 < \mu_1$ 情形，这等价于**当样本均值够大时拒绝**：

$$\text{拒绝域 } R = \{\bar{X} > c\}.$$

阈值 c 由“检验大小”为 α 确定：

$$\alpha = P_{H_0}(\bar{X} > c) = P\left(\frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} > \frac{c - \mu_0}{\sigma/\sqrt{n}}\right) = 1 - \Phi\left(\frac{c - \mu_0}{\sigma/\sqrt{n}}\right).$$

令 $z(\alpha)$ 为 $N(0, 1)$ 的**上侧 α 分位数**，即 $P(Z > z(\alpha)) = \alpha$ 。

于是

$$\frac{c - \mu_0}{\sigma/\sqrt{n}} = z(\alpha) \implies c = \mu_0 + z(\alpha) \frac{\sigma}{\sqrt{n}}.$$

最终判别式 (单侧右尾检验) :

$$\frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} > z(\alpha) \Rightarrow \text{拒绝 } H_0$$

这就是大小为 α 的**最强检验** (在已知 σ 、 $\mu_0 < \mu_1$ 的简单对简单情形)。

3. 解读与扩展

■ **p 值**: $p = 1 - \Phi((\bar{X} - \mu_0)/(\sigma/\sqrt{n}))$; 当 $p < \alpha$ 时拒绝 H_0 。

■ **功效函数** (对一般 μ) :

$$\beta(\mu) = P_\mu \left(\frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} > z(\alpha) \right) = 1 - \Phi \left(z(\alpha) - \frac{(\mu - \mu_0)\sqrt{n}}{\sigma} \right).$$

■ 若 $\mu_0 > \mu_1$ (左尾), 则拒绝域变为 $\frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} < -z(\alpha)$ 。

■ 双侧检验 ($H_1: \mu \neq \mu_0$) 时取两侧阈值 $z(\alpha/2)$, 拒绝域为

$$\left| \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \right| > z(\alpha/2).$$

例: 正态均值的 UMP / UMPU / t 检验

设 $X_1, \dots, X_n \stackrel{i.i.d.}{\sim} N(\mu, \sigma^2)$ 。以下给出在不同备择下的最优 (或常用) 检验。

约定: $z(\alpha)$ 为 $N(0, 1)$ 的**上侧** α 分位数 ($P(Z > z(\alpha)) = \alpha$)。

1. 单侧左尾: $H_0: \mu = \mu_0$ vs $H_1: \mu < \mu_0$ (σ^2 已知)

由 Neyman-Pearson 引理 (例 4.6 的同样推导), 似然比随 $\bar{X}$ 单调, 因此**UMP**检验为

$$R_{\text{UMP}} = \left\{ \bar{X} < c \right\}, \quad c = \mu_0 - z(\alpha) \frac{\sigma}{\sqrt{n}}.$$

等价写法:

$$\frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} < -z(\alpha) \Rightarrow \text{拒绝 } H_0.$$

若是右尾 $H_1: \mu > \mu_0$, 则 UMP 拒绝域为

$$\frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} > z(\alpha).$$

2. 双侧: $H_0: \mu = \mu_0$ vs $H_1: \mu \neq \mu_0$ (σ^2 已知)

不存在单一的 UMP 检验 (因为对 $\mu > \mu_0$ 与 $\mu < \mu_0$ 的 UMP 拒绝域不同, 无法用一个拒绝域同时对所有单侧都最强)。

常用且具有良好性质的是 **UMPU/GLRT 的双侧 z 检验**:

$$R_{(\text{UMPU/GLRT})} = \left\{ \left| \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \right| > z(\alpha/2) \right\},$$

它不是 UMP, 但在对称分布下具有“最强无偏 (UMPU)”等良好功效性质

3. 与 1)-2) 同样的假设, 但 σ^2 未知——t 检验

令 S 为样本标准差, 则

- 右尾: $H_0: \mu = \mu_0$ vs $H_1: \mu > \mu_0$

$$\frac{\bar{X} - \mu_0}{S/\sqrt{n}} > t_{n-1}(\alpha) \Rightarrow \text{拒绝 } H_0.$$

- 左尾: $H_0: \mu = \mu_0$ vs $H_1: \mu < \mu_0$

$$\frac{\bar{X} - \mu_0}{S/\sqrt{n}} < -t_{n-1}(\alpha) \Rightarrow \text{拒绝 } H_0.$$

- 双侧: $H_0: \mu = \mu_0$ vs $H_1: \mu \neq \mu_0$

$$\left| \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \right| > t_{n-1}(\alpha/2) \Rightarrow \text{拒绝 } H_0.$$

由于 H_0 非“简单假设” (含未知 σ)，NP 引理不能直接应用。上述 t 检验可由广义似然比 (GLRT) 推得，具有良好功效，但**一般不能证明为 UMP**。

例: Bernoulli 参数的最有力 (MP) 检验 (Neyman-Pearson)

设 $X_1, \dots, X_n \stackrel{i.i.d.}{\sim} \text{Bern}(p)$, 检验**简单假设** $H_0: p = p_0$ vs $H_1: p = p_1$, 其中 $0 < p_0 < p_1 < 1$ 为给定常数。

1. 似然比与其单调性

样本为 $x = (x_1, \dots, x_n)$, 记 $Y = \sum_{i=1}^n x_i$ (成功次数)。

在 H_0 与 H_1 下的**似然比**为

$$\Lambda(x) = \frac{\prod_{i=1}^n p_0^{x_i} (1-p_0)^{1-x_i}}{\prod_{i=1}^n p_1^{x_i} (1-p_1)^{1-x_i}} = \left(\frac{1-p_0}{1-p_1} \right)^n \left(\frac{p_0(1-p_1)}{p_1(1-p_0)} \right)^{\sum_{i=1}^n x_i}.$$

因 $p_1 > p_0 \Rightarrow \frac{p_0(1-p_1)}{p_1(1-p_0)} < 1$, 故 $\Lambda(x)$ 随 $Y = \sum x_i$ **严格下降**。所以 Y 越大, $\Lambda(x)$ 越小, 越有利于拒绝 H_0 。

2. NP 引理给出的 MP 拒绝域

由 Neyman-Pearson 引理, **给定显著性水平 α 的最有力 (MP) 检验**为

$$R = \{x: \Lambda(x) < c_0\} = \{x: \sum_{i=1}^n x_i > c\},$$

其中阈值 c (正整数) 由**控制检验规模**确定:

$$P_{H_0}(Y > c) = P(Y > c \mid Y \sim \text{Bin}(n, p_0)) \leq \alpha,$$

并选使上式成立的**最小 c** (使检验“尽量有力”)。

3. 数值例: $n = 25, p_0 = 0.25, \alpha = 0.05$

计算右尾概率:

$$P(Y > 9 \mid Y \sim \text{Bin}(25, 0.25)) \approx 0.07, \quad P(Y > 10 \mid Y \sim \text{Bin}(25, 0.25)) \approx 0.03.$$

故取

$$c = 10, \text{ 使 } P_{H_0}(Y > c) = P_{H_0}(Y > 10) \approx 0.03 \leq 0.05.$$

判决: 当且仅当 $Y > 10$ 时, 在水平 $\alpha = 0.05$ 拒绝 H_0 。

4. p 值计算与解释

若观测到 $y_{\text{obs}} = 11$, 则

$$p\text{-value} = P_{H_0}(Y \geq 11) = \sum_{k=11}^{25} \binom{25}{k} 0.25^k (0.75)^{25-k} \approx 0.01 < \alpha,$$

故拒绝 H_0 。

- p-value (p值)

核心概念

- 设统计量为 T ，观测到的样本得到的统计量取值为 t_{obs} 。
 - **p 值** 是“在原假设 H_0 成立时，统计量至少像当前这么极端的概率”。
- $$p\text{-value} = P(T \text{ is as or more extreme than } t_{\text{obs}} \mid H_0)$$

直观解释

- p 值小 $\Rightarrow$ 观测数据与 H_0 不相容，**反对** H_0 的证据强。
- p 值大 $\Rightarrow$ 数据与 H_0 相容，**没有足够证据**反对 H_0 。

基于 p 值的决策规则（显著性水平 α ）

- 若 $p\text{-value} < \alpha$ ，则**拒绝** H_0 ；
 - 若 $p\text{-value} \geq \alpha$ ，则**不拒绝** H_0 。
- 这与临界值法一致：例如单侧检验中，当且仅当

$$\frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} > z(\alpha)$$

时拒绝 H_0 。此时 p 值为 $P(Z > z_{\text{obs}})$ ，因此 $p\text{-value} < \alpha \iff z_{\text{obs}} > z(\alpha)$ 。

- Z 检验中的 p 值公式（已知总体方差）

设 z_{obs} 为观测到的 Z 统计量取值， $\Phi(\cdot)$ 为标准正态 $N(0, 1)$ 的分布函数。检验 $H_0: \mu = \mu_0$ 与不同的备择假设 H_1 时：

1. **右单侧** $H_1: \mu > \mu_0$

$$p\text{-value} = P(Z > z_{\text{obs}}) = 1 - \Phi(z_{\text{obs}})$$

2. **左单侧** $H_1: \mu < \mu_0$

$$p\text{-value} = P(Z < z_{\text{obs}}) = \Phi(z_{\text{obs}})$$

3. **双侧** $H_1: \mu \neq \mu_0$

$$p\text{-value} = P(|Z| \geq |z_{\text{obs}}|) = 2[1 - \Phi(|z_{\text{obs}}|)]$$

其中 $Z = \frac{\bar{X} - \mu_0}{\sigma/\sqrt{n}} \sim N(0, 1)$ (在 H_0 下)。

- t 检验中的 p 值公式（未知总体方差）

当 σ^2 未知、样本来自正态总体时，令

$$T = \frac{\bar{X} - \mu_0}{S/\sqrt{n}} \sim t_{n-1} \quad (\text{在 } H_0 \text{ 下}),$$

并用 t_{obs} 代替 z_{obs} ，把上面 Z 检验中的 $N(0, 1)$ 全部替换为 t_{n-1} 分布即可得到对应的 p 值。

- 广义似然比检验 Generalized Likelihood Ratio Test (GLRT)

设定

- 有独立同分布样本 $X_1, \dots, X_n$ ，模型密度（或 pmf）为 $f(x \mid \theta)$ ， $\theta \in \Omega$ 。

- 检验双侧假设:

$$H_0: \theta = \theta_0 \quad \text{vs} \quad H_1: \theta \neq \theta_0,$$

其中 θ_0 给定。

似然与广义似然比

- 全样本的似然函数:

$$L(\theta) = \prod_{i=1}^n f(X_i | \theta).$$

- 记 $\hat{\theta}$ 为 $L(\theta)$ 在参数空间 Ω 上的极大似然估计 (MLE)。
- 广义似然比统计量 (越小越不利于 H_0):

$$\Lambda = \frac{L(\theta_0)}{L(\hat{\theta})} \in (0, 1].$$

拒绝域 (大小 α 的检验)

- “小的 Λ 支持 H_1 ”。选择常数 c 使得在 H_0 下

$$\alpha = P(\Lambda < c | H_0),$$

从而采用**临界规则**: 当 $\Lambda < c$ 时**拒绝** H_0 。

- 等价地, 可用任意单调变换, 如

$$W = -2 \log \Lambda = 2[\ell(\hat{\theta}) - \ell(\theta_0)], \quad \ell(\theta) = \log L(\theta),$$

并在 $W > c'$ 时拒绝 H_0 。 c' 由同样的显著性水平 α 确定。

大样本近似 (Wilks 定理)

- 在常见的正则条件下, n 足够大时

$$-2 \log \Lambda \xrightarrow{d} \chi^2_{\text{df}},$$

其中 $\text{df} = \text{参数维度差} = \dim(\Omega) - \dim(\Omega_0)$ 。

本页双侧点假设 (1 个参数) 下, $\text{df} = 1$ 。

- 因而可用

$$\text{p-value} = P(\chi^2_{\text{df}} \geq -2 \log \Lambda_{\text{obs}})$$

计算近似 p 值, 并据此作出决策。

与 Neyman-Pearson 的关系

- 当 H_0 与 H_1 都是**简单假设**时, GLRT 退化为**最有力检验** (N-P 引理)。
- 对**复合**备择, GLRT 提供通用且易实现的构造方法, 通常具有良好的大样本性质。
- 实操步骤 (配方)

1. 写出对数似然 $\ell(\theta) = \sum_{i=1}^n \log f(X_i | \theta)$ 。

2. 求 MLE: $\hat{\theta} = \arg \max_{\theta \in \Omega} \ell(\theta)$ 。

3. 计算统计量:

$$\Lambda = \frac{L(\theta_0)}{L(\hat{\theta})} \quad \text{或} \quad W = -2 \log \Lambda = 2\{\ell(\hat{\theta}) - \ell(\theta_0)\}.$$

4. **小样本**：若能得到 Λ 的精确分布，用精确临界值 c （或 c' ）；

大样本：用 $W \approx \chi_{df}^2$ 求临界值或 p 值。

5. 依据 α 做出结论： $\Lambda < c$ （等价 $W > c'$ ）则拒绝 H_0 。

- Likelihood Ratio (LR) 检验：复合原假设 vs 复合备择

问题设置

参数空间为 Θ ，原假设下的可行参数集合为 $\Theta_0 \subset \Theta$ 。给定样本 $X = (X_1, \dots, X_n)$ ，似然函数为 $L(\theta)$ 。

广义似然比统计量

定义

$$\Lambda = \frac{\max_{\theta \in \Theta_0} L(\theta)}{\max_{\theta \in \Theta} L(\theta)},$$

其中分子是原假设允许的参数空间 Θ_0 上的最大似然，分母是全参数空间 Θ 上的最大似然。

性质 (Properties of Λ)

1. **取值范围**： $\Lambda(X) \in [0, 1]$ 。

分母不小于分子，因此比值不超过 1，同时似然非负使得比值不为负。

2. **证据方向**： Λ 越小，对 H_0 越不利。

因为这意味着在全空间能取得的最大似然远大于在 Θ_0 内能取得的最大似然。

3. **大样本分布 (Wilks 定理)**

在常见的平滑正则条件下， $n \rightarrow \infty$ 时

$$-2 \log \Lambda \xrightarrow{d} \chi_{r-r_0}^2,$$

其中 $r = \dim(\Theta_1)$ 是备择下的自由参数个数， $r_0 = \dim(\Theta_0)$ 是原假设下的自由参数个数（ Θ_1 表示备择允许的参数子空间，通常与 Θ 维度相同）。

4. **决策规则 (大小为 α)**

给定显著性水平 α ，取临界值 c_α 使

$$P_{H_0}(-2 \log \Lambda > c_\alpha) = \alpha, \quad c_\alpha = \chi_{r-r_0}^2(\alpha),$$

则当 $-2 \log \Lambda > c_\alpha$ 时拒绝 H_0 。

例：单样本 $N(\mu, \sigma^2)$ ，检验均值

模型与假设

独立同分布样本 $X_1, \dots, X_n \sim N(\mu, \sigma^2)$ ， σ^2 已知。

检验 $H_0: \mu = \mu_0$ 对 $H_1: \mu \neq \mu_0$ 。

GLRT 构造

GLRT 的统计量为

$$\Lambda = \frac{\max_{\theta \in \Theta_0} L(\theta)}{\max_{\theta \in \Theta} L(\theta)} = \frac{L(\mu_0)}{L(\hat{\mu})},$$

其中 $\hat{\mu} = \bar{X}$ 是无约束极大似然估计。

把正态对数似然代入可得 Λ 是 $|\bar{X} - \mu_0|$ 的单调函数，因而 GLRT 的拒绝域等价于

$$\Lambda < c \iff \frac{|\bar{X} - \mu_0|}{\sigma/\sqrt{n}} > c^*$$

显著性水平与临界值

在 H_0 下, $\frac{\sqrt{n}(\bar{X} - \mu_0)}{\sigma} \sim N(0, 1)$ 。

取 $c^* = z(\alpha/2)$ (标准正态上侧 $\alpha/2$ 分位数), 得到 $100(1 - \alpha)\%$ 的 GLRT:

$$\text{拒绝 } H_0 \iff \frac{|\bar{X} - \mu_0|}{\sigma/\sqrt{n}} > z(\alpha/2).$$

例: 两独立正态总体方差比较 (等方差检验)

模型与假设

两独立样本: $X_{1,1}, \dots, X_{1,n_1} \sim N(\mu_1, \sigma_1^2)$;

$X_{2,1}, \dots, X_{2,n_2} \sim N(\mu_2, \sigma_2^2)$, 相互独立。

检验

$$H_0: \sigma_1^2 = \sigma_2^2 = \sigma^2 \quad \text{vs} \quad H_1: \sigma_1^2 \neq \sigma_2^2.$$

极大似然与 GLRT

记样本方差 $S_i^2 = \frac{1}{n_i-1} \sum_{j=1}^{n_i} (X_{i,j} - \bar{X}_i)^2$ ($i = 1, 2$)。

无约束 MLE 为 $\hat{\mu}_i = \bar{X}_i$, $\hat{\sigma}_i^2 = S_i^2$;

约束 (H_0) 下的 MLE 为 **合并方差**

$$\hat{\sigma}^2 = \frac{(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2}{n_1 + n_2 - 2}.$$

代入似然比后可化简为对统计量

$$F = \frac{S_1^2}{S_2^2}$$

的单调函数 (取 $S_1^2 \geq S_2^2$ 时 $F \geq 1$)。在 H_0 下

$$F \sim F_{n_1-1, n_2-1}.$$

双侧检验的拒绝域与临界值

令 $F_{\nu_1, \nu_2}(\cdot)$ 为 F 分布分位数。取对称显著性水平 α ,

$$\text{拒绝 } H_0 \iff F < F_{n_1-1, n_2-1}(\alpha/2) \text{ 或 } F > F_{n_1-1, n_2-1}(1 - \alpha/2).$$

在实际计算中, 常把较大的样本方差放在分子 (使 $F \geq 1$), 然后只用右尾临界值

$$\text{拒绝 } H_0 \iff F > F_{n_1-1, n_2-1}(1 - \alpha/2),$$

并把左尾对称性体现在“把大者置于分子”的约定中 (或同时报告两侧 p 值)。